

Rosângela Miyeko Shigenari

# **Implementação de um Sistema de Navegação usando Fusão Sensorial através dos Filtros Complementar e de Kalman**

São José dos Campos

25 de outubro de 2020

Rosângela Miyeko Shigenari

**Implementação de um Sistema de Navegação usando  
Fusão Sensorial através dos Filtros Complementar e de  
Kalman**

Trabalho de Conclusão de Curso apresentado  
à disciplina de Trabalho de Graduação do  
curso de Engenharia de Computação do Insti-  
tuto de Ciência e Tecnologia da Universidade  
Federal de São Paulo, como requisito parcial  
para obtenção do título de Engenheira da  
Computação.

Universidade Federal de São Paulo  
Instituto de Ciência e Tecnologia  
Bacharelado em Engenharia da Computação

Orientador: Prof. Dr. Sergio Ronaldo Barros dos Santos

São José dos Campos  
25 de outubro de 2020

Rosângela Miyeko Shigenari

Implementação de um Sistema de Navegação usando Fusão Sensorial através dos Filtros Complementar e de Kalman/ Rosângela Miyeko Shigenari. – São José dos Campos , 25 de outubro de 2020-

[111](#)

Orientador: Prof. Dr. Sergio Ronaldo Barros dos Santos

Trabalho de Graduação – Universidade Federal de São Paulo

Instituto de Ciência e Tecnologia

Bacharelado em Engenharia da Computação, 25 de outubro de 2020.

1. Filtro de Kalman. 2. IMU. 2. GPS. I. Sérgio Ronaldo Barros dos Santos.  
II. Universidade Federal de São Paulo. III. Instituto de Ciência e Tecnologia. IV.  
Bacharelado em Engenharia da Computação.

Rosângela Miyeko Shigenari

# **Implementação de um Sistema de Navegação usando Fusão Sensorial através dos Filtros Complementar e de Kalman**

Trabalho de Conclusão de Curso apresentado  
à disciplina de Trabalho de Graduação do  
curso de Engenharia de Computação do Insti-  
tuto de Ciência e Tecnologia da Universidade  
Federal de São Paulo, como requisito parcial  
para obtenção do título de Engenheira da  
Computação.

---

**Prof. Dr. Sergio Ronaldo Barros dos  
Santos**  
Orientador

---

**Prof. Dr. André Marcorin de Oliveira**  
Convidado 1

---

**Prof. Dr. Luiz Eduardo Galvão  
Martins**  
Convidado 2

São José dos Campos  
25 de outubro de 2020

*Dedico este trabalho aos meus pais, Alice e Toshimitsu, que sempre me apoiaram em toda minha vida acadêmica, abrindo portas para um mundo que eles não tiveram a oportunidade de conhecer, daqui para frente quero retribuir cada esforço e confiança que eles colocaram em mim.*

# Agradecimentos

Os agradecimentos especiais são direcionados ao meu orientador, professor Sérgio, que me deu todo auxílio e orientação necessária pra concluir este trabalho, além do grande aprendizado obtido nas disciplinas que ministrou durante minha graduação; ao professor Tiago Oliveira, por toda ajuda como coordenador do curso e também professor dos laboratórios de sistemas computacionais, representa uma das figuras mais marcantes da minha formação como engenheira de computação; e também ao professor Augusto Chaves, meu primeiro orientador, ainda no curso de Bacharelado em Ciência e Tecnologia, nunca tinha tido contato com a programação antes, e ele foi responsável por me apresentar as primeiras experiências na grande área que é a computação.

Por fim, gostaria deixar um *muito obrigada* a cada professor, colega, amigo que me ajudou a chegar até aqui, futuramente, quero usar o melhor que aprendi de cada um para poder fazer a diferença na vida de alguém, como todos estes fizeram na minha.

*“O estudo em geral, a busca da verdade e da beleza são domínios  
em que nos é consentido ficar crianças toda a vida.”*  
*(Albert Einstein)*

# Resumo

Este trabalho apresenta um estudo e a implementação de um sistema de navegação, através da fusão de dados relativos à posição geográfica obtidos pelo GPS (*Global Positioning System*) e da Unidade de Navegação Inercial (IMU), contendo um acelerômetro, um giroscópio e um magnetômetro. Essa fusão sensorial foi realizada através do *Filtro de Kalman*, que tem por objetivo realizar a correção de possíveis erros, decorrentes de ruídos ou outras incertezas, para que a posição geográfica de um determinado veículo terrestre seja obtida de maneira precisa. O Filtro de *Kalman*, por ser um sistema com memória, armazena informações sobre os valores passados, para serem utilizados no próximo ciclo. A partir dessa realimentação de dados, são lançadas estimativas, em uma fase chamada de *previsão* e posteriormente, realizada uma correção dessas incertezas através do *ganho de Kalman*, procedendo assim, a *atualização* desses valores acurados. Para realizar a coleta de dados da posição geográfica, foi utilizado um sistema embarcado contando com o microcontrolador baseado no ATMEGA2560 do Arduino Mega, IMU, um GPS e a implementação do Filtro de Kalman em C modificado do Arduino. Para auxiliar na análise de dados, foram desenvolvidos, em conjuntos, 2 módulos: o primeiro para análise das diferenças entre os dados brutos dos sensores e os melhoramentos após cada etapa de filtragem; e um simulador 3D, que esboça o posicionamento da IMU em função das coordenadas x, y e z.

**Palavras-chave:** filtro de *Kalman*, acelerômetro, giroscópio, magnetômetro, GPS, INS, fusão sensorial, *bias*, NED.

# Abstract

This work presents a study and the implementation of a navigation system by merging geographic position data obtained by GPS (Global Positioning System) and the IMU (Inertial Navigation Unit), containing an accelerometer, a gyroscope, and a magnetometer. This sensory fusion will be performed through the *Kalman Filter*, which aims to correct possible errors resulting from noise or other uncertainties, so that the geographical position of a particular land vehicle is obtained accurately. The Kalman Filter as a system with memory, stores information about the past values to be used in the next cycle, and from this data feedback, some estimates are released, in a phase called prediction. Subsequently, a correction of these uncertainties was performed through the *Kalman gain*, thus proceeding to *updating* these accurate values. Geographic position data will be collected using an embedded system relying on the microcontroller based on ATMEGA2560 of the Arduino Mega, IMU, a GPS and the Filter implementation of the Kalman Filter in modified Arduino C. To assist in data analysis, 2 module were developed in sets: the first one to analyze the differences between the raw data of the sensors and the improvements after each filtering step; and a 3D simulator, which sketches the positioning of the IMU as a function of x, y, and z coordinates.

**Keywords:** Kalman filter, accelerometer, gyroscope, magnetometer, GPS, INS, sensor fusion, bias, NED.

# Lista de ilustrações

|   |    |
|---|----|
| Figura 1 – Diagrama de Blocos do Sistema GNC (FARRELL; BARTH, 1999) . . . . .   | 31 |
| Figura 2 – Constelação dos satélites GPS (EMBRAPA, 2015) . . . . .  | 33 |
| Figura 3 – Sistema de triangulação (GIS, 2019) . . . . .  | 34 |
| Figura 4 – Sistema de trilateração (GIS, 2019) . . . . .  | 34 |
| Figura 5 – Representação do sistema de trilateração (GIS, 2019) . . . . .   | 35 |
| Figura 6 – Latitude ( $\phi$ ) e longitude ( $\lambda$ ) geodésicas e altitude geométrica (h) (CAMARA; CASANOVA; MAGALHAES, 1996) . . . . . | 36 |
| Figura 7 – Sistema de coordenadas NED (SANTANA, 2011) . . . . .   | 36 |
| Figura 8 – Possíveis fontes de erros na captura de feita pelo GPS (FRANCA, 2009) .  | 39 |
| Figura 9 – Imagem microscópica de um acelerômetro MEMS (CALACHE, 2013) .  | 41 |
| Figura 10 – Esquematização do funcionamento do giroscópio (FARIA, 2018) . . . . .   | 41 |
| Figura 11 – Magnetômetro HMC5883L . . . . .   | 42 |
| Figura 12 – Definição do <i>yaw</i> , <i>pitch</i> e <i>roll</i> (FARIA, 2018) . . . . .  | 43 |
| Figura 13 – Angulações <i>yaw</i> , <i>pitch</i> e <i>roll</i> (OLIVEIRA; NUNES, 2017) . . . . .  | 44 |
| Figura 14 – Diagrama de blocos do Filtro Complementar (ISLAM et al., 2017) . . . . .  | 45 |
| Figura 15 – Esquema do algoritmo do filtro de Kalman (ZANONI, 2012) . . . . .   | 51 |
| Figura 16 – Esquematização do funcionamento do Filtro de Complementar (YOO et al., 2011) . . . . .  | 61 |
| Figura 17 – Esquematização do funcionamento do <i>Filtro de Kalman</i> (OLIVEIRA; NUNES, 2017) . . . . .                                    | 63 |
| Figura 18 – Sistema de captação dos dados de posicionamento do sistema . . . . .  | 66 |
| Figura 19 – Central de Monitoramento . . . . .  | 67 |
| Figura 20 – Animação 3D com o <i>OpenGL</i> . . . . .   | 68 |
| Figura 21 – Trecho da função de inicialização, da biblioteca da IMU LSM9DS1 (SPARKFUN, 2018) . . . . .                                      | 70 |
| Figura 22 – Representação completa do Sistema de Navegação . . . . .  | 74 |
| Figura 23 – SparkFun 9DoF IMU Breakout - LSM9DS1 . . . . .  | 78 |
| Figura 24 – Funcionamento da interface com os dados da IMU . . . . .  | 79 |
| Figura 25 – Saída do Filtro Complementar a IMU em repouso em uma superfície plana (sem inclinação) . . . . .                                | 80 |
| Figura 26 – Saída do Filtro Complementar com relação ao eixo lateral . . . . .  | 80 |
| Figura 27 – Saída do Filtro Complementar com relação ao eixo longitudinal . . . . .   | 81 |
| Figura 28 – IMU sem inclinação em relação ao eixo vertical . . . . .  | 81 |
| Figura 29 – IMU com inclinação de 90° em relação ao eixo vertical . . . . .   | 81 |
| Figura 30 – Resultado da trajetória do automóvel em descida, com o GPS . . . . .  | 83 |
| Figura 31 – Resultado da trajetória do automóvel subindo uma ladeira, com o GPS   | 83 |

|   |     |
|---|-----|
| Figura 32 – Resultado da trajetória em linha reta do automóvel com o GPS . . . . .  | 84  |
| Figura 33 – Resultado de uma trajetória fechada . . . . .   | 84  |
| Figura 34 – Central de monitoramento em resposta a trajetória 1 . . . . .   | 86  |
| Figura 35 – Resposta da central de monitoramento com a trajetória 2 . . . . .   | 87  |
| Figura 36 – Resposta da central de monitoramento com a trajetória 3 . . . . .   | 87  |
| Figura 37 – Trajetória 3: Variação do eixo X em função do tempo . . . . .   | 88  |
| Figura 38 – Trajetória 3: Variação do eixo Y em função do tempo . . . . .   | 88  |
| Figura 39 – Trajetória 3: Diferença observada entre o resultado do Filtro de Kalman<br>e do módulo GPS, no eixo x, em função do tempo . . . . . | 89  |
| Figura 40 – Trajetória 3: Diferença observada entre o resultado do Filtro de Kalman<br>e do módulo GPS, no eixo y, em função do tempo . . . . . | 89  |
| Figura 41 – Variação do vetor <i>bias</i> , em função do tempo, em segundos . . . . .   | 91  |
| Figura 42 – Posicionamento do veículo em função do tempo . . . . .  | 102 |
| Figura 43 – Erro obtido pela medição e o obtido pelo estimador (Filtro de Kalman) .   | 103 |
| Figura 44 – Velocidade medida e estimada do veículo . . . . .   | 103 |
| Figura 45 – Erro na estimativa da velocidade do veículo . . . . .   | 104 |

# Lista de tabelas

|   |    |
|---|----|
| Tabela 1 – Significado das sequências no NMEA (FRANCISCO; MONICO, 2001) | 38 |
| Tabela 2 – Materiais a serem utilizados no projeto . . . . .            | 59 |
| Tabela 3 – Materiais a serem utilizados no projeto . . . . .            | 78 |

# **Lista de Pseudocódigos**

|     |   |     |
|-----|---|-----|
| 3.1 | Função de implementação da bússola              | 62  |
| 4.1 | Função de leitura de dados da porta serial      | 69  |
| A.1 | Implementação do Filtro Complementar no Arduino | 107 |
| B.1 | Simulação do Filtro de Kalman (SIMON, 2001)     | 109 |

# Lista de abreviaturas e siglas

|         |   |
|---------|---|
| CTP     | Conventional Terrestrial Pole                           |
| GPGGA   | Global Positioning System Fix Data                      |
| GPS     | Global Positioning System                               |
| GLONASS | Global Navigation Satellite System                      |
| GNC     | Guidance, Navigation and Control                        |
| I2C     | Inter-integrated Circuit                                |
| IMU     | Inertial Measurement Unit                               |
| INS     | Inertial Navigation System                              |
| MEMS    | Micro-Electro-Mechanical Systems                        |
| NED     | North-East-Down   |
| NMEA    | National Marine Electronics Association                 |
| NED     | North-East-Down   |
| PC      | Personal Computer                                       |
| SPI     | Serial Peripheral Interface                             |
| USART   | Universal Synchronous/Asynchronous Receiver/Transmitter |
| USB     | Universal Serial Bus                                    |
| WGS84   | World Geodetic System                                   |

# Lista de símbolos

|           |                                       |
|-----------|---------------------------------------|
| $p_x$     | Posição do corpo no eixo x            |
| $p_y$     | Posição do corpo no eixo y            |
| $p_z$     | Posição do corpo no eixo z            |
| $a_x$     | Aceleração do corpo no eixo x         |
| $a_y$     | Aceleração do corpo no eixo y         |
| $w_z$     | Velocidade Angular do corpo no eixo z |
| $\Phi$    | Latitude                              |
| $\lambda$ | Longitude                             |
| $\phi$    | Pitch                                 |
| $\theta$  | Roll                                  |
| $\psi$    | Yaw                                   |

# Sumário

|            |  |           |
|------------|--|-----------|
| <b>1</b>   | <b>INTRODUÇÃO</b>  | <b>27</b> |
| <b>1.1</b> | <b>Objetivo</b>  | <b>28</b> |
| <b>1.2</b> | <b>Motivação</b>   | <b>28</b> |
| <b>1.3</b> | <b>Organização do trabalho</b>                                   | <b>28</b> |
| <b>2</b>   | <b>REVISÃO BIBLIOGRÁFICA</b>                                     | <b>31</b> |
| <b>2.1</b> | <b>Fundamentação Teórica</b>                                     | <b>31</b> |
| 2.1.1      | Sistema de Navegação   | 31        |
| 2.1.2      | <i>Global Positioning System (GPS)</i>                           | 32        |
| 2.1.2.1    | Satélite   | 33        |
| 2.1.3      | Sistema de Coordenadas   | 35        |
| 2.1.3.1    | Funcionamento do GPS   | 36        |
| 2.1.4      | Transmissão de Dados   | 37        |
| 2.1.4.1    | <i>World Geodetic System (WGS84)</i>                             | 37        |
| 2.1.4.2    | <i>National Marine Electronics Association (NMEA)</i>            | 38        |
| 2.1.5      | Processamento de Dados do Sistema de Posicionamento Global (GPS) | 39        |
| 2.1.6      | <i>Inertial Navigation System (INS)</i>                          | 39        |
| 2.1.7      | <i>Inertial Measurement Unit (IMU)</i>                           | 40        |
| 2.1.8      | Fusão Sensorial  | 42        |
| 2.1.8.1    | Definição de <i>roll</i> , <i>pitch</i> e <i>yaw</i>             | 43        |
| 2.1.9      | Filtro Complementar  | 44        |
| 2.1.10     | Filtro de Kalman   | 46        |
| 2.1.10.1   | Atualização  | 52        |
| 2.1.10.2   | Propagação   | 53        |
| <b>2.2</b> | <b>Trabalhos Relacionados</b>                                    | <b>54</b> |
| <b>3</b>   | <b>MATERIAIS E MÉTODOS</b>                                       | <b>59</b> |
| <b>3.1</b> | <b>Recursos Utilizados</b>                                       | <b>59</b> |
| 3.1.1      | Materiais  | 59        |
| 3.1.1.1    | Especificações dos módulos de captação de dados.                 | 60        |
| <b>3.2</b> | <b>Métodos</b>   | <b>61</b> |
| 3.2.1      | Filtro Complementar  | 61        |
| 3.2.2      | Bússola Digital  | 62        |
| 3.2.3      | Filtro de Kalman   | 62        |
| <b>4</b>   | <b>DESENVOLVIMENTO</b>   | <b>65</b> |

|         |   |     |
|---------|---|-----|
| 4.1     | Desenvolvimento do Sistema de Captura de Dados . . . . .                                  | 65  |
| 4.2     | Módulo 1: Central de Monitoramento . . . . .  | 66  |
| 4.3     | Módulo 2: Animação 3D . . . . .   | 68  |
| 4.4     | Filtro Complementar . . . . .   | 69  |
| 4.4.1   | Giroscópio . . . . .  | 69  |
| 4.4.2   | Acelerômetro . . . . .  | 70  |
| 4.4.3   | Implementação . . . . .   | 71  |
| 4.5     | Sistema de Posicionamento Global (GPS) . . . . .  | 72  |
| 4.6     | Fusão sensorial por Filtro de Kalman . . . . .  | 73  |
| 4.6.1   | Implementação . . . . .   | 73  |
| 4.6.1.1 | Inicialização . . . . .   | 74  |
| 4.6.1.2 | Atualização . . . . .   | 75  |
| 4.6.1.3 | Propagação ou Predição . . . . .  | 76  |
| 5       | <b>RESULTADOS</b> . . . . .   | 77  |
| 5.1     | Custos de implementação . . . . .   | 77  |
| 5.2     | Determinação da atitude usando o Filtro Complementar . . . . .                            | 78  |
| 5.3     | Navegação com o Módulo GPS . . . . .  | 81  |
| 5.4     | Navegação usando a Fusão Sensorial entre IMU e GPS a partir do Filtro de Kalman . . . . . | 85  |
| 6       | <b>CONCLUSÃO</b> . . . . .  | 93  |
|         | <b>REFERÊNCIAS</b> . . . . .  | 95  |
|         | <b>APÊNDICES</b> . . . . .  | 99  |
|         | APÊNDICE A – FILTRO DE KALMAN PROPOSTO POR (SIMON, 2001) . . . . .                        | 101 |
|         | <b>ANEXOS</b> . . . . .   | 105 |
|         | ANEXO A – FILTRO COMPLEMENTAR . . . . .   | 107 |
|         | ANEXO B – SIMULAÇÃO DO FILTRO DE KALMAN . . . . .   | 109 |
|         | ANEXO C – REPOSITÓRIO NO GITHUB . . . . .   | 111 |

# 1 Introdução

A década de 1970 é conhecida como um dos períodos de maior tensão da história contemporânea, a Guerra Fria. Durante essa época, houve um grandioso avanço tecnológico, principalmente voltado à área militar. Nesse contexto foi criado o Sistema de Posicionamento Global, ou GPS, que era inicialmente utilizado em aeronaves e navios militares, para que pudessem estimar, em qualquer momento, sua posição geográfica precisa, ajudando na localização de tropas em movimento e em lançamento de mísseis, por exemplo (MACIEL et al., 2012). Devido ao seu caráter eficiente para determinação do posicionamento global, com o passar do tempo, o GPS se tornou uma ferramenta a ser amplamente utilizada por civis, passando a ter diversas aplicações na atualidade, como por exemplo, na determinação de rotas de viagens e na estimativa de localização, no uso de sistemas de rastreamento de objetos, no mapeamento de áreas, entre outros. Por esse motivo, esse sistema é um grande objeto de estudos ainda nos dias atuais (NASCIMENTO, 2018).

Embora o GPS seja uma ótima ferramenta para determinação da localização, está propenso à erros de medição, causados por inúmeros tipos de interferências, como as barreiras físicas (árvores, construções, veículos, etc), assim, necessitando de correções para as diversas aplicações onde a precisão é um ponto crucial.

A margem de erro existente nos GPSs é gerada por problemas técnicos durante propagação ou interferências como em regiões cercadas por prédios ou florestas, por exemplo. Com isso, pesquisadores de todo o mundo buscam minimizar essa margem à zero, que significaria um grande avanço ao desenvolvimento de veículos autônomos, robôs com auto-orientação, que realizam trabalhos assistenciais à deficientes e idosos; drones que conseguem realizar entrega confiável de objetos ou até permitir o rastreamento de pessoas; entre outras inovações tecnológicas decorrente da precisa estimativa da localização.

A obtenção de um posicionamento geográfico mais preciso foi objeto de inúmeros estudos na literatura, como o trabalho realizado por (OLIVEIRA; NUNES, 2017) e (SIMON, 2001), que utilizaram técnicas de fusão sensorial para este propósito.

A fusão sensorial pode ser feita de diversas formas. Dentre as abordagens mais conhecidas podemos citar: o Filtro Complementar (usando somente para estimar a atitude do veículo no ambiente) e o Filtro de *Kalman* (usado para realizar a fusão entre os dados dos sensores inerciais e GPS, estimando a atitude, velocidade e posição do veículo no ambiente), que serão discutidas mais adiante, e justificada a escolha desse último para a futura aplicação neste projeto.

## 1.1 Objetivo

O objetivo deste trabalho é realizar o desenvolvimento de um Sistema de Navegação terrestre e de baixo custo, utilizando os módulos de Unidade de Medição Inercial (*Inertial Measurement Unit*, IMU), o de Sistema de Posicionamento Global (*Global Position System*, GPS) e a técnica de fusão sensorial.

A técnica de fusão sensorial é realizada, primeiramente, utilizando a IMU e aplicando o Filtro Complementar, onde serão obtidos os valores de atitude de um veículo (*roll*, *pitch* e *yaw*) e também a implementação da bússola utilizando o magnetômetro para o cálculo do ângulo *yaw* usado pelo filtro de Kalman, distinta da primeira. Em paralelo, com o auxílio do módulo GPS, são obtidos os valores do posicionamento do veículo, em latitude e longitude, posteriormente, convertidos para coordenadas cartesianas (x, y e z). O resultado desses três procedimentos (medidas de atitude, *yaw* estimado pela bússola e posicionamento do veículo, em coordenadas cartesianas) serão as entradas para o Filtro de Kalman.

## 1.2 Motivação

Atualmente são realizados inúmeros estudos acerca da navegação autônoma, que inclui uma série de dificuldades relacionadas a encontrar uma metodologia eficaz, e possua um custo compatível com os recursos disponibilizados para a pesquisa, as limitações dos materiais utilizados para a captação de dados, entre outros.

Exemplos de trabalhos desenvolvidos nesta área são o de (MACIEL, 2018), que utilizou movimentos de cabeça e comandos de voz de cadeirantes como entrada para o Filtro de Kalman com o objetivo de desenvolver um sistema de navegação semiautônomo e assistencial; e também o de (CABRAL, 2017), que utilizou a fusão sensorial de medidas iniciais e dados obtidos por um sistema acústico, utilizando a mesma técnica: o Filtro de Kalman.

Dessa forma, a motivação deste projeto é contribuir para esse estudo acerca da navegação autônoma, utilizando um sistema de baixo custo de implementação (construído com o Arduino e os módulos GPS e IMU), integrado às técnicas amplamente utilizadas na literatura: os Filtros Complementar e de Kalman.

## 1.3 Organização do trabalho

Este trabalho é dividido em capítulos. Iniciando-se no Capítulo 1, que corresponde a introdução, onde são apresentados os objetivos e a motivação para o desenvolvimento do projeto, a formulação do problema e a descrição do sistema utilizado como solução.

O Capítulo 2 corresponde a revisão bibliográfica, que apresenta a fundamentação

teórica e os estudos realizados com base na literatura, relacionados ao Filtro de Kalman, ao Filtro Complementar e outros exemplos de fusão sensorial.

O Capítulo 3 contém os materiais utilizados para o desenvolvimento do sistema de captação de dados do posicionamento geográfico, tal como os métodos utilizados para a fusão sensorial (por Filtro Complementar e de Kalman).

O Capítulo 4 descreve o Sistema de Navegação INS/GPS, a construção do sistema e como foi integrada a fusão sensorial realizada através do Filtro Complementar e de Kalman.

O capítulo 5 apresenta e discute os resultados obtidos através do sistema de navegação utilizando a fusão sensorial mencionada anteriormente.

O capítulo 6 contém a conclusão deste trabalho e os aprimoramentos que podem ser realizados, futuramente, no sistema proposto.

## 2 Revisão Bibliográfica

Este capítulo será dividido em duas seções: a primeira trará a fundamentação teórica para o desenvolvimento do trabalho, assim sendo, serão abordados os principais conceitos utilizados; na segunda parte, os trabalhos relacionados ao presente projeto serão apresentados.

### 2.1 Fundamentação Teórica

Nesta seção serão discorridas as principais definições utilizadas e aplicadas durante o desenvolvimento do projeto.

#### 2.1.1 Sistema de Navegação

Um Sistema de Navegação é um sistema composto por um conjunto de dispositivos que tem por finalidade auxiliar o motorista na tarefa de manutenção da rota, sendo utilizadas em aplicações onde o caminho é pouco conhecido ou desconhecido pelo condutor (MARQUES; DECANINI; PUGLIES, 2012). A localização retornada pelo sistema é obtida em relação a um ponto de referência inicial que pode ser definida de inúmeras maneiras, e empregadas em diversas aplicações como em indústrias, na área militar ou até mesmo em nosso cotidiano. (FARRELL, 2008).

O sistema de navegação se baseia em torno de um problema de orientação, navegação e controle, também chamado de GNC (*guidance, navigation and control*). O diagrama de blocos do sistema GNC é mostrado na Figura 1.

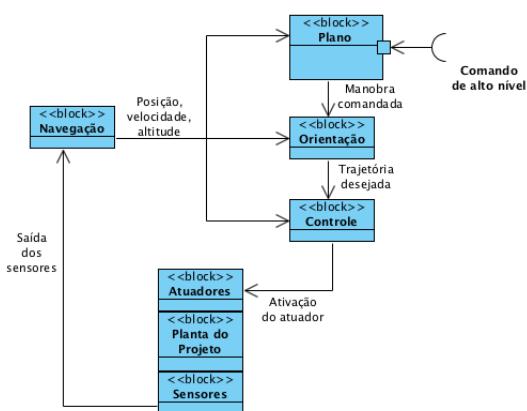


Figura 1 – Diagrama de Blocos do Sistema GNC (FARRELL; BARTH, 1999)

(FARRELL; BARTH, 1999) definem o GNC como um sistema em que há um comando de entrada, definindo um plano de ação, que retornará uma orientação, e assim, pode-se obter a trajetória desejada, onde através de sensores e atuadores resultará em uma saída a ser utilizada para a navegação. Essa saída retornará ao condutor informações como sua a posição, velocidade e altitude, a partir de um ponto de referência (FARRELL; BARTH, 1999).

Os sistemas mais conhecidos para se obter o posicionamento a partir de um dado ponto de referência é o GPS (*Global Positioning System*) e o INS (*Inertial Navigation System*), que serão abordados nas próximas seções.

### 2.1.2 *Global Positioning System (GPS)*

O GPS, ou NAVSTAR-GPS (*Navegation Satellite with Time and Hanging*) é um sistema de radioavegação implementado pelo Departamento de Defesa dos Estados Unidos, resultado da fusão de dois programas financiados pelo governo sob responsabilidade da Marinha e das Forças Aéreas, que tinham o intuito de implementar um sistema de navegação de abrangência global (FRANCISCO; MONICO, 2001). Atualmente, o sistema GPS é composto por 24 satélites ativos e 3 de reserva (FLORENZANO; CALLOTTI, 2002).

Esse sistema teve como meta fornecer, em tempo real, a posição, velocidade, rumo e hora certa para um veículo, independente de sua altitude e localização na Terra, isto é, desde um navio até um avião supersônico em qualquer ponto na Terra. Para alcançar estas metas, o sistema utiliza como princípio, a medição da distância do veículo em relação aos pontos conhecidos. A solução foi encontrada com uma constelação de 24 satélites (Figura 2), chamado de segmento espacial, distribuídos em 6 planos orbitais inclinados de 55° em relação ao Equador a uma altura aproximada de 20.000 km. Os satélites, dotados de padrões atômicos de freqüência e tempo, transmitem sinais horários de alta precisão na faixa de 1.500 MHz. Esta faixa foi escolhida devido a sua baixa susceptibilidade das interferências da ionosfera, atmosfera neutra e condições climatológicas. A determinação da posição espacial instantânea do veículo, em um sistema cartesiano geocêntrico, X, Y e Z, é obtida pela solução de um sistema de equações envolvendo um mínimo de 3 distâncias medidas a 3 satélites "visíveis" simultaneamente por uma antena receptora de sinais de GPS (VARGAS, 2001).

A seguir, serão discorridos termos importantes para a compreensão do funcionamento do GPS.

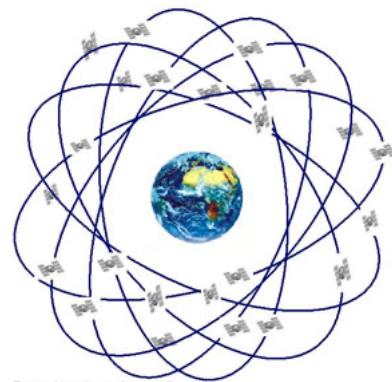


Figura 2 – Constelação dos satélites GPS (EMBRAPA, 2015)

### 2.1.2.1 Satélite

Satélites são corpos que se deslocam em círculos em torno de outros (FLORENZANO; CALLOTTI, 2002). Existem os **satélites naturais**, como, por exemplo, a Lua, que orbita a Terra, e os **artificiais**, que foram criados pelo homem para suas aplicações tecnológicas, como buscar informações sobre a coordenada geográfica na qual um dado corpo se encontra.

Os satélites artificiais possuem sensores capazes de enviar inúmeros dados à Terra, utilizados em diversas atividades como no estudo da atmosfera, monitoramento do clima, obtenção do posicionamento de um veículo e também de ampla aplicação na área da telecomunicação (KUGA et al., 2000). Essas aplicações exigem um monitoramento após o lançamento, realizando-se para este fim, uma comunicação por meio de transmissão e recepção de códigos, de maneira constante, entre os satélites e a Terra. Para que haja essa transmissão, é necessária uma alimentação de energia elétrica, que é obtida através de baterias e painéis fotovoltaicos, mas devido ao baixo rendimento de conversão desses últimos, os receptores da Terra devem possuir um ganho elevado e a órbita deve ser conhecida com grande precisão para que o posicionamento do satélite seja bem prevista, evitando possíveis falhas de comunicação (FLORENZANO; CALLOTTI, 2002).

Os satélites são posicionados através de sistemas chamados de **triangulação** e **trilateração**.

A **Triangulação** é utilizada para calcular o posicionamento medindo o ângulo formado entre os 3 satélites, utilizando uma base como referência. Ao se determinar os três pontos, forma-se a configuração mostrada na Figura 3.

Neste sistema é mensurado apenas os ângulos entre os pontos, mas não são utilizadas as distâncias para se obter o posicionamento, diferente do *sistema de trilateração*.

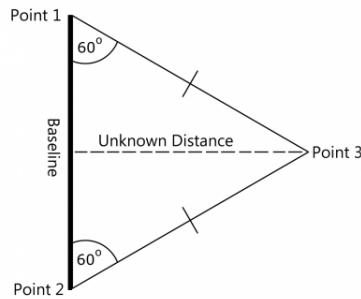


Figura 3 – Sistema de triangulação (GIS, 2019)

Na **trilateração** é realizada a medição das distâncias e não dos ângulos, onde nota-se que este é este o sistema utilizado nos GPS. Todos os satélites sincronizados enviam os sinais como um *broadcast* para o receptor, que realiza a captura de dados em uma determinada distância e tempo em relação ao satélite emissor do sinal.

Por exemplo, um primeiro satélite envia um sinal (*broadcast*), o receptor o recebe, a partir de uma distância conhecida, que é igual pra todos os sentidos em relação ao satélite, formando um círculo com raio  $r$ , ou seja, o GPS pode estar em qualquer posição dentro deste círculo. A Figura 4 mostra a representação em duas dimensões do sistema de trilateração a cada passo da conexão entre os satélites, até a obtenção dos dados solicitados pelo usuário do sistema.

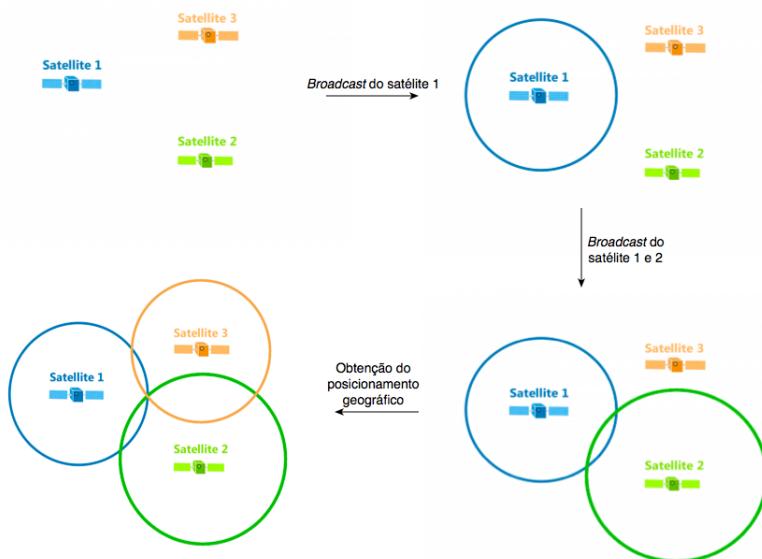


Figura 4 – Sistema de trilateração (GIS, 2019)

Os círculos representados, na realidade, são esferas, onde cada satélite está situado ao centro. A interseção dessas esferas determina o posicionamento a ser enviado pelo receptor do GPS, como mostrada Figura 5.

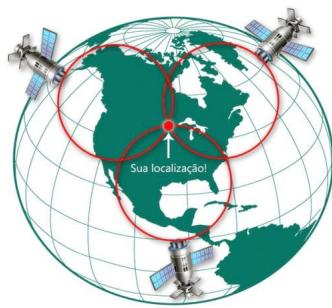


Figura 5 – Representação do sistema de trilateração ([GIS, 2019](#))

O receptor utiliza a mensagem recebida para determinar o tempo de transição de cada mensagem e dessa forma, computar a distância, em relação a cada satélite.

### 2.1.3 Sistema de Coordenadas

O sistema de coordenadas é utilizado para detectar o posicionamento de um determinado sistema/corpo, tendo como origem, o sistema de coordenadas que coincide com o centro de massa da Terra. Um ponto sobre a superfície terrestre pode ser representado por sistemas de coordenadas, onde podemos citar dois exemplos: o Sistema Curvilíneo ou **Geodésico** e o **NED** ("*North-East-Down*") ([ZANONI, 2012](#)).

- **Sistema Geodésico**

É um sistema de coordenadas esféricas, representado pelas longitude e latitude, que representam juntas um ponto na superfície terrestre. A primeira é a distância angular relativa entre um determinado ponto na Terra e o meridiano de origem, o segundo, a distância relativa à linha do Equador. Um outro parâmetro que pode ser levado em consideração também é a **altitude**, que é a altura relativa do ponto em relação ao nível do mar ([CAMARA; CASANOVA; MAGALHAES, 1996](#)). A Figura 6 mostra uma representação desses eixos (ROBSON, 1995).

- **Sistema NED ("*North-East-Down*")**

O NED é um sistema de coordenadas utilizado para navegação local, onde o ponto de referência pode ser definido em qualquer localidade da Terra. O eixo X possui a orientação para o norte geográfico, o Y referenciado através da regra da mão direita e o Z aponta para o centro do planeta([SANTANA et al., 2004](#)). A Figura 7 mostra a representação do sistema de coordenada NED.

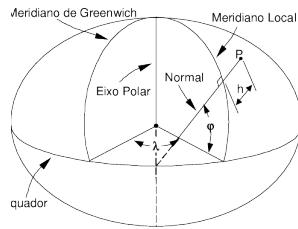


Figura 6 – Latitude ( $\phi$ ) e longitude ( $\lambda$ ) geodésicas e altitude geométrica (h) (CAMARA; CASANOVA; MAGALHAES, 1996)

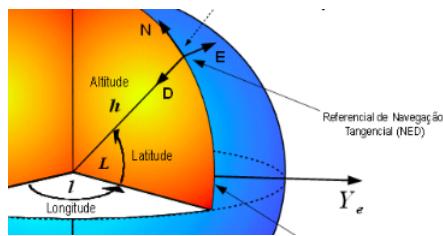


Figura 7 – Sistema de coordenadas NED (SANTANA, 2011)

Como mostrada na figura anterior, neste sistema, a Terra é simbolizada como uma superfície plana no local onde a navegação está sendo explorada. Pode ser utilizado para se percorrer trajetórias com longas distâncias sobre a superfície terrestre, os dados de navegação são obtidos em termos da longitude, latitude e altitude; por esse motivo, é amplamente utilizado para navegação de veículos (ZANONI, 2012).

#### 2.1.3.1 Funcionamento do GPS

As informações sobre o posicionamento geográfico de um determinado corpo dados pela latitude, longitude e altitude são a base de funcionamento do GPS. O surgimento desse sistema permite que usuários em qualquer parte do planeta Terra tenha disponível, no mínimo, quatro satélites para serem rastreados de forma a se obter esse posicionamento (FRANCISCO; MONICO, 2001).

O princípio básico de funcionamento do GPS é conhecer as coordenadas desses satélites fazendo o uso de um sistema de referência apropriado, possibilitando, em seguida, calcular as coordenadas da antena do usuário aplicando o mesmo sistema de referência. O GPS possui três segmentos principais, que serão descritos abaixo (BERNARDI; LANDIM, 2002).

- **Segmento Espacial:** Possui a função de gerar e transmitir os sinais do GPS. Esses satélites são capazes de se comunicarem entre si, de transmitir mensagens para o

sistema de controle na Terra e também de calcular os possíveis erros do próprio satélite.

- **Segmento de Controle:** Tem como principais funções realizar o monitoramento e controle contínuo do sistema de satélites, realizar as correções dos relógios dos satélites, determinar o tempo GPS, fazer a predição de possíveis falhas dos satélites e, periodicamente, atualizar os dados de navegação recebidos de cada satélite.
- **Segmento de Usuários:** É constituído basicamente dos receptores do GPS, que são utilizados para navegação de veículos terrestres, navios, aviões e outros meios de transporte; retorno do posicionamento de objetos em um dado espaço; detecção de movimentos da placa tectônica, dentre outras aplicações.

## 2.1.4 Transmissão de Dados

Ao se realizar a conexão com no máximo três satélites, como mostrado anteriormente, o sinal é transmitido a partir de cada satélite em direção ao ponto de intersecção na Terra. Esse sinal é codificado como uma "mensagem de navegação", que será lida por um receptor GPS. Essas mensagens possuem "parâmetros de órbita", para que os receptores possam obter as coordenadas (X, Y, Z) dos satélites (BLEWITT, 2001). O GPS utiliza o Sistema Geodésico Global (*World Geodetic System*, WGS84), que utiliza o sistema de coordenadas terrestres.

### 2.1.4.1 *World Geodetic System* (WGS84)

O Sistema Geodésico Global (*World Geodetic System*, WGS84) é a quarta versão do sistema de posicionamento global, criado em 1960, e estabelecido pelo Departamento de Defesa Americano (*Department of Defense*, DoD), com o objetivo de prover o posicionamento e dados de navegação em qualquer parte do mundo. Este é o sistema de referência do sistema de posicionamento global (GPS), por esse motivo, a importância do WGS84 em relação aos outros sistemas de referência. Os parâmetros utilizados por esse sistema são:

- *Z-Axis:* A direção do polo de referência do Serviço Internacional de Sistemas de Referência e Rotação da Terra (IERS). Esta direção corresponde à direção do Pólo Terrestre Convencional (*Conventional Terrestrial Pole*, CTP), com uma incerteza de 0,005 ″.
- *X-Axis:* Intersecção do Meridiano de Referência IERS (IERS *Reference Meridian*, IRM) e o plano passando pela origem e normal ao eixo Z.
- *Y-Axis:* Completa o sistema de coordenadas ortogonais fixas à Terra, este eixo é centrado na Terra.

### 2.1.4.2 National Marine Electronics Association (NMEA)

A US *National Marine Electronics Association* (NMEA) criou, em 1983, formato NMEA 0183 que consiste em uma interface dos dispositivos eletrônicos marítimos, que acabou se tornando o padrão industrial dos receptores do Sistema Global de Navegação por Satélite (*Global Navigation Satellite System*, GNSS). Uma sentença NMEA, representa uma cadeia de caracteres no formato ASCII 8-bit e contendo 82 caracteres, no máximo.

Essas sentenças das mensagens se iniciam com \$. Os dois caracteres seguintes indicam o *talker* e os próximos três indicam o tipo da sentença. Os *talkers* mais utilizados são o GP, indicando o posicionamento global (GPS), e o GL, indicando o Sistema de Navegação Global via Satélite, em russo (GLONASS). Os outros campos são particionados por vírgula, seguidos de um asterisco e uma verificação por *checksum*, que é opcional na maioria das mensagens. A mensagem é concluída com *carriage return* (CR) e *line feed*.

Na Tabela 1, podemos observar a sentença dos Dados de correção do Sistema de Posicionamento Global (*Global Positioning System fix data*, GGA), responsável por armazenar informações de localização e precisão de posicionamento.

**\$GPGGA,123519,4807.038N,01131.000E,1,08,0.9,545.4M,46.9M,\*47**

Tabela 1 – Significado das sequências no NMEA ([FRANCISCO; MONICO, 2001](#))

| Sequência de caracteres | Descrição  |
|-------------------------|--|
| GGA                     | <i>Global Positioning System Fix Data</i>            |
| 123519                  | Latitude 48 ° 07.038' N                              |
| 4807.038,N              | Latitude 48 ° 07.038' N                              |
| 01131.000,E             | Longitude 11 ° 31.000' E                             |
| 1                       | Qualidade da Fix                                     |
| 08                      | Número de satélites visíveis                         |
| 0.9                     | Posição horizontal                                   |
| 545.4,M                 | Altitude, em metros, acima do nível do mar           |
| 46.9,M                  | Nível médio do mar                                   |
| (vazio)                 | Tempo em segundos desde a última atualização do DGPS |
| (vazio)                 | DGPS ID  |
| *47                     | Checksum*  |

Existem outros dois formatos de mensagem, o Mínimo de Informação de Navegação Recomendada (*Recommended Minimum Navigation Information*, RMC) responsável por enviar sentenças com informações mínimas de navegação e a Agência Européia do GNSS

(GSA), que transmite informações sobre o *status* do satélite.

### 2.1.5 Processamento de Dados do Sistema de Posicionamento Global (GPS)

A antena do receptor captura as ondas eletromagnéticas enviadas pelos satélites. Nessas antenas há três tipos de canais: **dedicados, sequenciais e multiplexados** (NASCIMENTO, 2018).

Os canais dedicados rastreiam os satélites visíveis, continuamente, já os sequenciais possuem a função de alternar entre o recebimento do sinal e o envio de mensagens de navegação em intervalos regulares, como não coincide normalmente com a transmissão de dados, as mensagens são recebidas totalmente apenas após várias sequências. Os canais multiplexados permitem que as sequências sejam efetuadas a uma velocidade muito alta entre os satélites, isso faz com que as mensagens sejam obtidas praticamente em tempo real, para que posteriormente, seja enviada ao microprocessador do dispositivo receptor. O microprocessador possui a função de obter e processar os sinais, decodificar essas mensagens de navegação e essas informações obtidas são enviadas ao *display* para o usuário (MACIEL et al., 2012).

Embora o GPS seja um sistema amplamente utilizado nos dias atuais, ainda apresenta alguns erros de medição, devido a fatores externos, observados na Figura 8.

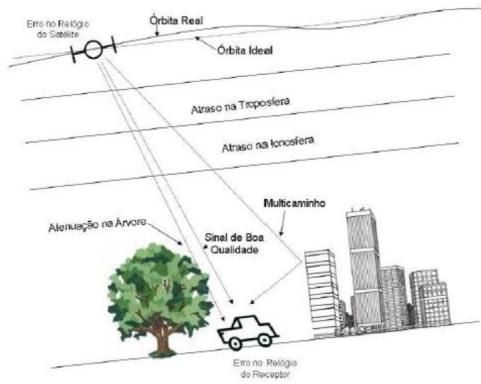


Figura 8 – Possíveis fontes de erros na captura de feita pelo GPS (FRANCA, 2009)

Podemos observar que inúmeros fatores podem interferir na medida precisa do posicionamento geográfico de um usuário. Por esse motivo, outras ferramentas são utilizadas de modo a atenuar essas possíveis interferências, por exemplo, o Sistema de Navegação Inercial (INS).

### 2.1.6 *Inertial Navigation System* (INS)

O *Inertial Navigation System*, ou Sistema de Navegação Inercial, é um processo responsável por obter a posição, velocidade e altitude de um determinado corpo com

base em um referencial (FRANCA, 2009). A diferença básica do INS com o GPS é que a primeira usa a metodologia de navegação que consiste em um método relativo, no qual se utiliza a posição, direção e distância percorridas em momentos anteriores para se calcular o posicionamento atual. Já a segunda é um método absoluto, no qual cálculo da posição é realizado a partir de um ponto de referência fixo, sem considerar o posicionamento passado (FILHO, 2005).

Um INS, comumente, possui três sensores translacionais e três rotacionais. Se as bases de sensibilidade dos instrumentos, utilizados no sistema de navegação inercial estiverem fixados à estrutura do veículo, é designado de plataforma *strapdown* (FRANCA, 2009).

Para que um sistema seja capaz de operar em três dimensões, é necessário que haja 3 sensores inerciais, de cada tipo, cada um operando em um eixo ( $x$ ,  $y$  e  $z$ ) (LI; WANG, 2012). Esses sensores são o **acelerômetro**, o **giroscópio** e o **magnetômetro**, que serão discutidos nas próximas seções. Quando esses sensores inerciais obtém-se montados sobre uma base rígida com um controle eletrônico dedicado obtém-se em uma estrutura chamada de IMU (*Inertial Measurement Unit*) (ZANONI, 2012).

### 2.1.7 *Inertial Measurement Unit (IMU)*

Os sensores IMU, *Inertial Measurement Unit*, ou Unidade de Medida Inercial são utilizados para se obter o posicionamento relativo de um dado corpo (AHMAD; GHAZILLA; KHAIRI, 2013), a partir das informações retornadas pelo acelerômetro, giroscópio e magnetômetro. Esses sensores também são chamados de sensores **MEMS** (*Sistemas microeletromecânicos*), compostos por micro-sensores, responsáveis por detectar as mudanças físicas do meio, podendo ser mecânicas, térmicas, magnéticas, químicas ou eletromagnéticas, convertendo-as em sinal elétrico. A microeletrônica processa essas informações e aciona os microatuadores de forma a criar uma resposta a esta mudança, convertendo em sinais elétricos, e posteriormente, gerando uma resposta ao usuário (COSTA, 2013).

#### **Acelerômetro**

Acelerômetros são sensores inerciais que calculam variações da velocidade e da posição a partir de sucessivas integrações matemáticas da aceleração em função do tempo. Os sensores IMU possuem três acelerômetros perpendiculares entre si, onde cada um é responsável por medir a aceleração de seu eixo (OLIVEIRA, 2012).

A estrutura de um acelerômetro, tanto o discreto quanto o Sistema Microeletromecânico (*Microelectromechanical System*, MEMS) possui o mesmo princípio, que é basicamente um sistema massa-mola e um amortecedor. A diferença é que nesse segundo a escala é reduzida. Sua estrutura pode ser observada na Figura 9.

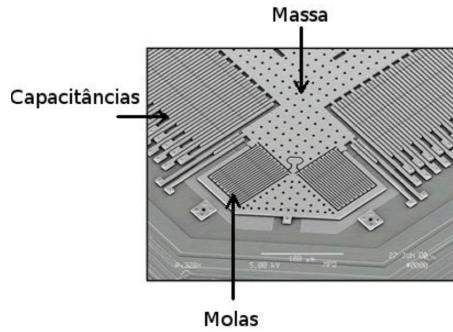


Figura 9 – Imagem microscópica de um acelerômetro MEMS ([CALACHE, 2013](#))

O funcionamento do acelerômetro se dá da seguinte forma: uma massa de prova é conectada a um referencial através de uma mola e um amortecedor. Devido à inércia o movimento da massa de prova não será o mesmo do que o da referência, desse modo é possível calcular a aceleração a partir dessa diferença entre as posições ([CALACHE, 2013](#)).

### Giroscópio

O giroscópio é capaz de medir a variação angular e é baseado no princípio da conservação do momento angular. Assim, ao ser rotacionado, a massa suspensa presente no sensor se move em uma determinada direção, resultando na variação da capacitância entre os eletrodos da massa suspensa e os fixos ([LI1; WANG, 2012](#)). A Figura 10 mostra uma esquematização do seu funcionamento.

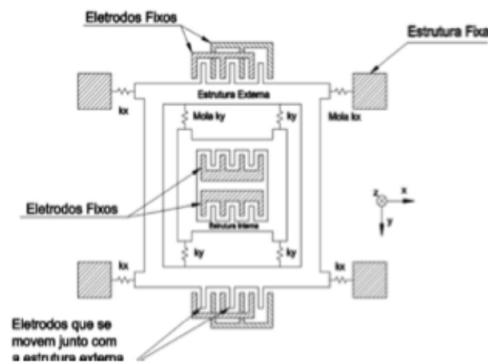


Figura 10 – Esquematização do funcionamento do giroscópio ([FARIA, 2018](#))

Podemos observar o comportamento físico dos componentes do giroscópio, e assim como no acelerômetro, há 3 desses sensores em cada eixo, que são perpendiculares entre si.

## Magnetômetro

O magnetômetro possui um sensor magnético de 3 eixos capazes de medir a intensidade, direção e sentido do campos magnéticos, e são amplamente utilizados para mensurar o campo magnético terrestre (GABRIEL, 2014). A partir do cálculo dessas coordenadas, é possível obter a orientação de um determinado corpo em relação ao norte magnético. A Figura 11 mostra o magnetômetro HMC5883L e as coordenadas utilizadas para essa obtenção.

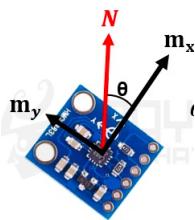


Figura 11 – Magnetômetro HMC5883L

Como mostrada na Figura 11, através das coordenadas  $m_x$  e  $m_y$  é possível localizar no norte magnético, podendo assim, auxiliar a obtenção do posicionamento geográfico do corpo.

O posicionamento geográfico pode ser obtido através da fusão dos dados retornados por esses sensores, através da chamada **fusão sensorial**.

### 2.1.8 Fusão Sensorial

A fusão sensorial consiste em um modelo matemático implementado com a ideia básica de se determinar um conjunto de propriedades frequentemente representadas por um vetor de estados. Esses estados e as informações obtidas pelos sensores são combinados de modo a produzir informações mais precisas. Uma das técnicas mais conhecidas são o Filtro Complementar e o **Filtro de Kalman** (HOSSEINYALAMDARY, 2018).

O filtro complementar consiste em uma técnica de obter as informações dos sensores, e integrar esses valores corrigidos, porém podem ocorrer falhas durante essa integração. Com o tempo, o filtro complementar tende a acumular esses erros, portanto para sistemas de navegação mais complexos, esse filtro não é indicado. Nessas aplicações, o *Filtro de Kalman* seria mais eficiente, pois se trata de um sistema recursivo, utilizando estados anteriores para gerar estimativas e corrigir os erros a cada ciclo. A abordagem dessa técnica será mais aprofundada no Capítulo 3.

Um dos principais erros que degeneram o sistema de navegação inercial é o **bias**, que é um nível de sinal constante que varia lentamente e independe do sinal de entrada,

mas esse nível pode-se alterar em algumas condições, como ao reiniciar o equipamento (GABRIEL, 2014).

Na fusão sensorial, para se obter uma estimativa do posicionamento de um veículo, por exemplo, é necessário auferir as medições em relação ao seus eixos ortogonais, melhores descritos na subseção 2.1.8.1.

#### 2.1.8.1 Definição de *roll*, *pitch* e *yaw*

Os veículos que são livres para operar em três dimensões, assim como aeronaves e submarinos, podem mudar sua atitude e rotação em torno dos três eixos ortogonais centralizados no centro de gravidade do veículo - os eixos longitudinal, vertical e horizontal. As definições para essas 3 medidas (OLIVEIRA; NUNES, 2017) (representadas na Figura 20), são:

- *Roll*: Rotação do corpo em relação ao eixo X.
- *Pitch*: Rotação do corpo em relação ao eixo Y.
- *Yaw*: Rotação do corpo em relação ao eixo Z.

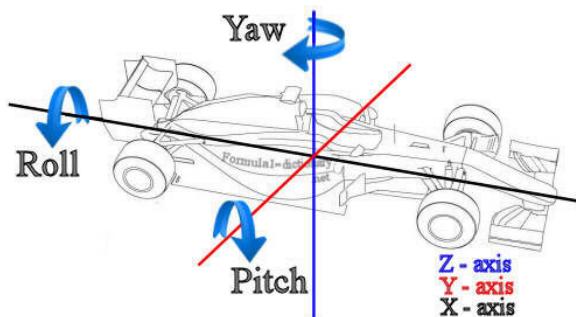


Figura 12 – Definição do *yaw*, *pitch* e *roll* (FARIA, 2018)

Essas três rotações são medidas em ângulos  $\phi$  (*roll*),  $\psi$  (*pitch*) e o  $\theta$  (*yaw*) como podem ser observados na Figura 13.

Para a determinação desses ângulos é utilizada a função *atan2* (MATHWORKS, 2011), chamada de "arco-tangente 4-quadrantes". A diferença com a função *atan*, é que este último permite calcular o arco tangente apenas de 2 quadrantes.

Esta função é utilizada para realizar a mudança de coordenadas, da cartesiana para a polar. Por exemplo, o número complexo  $Z = a + bj$  (SCILAB, 2017), o argumento deste pode ser calculado com o *atan2(y,x)*;

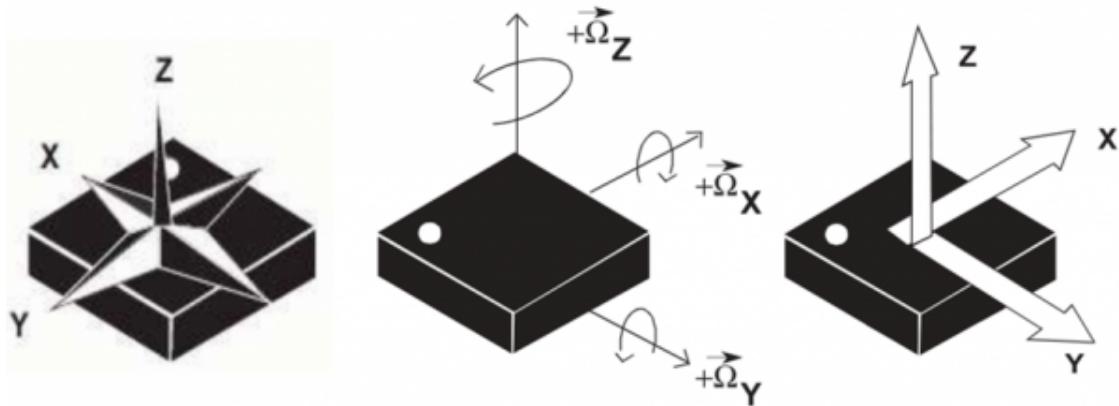


Figura 13 – Angulações *yaw*, *pitch* e *roll* (OLIVEIRA; NUNES, 2017)

### 2.1.9 Filtro Complementar

A fusão sensorial é uma técnica utilizada para a combinar faixas de precisão de diferentes sensores, com o intuito de diminuir a imprecisão do outro, e assim, obter os ângulos de atitude: *yaw* (guinada), *pitch* (arfagem) e *roll* (rolagem), do automóvel, da aeronave ou de um objeto, por exemplo. O giroscópio é responsável por mensurar comportamentos de alta frequência de forma precisa e o acelerômetro com a sua medição de erro estacionário nulo (OLIVEIRA; NUNES, 2017). A técnica utilizada para combinar essas duas medições é chamada de Filtro Complementar.

A idéia básica do Filtro Complementar é combinar as saídas do giroscópio e do acelerômetro a fim de se obter uma boa estimativa da orientação e, assim, compensar o desvio de taxa do giroscópio e a lenta dinâmica do acelerômetro e magnetômetro (YOO et al., 2011). No Filtro Complementar, o acelerômetro e o giroscópio são os sensores principais e o magnetômetro seria o de correção. Todas as forças sobre o sistema são medidos pelo acelerômetro, e como as pequenas forças acabam gerando medidas inexatas, a longo prazo, a medição é confiável, portanto é necessário um filtro passa-baixa para este sensor. Já no giroscópio, a integração numérica dos dados dos três eixos é feita durante um período de tempo em que o valor começa a desviar a longo prazo, por esse motivo é aplicado um filtro passa-alta para realizar essa correção (ISLAM et al., 2017). A Figura 14 esquematiza o funcionamento do Filtro Complementar.

Como descreveu (T.HIGGINS, 1975), se consideramos duas as variáveis x e y, que são as medidas ruídosas, sendo as entradas, respectivamente, do filtro passa-baixa e passa-alta. Assumindo que o ruído em y possui uma alta frequência e x, uma baixa frequência. Se a função de transferência  $H(s)$  representa o filtro passa-baixa, sendo  $[1 - H(s)]$  o seu

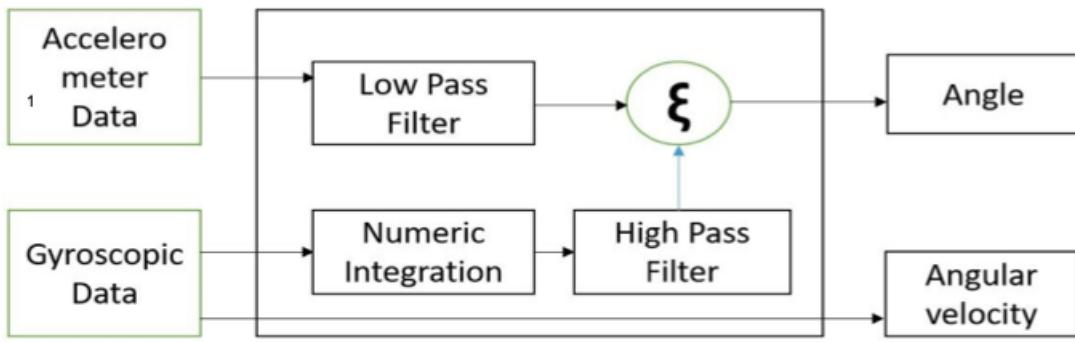


Figura 14 – Diagrama de blocos do Filtro Complementar (ISLAM et al., 2017)

complemento, no caso o filtro passa-alta. Considerando:

$$H_2(s) = 1 - H(s) \quad (2.1a)$$

$$H_2(s) = 1 - \frac{1}{\tau s + 1} \quad (2.1b)$$

$$\therefore H_2(s) = \frac{\tau}{\tau s + 1} \quad (2.1c)$$

A função de transferência do filtro passa-baixa é dada por  $H(s) = \frac{1}{\tau s + 1}$  e se o filtro passa-alta é complemento do filtro passa-baixa, então sua função transferência é  $[1-H(s)]$ .

Em termos de função transferência, onde a entrada são os dados obtidos pelo acelerômetro:

$$H_{resultante}(s) = \frac{\alpha}{1 + \tau s} + \left[ \frac{\tau s}{s(1 + \tau s)} + \frac{1}{s} \right] \times \beta \quad (2.2)$$

Onde  $\alpha$  é a entrada de dados do acelerômetro e  $\frac{\beta}{s}$  é o ângulo calculado obtido pelo giroscópio, após passar pelo integrador. Os valores comumente utilizados na literatura são  $\alpha = 2\%$  e  $\beta = 98\%$ .

Esses parâmetros são explicados pelo engenheiro eletrônico Peter Maele (MAELE, 2013). O filtro complementar é uma forma de se obter "o melhor dos dois mundos", como o giroscópio, a curto prazo, é muito preciso e não suscetível às forças externas, 98% do resultado do estimador é proveniente deste sensor, em contrapartida, a longo prazo, o desvio do acelerômetro tende à zero, dessa forma é utilizado os outros 2%.

Peter realizou o estudo utilizando o *Raspberry Pi* e uma IMU MPU6050 da seguinte forma: os dados do giroscópio são integrados a cada passo no tempo com o valor atual do ângulo, em seguida, é combinado com os dados passa-baixa do acelerômetro. Para isso, desenvolveu uma função de filtro complementar fosse executada em *loop* infinito e a cada iteração, os valores do ângulo de inclinação e rotação fossem atualizados com os novos valores do giroscópio por meio da integração ao longo do tempo. O filtro então verifica se

a magnitude da força vista pelo acelerômetro tem um valor consistente, caso o valor for muito pequeno ou muito grande, o distúrbio não é levado em consideração. Posteriormente, são atualizados os ângulos de inclinação e rotação com os dados do acelerômetro, obtendo 98% do valor atual e adicionando 2% do ângulo calculado pelo giroscópio, garantindo que a medida não seja desviada, ou seja, precisa no curto prazo. A equação que representa a execução dessa função é dada por:

$$\theta = 0.98 \times \theta + gyrData \times dt + 0.02 \times accData \quad (2.3)$$

sendo,

- $\theta$ , o ângulo de guinada.
- gyroData, o dado do giroscópio.
- accData, o dado do acelerômetro.

### 2.1.10 Filtro de Kalman

O Filtro de Kalman foi lançada por Rudolf Emil Kalman, em 1960, com a publicação de seu artigo descrevendo uma solução recursiva para o problema de filtragem linear de dados discretos. A partir disso, graças aos avanços da computação digital, o Filtro de Kalman tem sido uma tema de extensa aplicação e pesquisa, principalmente na área de navegação autônoma ou assistida ([WELCH; BISHOP, 1995](#)).

O Filtro de Kalman é um estimador que propaga um estado caracterizado por uma distribuição gaussiana usando funções de transição linear de maneira ideal ([MONTELLA, 2011](#)), tendo como entrada as medidas corrompidas por ruídos pelo seu presente sistema. Desde que algumas condições sejam satisfeitas, o Filtro de Kalman se comporta como um estimador ótimo que minimiza a covariância do erro de estimativa do vetor de estados ([CABRAL, 2017](#)).

Um dos maiores problemas obtidos na navegação é obter a acurácia dos dados capturados pelos GPS, sensores e sistemas, de forma a predizer o posicionamento com o menor erro possível. A partir dessa abordagem, são realizadas inúmeras pesquisas e desenvolvimento de projetos a fim de se obter estimativas mais próximas dos dados reais possíveis. Uma das técnicas amplamente utilizadas é a fusão sensorial utilizando o filtro de Kalman, como no estudo e desenvolvimento realizado por ([CABRAL, 2017](#)), que realiza a fusão de dados do Sistema de Localização Acústico (SILA), que é um sistema composto por módulos emissores de ultrassons fixos nas paredes do ambiente e um módulo acoplado no robô; e os dados da Unidade de Medição Inercial (IMU).

Neste projeto é proposto a utilização do Filtro de Kalman para a fusão sensorial de dados obtidos pela IMU e ao invés do SILA, o posicionamento a ser obtido por um módulo de posicionamento global (GPS), de forma a obter-se estimativas mais próximas possíveis do posicionamento real do veículo.

O Filtro de Kalman estima dados de um processo utilizando como forma o controle por *feedback*. O filtro estima o estado do processo em algum momento e, em seguida, obtém a resposta na forma de medições ruidosas. Assim, o algoritmo de Filtro de Kalman se divide em duas partes: a fase de **propagação** e a de **atualização** de medição. A primeira é responsável por projetar adiante (no tempo) as estimativas de covariância do estado atual e de erro para obtenção das estimativas a priori para a iteração seguinte. As equações de atualização das medidas são responsáveis pelo *feedback*, ou seja, para incorporar uma nova medida na estimativa a priori para obter uma estimativa a posteriori mais precisa (WELCH; BISHOP, 1995).

Considerando um sistema de navegação embarcado em um veículo terrestre, com o seguinte vetor  $X^R$  de estados reais do sistema, com dados de posição, velocidade e ângulo de guinada.

$$X^R(t) = \begin{bmatrix} v_x(t) \\ v_y(t) \\ p_x(t) \\ p_y(t) \\ \psi(t) \end{bmatrix} \quad (2.4)$$

sendo,

- $v_x(t)$  e  $v_y(t)$  representam as velocidades reais do veículo, respectivamente, no eixo x e y do sistema inercial.
- $p_x(t)$  e  $p_y(t)$  representam os posicionamentos reais do veículo, respectivamente, no eixo x e y do sistema inercial.
- $\psi(t)$  representa o ângulo de guinada do veículo.

Para essa abordagem, foram considerados dois sistemas de coordenadas: o sistema inercial, fixo (referente ao ambiente) e o sistema que representa o corpo, que é em relação ao centro de massa do veículo, deslocando com o movimento do corpo (CABRAL, 2017).

Expressando a aceleração, inicialmente no sistema corpo, para o sistema inercial, temos a Equação 2.5.

$$\begin{bmatrix} a_x(t) \\ a_y(t) \end{bmatrix} = \begin{bmatrix} \cos(\psi(t)) & -\sin(\psi(t)) \\ \sin(\psi(t)) & \cos(\psi(t)) \end{bmatrix} \begin{bmatrix} a_{xc}(t) \\ a_{yc}(t) \end{bmatrix} \quad (2.5)$$

$$\begin{bmatrix} a_x(t) \\ a_y(t) \end{bmatrix} = \begin{bmatrix} \cos(\psi(t))a_{xc}(t) - \sin(\psi(t))a_{yc}(t) \\ \sin(\psi(t))a_{xc}(t) + \cos(\psi(t))a_{yc}(t) \end{bmatrix} \quad (2.6)$$

- $a_x(t)$  e  $a_y(t)$  representam as acelerações reais do veículo, respectivamente, nos eixos x e y do sistema de coordenadas inercial.
- $a_{xc}(t)$  e  $a_{yc}(t)$  representam as acelerações reais do veículo, respectivamente, nos eixos x e y do sistema de coordenadas do corpo.

Derivando o vetor de estados reais  $X^R$  expresso anteriormente em ?? e substituindo os valores obtidos pela equação 2.6 temos que,

$$\dot{X}^R = \begin{bmatrix} \dot{v}_x(t) \\ \dot{v}_y(t) \\ \dot{p}_x(t) \\ \dot{p}_y(t) \\ \dot{\psi}(t) \end{bmatrix} = \begin{bmatrix} \cos(\psi(t))a_{xc}(t) - \sin(\psi(t))a_{yc}(t) \\ \sin(\psi(t))a_{xc}(t) + \cos(\psi(t))a_{yc}(t) \\ v_x(t) \\ v_y(t) \\ w_{zc}(t) \end{bmatrix} \quad (2.7)$$

onde  $w_{zc}(t)$  é a velocidade angular ao redor do eixo Z.

Considerando os vetores que representam a entrada e a saída reais do sistemas são representados, respectivamente, por  $U^R$  e  $Y^R$  (CABRAL, 2017).

$$U^R(t) = \begin{bmatrix} a_{xc}(t) \\ a_{yc}(t) \\ w_{zc}(t) \end{bmatrix} \quad (2.8)$$

$$Y^R(t) = \begin{bmatrix} 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \end{bmatrix} \times X^R(t) \quad (2.9)$$

$$Y^R(t) = \begin{bmatrix} p_x(t) \\ p_y(t) \\ \psi(t) \end{bmatrix} \quad (2.10)$$

Logo, podemos representar a entrada obtida no sistema inercial (INS), proveniente das medições do acelerômetro e giroscópio, como  $U^{INS}(t)$ .

$$U^{INS}(t) = \begin{bmatrix} a_{xc}^{INS}(t) \\ a_{yc}^{INS}(t) \\ w_{zc}^{INS}(t) \end{bmatrix} \quad (2.11)$$

Relacionando essa entrada com valores reais temos que,

$$a_{xc}^{INS}(t) = a_{xc} + bias_{ax}(t) + r_{ax}^{INS}(t) \quad (2.12a)$$

$$a_{yc}^{INS}(t) = a_{yc} + bias_{ay}(t) + r_{ay}^{INS}(t) \quad (2.12b)$$

$$w_{zc}^{INS} = w_{zc} + bias_{wz}(t) + r_{wz}^{INS}(t) \quad (2.12c)$$

sendo,

- $bias_{ax}(t)$  e  $bias_{ay}(t)$  são os *bias* provenientes do acelerômetro, respectivamente nos eixos x e y; e  $bias_{wz}(t)$ , do giroscópio no eixo Z da IMU. Organizando os *bias* em um vetor denominado  $Bias(t)$ , obtemos a configuração mostrada em 2.13.

$$Bias(t) = \begin{bmatrix} bias_{ax}(t) \\ bias_{ay}(t) \\ bias_{wz}(t) \end{bmatrix} \quad (2.13)$$

- $r_{ax}^{INS}$ ,  $r_{ay}^{INS}(t)$  e  $r_{wz}^{INS}(t)$  são ruídos, com distribuição gaussiana de média zero e variância  $\sigma_{accx}^2$ ,  $\sigma_{accy}^2$ ,  $\sigma_{gyrz}^2$ , respectivamente, independentes entre si. Organizando esses ruídos em um vetor denominado  $Ruidos^{INS}$ , obtemos a configuração mostrada em 2.14.

$$Ruidos^{INS}(t) = \begin{bmatrix} r_{ax}^{INS}(t) \\ r_{ay}^{INS}(t) \\ r_{wz}^{INS}(t) \end{bmatrix} \quad (2.14)$$

A partir das equações obtidas em 2.13 e 2.14 é possível definir um modelo de erro para o estado, a entrada e saída, representados, respectivamente, por  $X^E(t)$ ,  $U^E(t)$  e  $Y^E(t)$ :

$$X^E(t) = \begin{bmatrix} X^{INS}(t) - X^R \\ Bias(t) \end{bmatrix} \quad (2.15)$$

$$U^E(t) = U^{INS}(t) - U^R(t) \quad (2.16)$$

$$Y^E(t) = Y^{INS}(t) - Y^{Bussola}(t)^* \quad (2.17)$$

\*  $Y^{Bussola}(t)$  representa as medições realizadas pela bússola digital também presente na IMU.

Similarmente às representações para a IMU, nas equações 2.12, podemos descrever as medições do GPS como:

$$p_x^{GPS}(t) = p_x(t) + r_x^{GPS}(t) \quad (2.18a)$$

$$p_y^{GPS}(t) = p_y(t) + r_y^{GPS}(t) \quad (2.18b)$$

$$\psi^{Bussola} = \psi(t) + r_\psi^{Bussola}(t) \quad (2.18c)$$

- $p_x(t)$ ,  $p_y(t)$  e  $\psi^{Bussola}$ , são, respectivamente, a posição real do veículo na coordenada X do sistema inercial, na coordenada Y do sistema inercial e o ângulo de guinada real do veículo.
- $r_x^{GPS}(t)$ ,  $r_y^{GPS}(t)$  e  $r_\psi^{Bussola}(t)$  são ruídos, com distribuição gaussiana de média zero e variância  $\sigma_{GPSx}^2$ ,  $\sigma_{GPSy}^2$ ,  $\sigma_{Bussola}^2$ , respectivamente. Construindo o vetor de ruídos do GPS, temos:

$$Ruidos^{GPS}(t) = \begin{bmatrix} r_x^{GPS}(t) \\ r_y^{GPS}(t) \\ r_\psi^{Bussola}(t) \end{bmatrix} \quad (2.19)$$

Assumindo que para qualquer instante  $t$ :

- $\frac{dBias(t)}{dt} = 0_{3 \times 1}$ , ou seja,  $bias$  constante.
- $\psi^{INS} \approx \psi^R(t)$ , o ângulo de guinada obtido pela IMU possui um erro pequeno.

Com as equações essenciais do Filtro de Kalman construídas, a fusão sensorial poderá ser inicializada. No tempo  $t = 0$ , temos que as seguintes considerações:

- O estado inicial do vetor de estados construído com os dados da IMU é dado por:

$$X_0^{INS}(t) = \begin{bmatrix} v_x^{INS}(0) \\ v_y^{INS}(0) \\ p_x^{INS}(0) \\ p_y^{INS}(0) \\ \psi^{INS}(0) \end{bmatrix} \quad (2.20)$$

- A estimativa do  $bias$  com as medições no sistema inercial é representada por  $\hat{Bias}_0$ :

$$\hat{Bias}_0(t) = \begin{bmatrix} \hat{bias}_{ax}(0) \\ \hat{bias}_{ay}(0) \\ \hat{bias}_{wz}(0) \end{bmatrix} \quad (2.21)$$

- A matriz de covariância dos ruídos independentes de estados, obtidos através da IMU é dada por:

$$Q = \begin{bmatrix} \sigma_{accx}^2 & 0 & 0 \\ 0 & \sigma_{accy}^2 & 0 \\ 0 & 0 & \sigma_{gyrz}^2 \end{bmatrix} \quad (2.22)$$

- A matriz de covariância dos ruídos de medida, obtidos através do GPS é dada por:

$$R = \begin{bmatrix} \sigma_{GPSx}^2 & 0 & 0 \\ 0 & \sigma_{GPSy}^2 & 0 \\ 0 & 0 & \sigma_{Bussola}^2 \end{bmatrix} \quad (2.23)$$

Como citado inicialmente, o filtro de Kalman possui duas fases: **Atualização** e **Propagação**, como representados por (ZANONI, 2012) com o esquema da Figura 15.

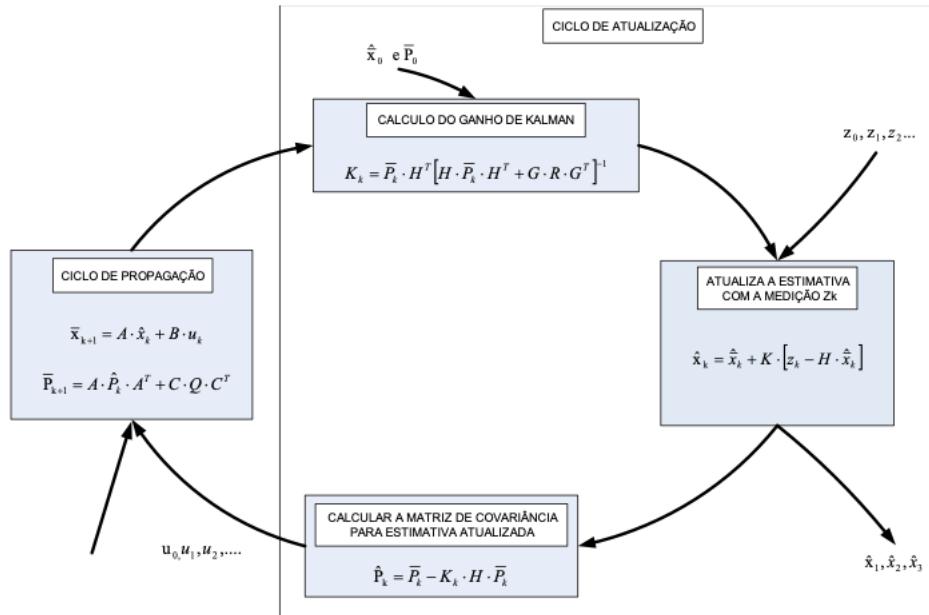


Figura 15 – Esquema do algoritmo do filtro de Kalman (ZANONI, 2012)

O primeiro passo do algoritmo é o ciclo de atualização, onde é calculado o ganho de Kalman ( $K$ ), a média e a covariância, respectivamente. Após a atualização, é executado a propagação, que calcula a média e a covariância, de modo a se obter uma estimativa posterior. Após cada ciclo de atualização e propagação, esse processo é repetido e, através da estimativa posterior, é predito uma nova estimativa a priori. Nas próximas seções será explicado o funcionamento desses dois ciclos da fusão sensorial.

Para a interpretação dos ciclos, são consideradas as seguintes anotações:

- $\text{diag}[d_1 d_2 \dots d_n]$  representa os elementos da diagonal principal da matriz  $d$  e os demais elementos da matriz são iguais a 0.
- $\hat{d}$  representa a estimativa do dado  $d$ .
- $d^-$ , o sinal (-) acima da variável representa que este é obtido pelo ciclo de propagação do filtro de Kalman.
- $d^+$ , o sinal (+) acima da variável representa que este é obtido pelo ciclo de atualização do filtro de Kalman.
- $d_k$  representa  $d(t)$  no instante  $t = kT$ ;
- $d_k [N : M]$  representa um vetor coluna  $[a_k[N], \dots, d_k[N]]^T$ , com as linhas de N a M do vetor de dados reais,  $d_k$ .

#### 2.1.10.1 Atualização

(ZANONI, 2012) descreve as equações de atualização como responsáveis pela alimentação. Dessa forma, incorporam uma nova medição ao estado estimado a priori para obter uma estimava melhorada a posteriori.

Como descrito por (CABRAL, 2017), sempre que há medidas de posicionamento do GPS,  $p_{x,k}^{GPS}$  e  $p_{y,k}^{GPS}$  e da bússola digital  $\psi^{Bussola}$ , são realizados os seguintes passos, sequencialmente.

1. Cálculo do vetor de erro de saída da medição,  $Y_k^E$ .

$$Y_k^E = \hat{X}_k^{IMU-}[3 : 5] - \begin{bmatrix} p_{x,k}^{GPS} \\ p_{y,k}^{GPS} \\ \psi^{Bussola} \end{bmatrix} \quad (2.24)$$

2. Atualização do vetor de ganho (K), onde  $H$  é o modelo de observação, que é a matriz responsável pelo mapeamento do espaço de estados reais para o de estados observados, e  $H^T$ , sua matriz transposta:

$$H = \begin{bmatrix} 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \end{bmatrix} \quad (2.25)$$

$$K_k = P_k^- H^T [H P_k^- H^T + R]^{-1} \quad (2.26)$$

3. Atualização da matriz de covariância (P):

$$P_k^+ = [I_{8 \times 8} - K_k H] P_k^- \quad (2.27)$$

4. Obtenção dos estados do modelo de erro:

$$\hat{X}_k^E = \begin{bmatrix} 0_{5 \times 1} \\ \hat{Bias}_k^- \end{bmatrix} + K_k Y_k^E \quad (2.28)$$

5. Atualização do vetor de estados estimados do veículo, a partir dos dados da IMU:  
 $\hat{P}_x, \hat{P}_y, \hat{\psi}$

$$X_k^{IMU+} = X_k^{IMU-} - \hat{X}_k^E[1 : 5] \quad (2.29)$$

6. Atualização do vetor Bias, obtido pela IMU:

$$\hat{Bias}_k^+ = \hat{X}_k^E[6 : 8] \quad (2.30)$$

### 2.1.10.2 Propagação

Já as equações de propagação são definidas por (ZANONI, 2012) como a forma de propagar para frente o estado corrente e realizar a predição da covariância do erro de modo a obter uma estimativa para o próximo estado de tempo. Para descrever esta fase, (CABRAL, 2017) utiliza os seguintes passos, sequencialmente:

1. Obter as medições no sistema inercial e utilizá-las como a entrada  $U_k^{INS}$ .

$$U_k^{INS} = \begin{bmatrix} a_{xc,k}^{INS} \\ a_{yc,k}^{INS} \\ w_{zc,k}^{INS} \end{bmatrix} - \hat{Bias}_k^- \quad (2.31)$$

2. Calcular o vetor de estados de  $k + 1$ , a partir de  $k$ , através da integração numérica, a partir da equação 2.7.  $f$  é a função que relaciona a matriz de estados estimados com a entrada do Filtro de Kalman.

$$\dot{\hat{X}}^{INS}(t) = f(\hat{X}^{INS}(t), U^{INS}(t)) \quad (2.32)$$

3. Considerar que o vetor de *bias* estimado no instante  $k+1$  é igual ao estimado no instante  $k$ , ou seja:

$$\hat{Bias}_{k+1}^- = \hat{Bias}_k^- \quad (2.33)$$

4. Ao final, calcular a matriz de covariância no instante  $k + 1$ .

$$P_{k+1}^- = A_d^E P_k^+ [A_d^E]^T + B_d^E Q_k [B_d^E]^T + \beta P_0^- \quad (2.34)$$

$A^E(t)$  e  $B^E(t)$  são matrizes que relacionam os estados e as entradas do modelo de erros e  $A_d^E(kT)$  e  $B_d^E(kT)$  são suas matrizes discretizadas, respectivamente. O

coeficiente  $\beta$  é um escalar que evita divergências no filtro de Kalman ao impedir que a matriz de covariância  $P_k$  fique com um valor muito reduzido

O exemplo desenvolvido por (SIMON, 2001) traz uma boa ilustração do funcionamento do Filtro de Kalman, veja no Apêndice A.

## 2.2 Trabalhos Relacionados

Para a inicialização do projeto e a contextualização sobre sistemas de navegação, foram realizadas revisões bibliográficas de trabalhos relacionados aos sensores inerciais, ao GPS e a fusão sensorial com filtro de *Kalman*.

(CABRAL, 2017) desenvolveu um projeto de um Sistema de Navegação para estimativa de posição e orientação em ambientes internos. Esse sistema realiza a estimativa em tempo real da posição e orientação de um robô móvel, utilizando sensores ultrassônicos para a medição das distâncias. O sistema de navegação desenvolvido foi composto por um Sistema de Localização Acústico (SILA), Unidade de Medição Inercial (IMU) e o algoritmo de fusão sensorial por Filtro de Kalman. Após o desenvolvimento da estação de captação de dados de posicionamento, foram realizados dois tipos de testes: o controle da posição de um quadrirroto e a navegação autônoma do robô de solo de quatro rodas, que foi realizado usando a posição e a orientação estimadas pelo Sistema de Navegação proposto, onde robô percorreu os pontos de um percurso predefinido na área de teste e, nesse teste, o erro entre a posição real e a estimada foi de poucos centímetros. Além do desenvolvimento do projeto, o autor também realiza um estudo comparativo das tecnologias para a construção de sistema de localização em ambientes internos, efetuando análises de custos, metodologias e eficiência de ferramentas.

O estudo e a implementação do filtro de *Kalman* estendido foram realizados por (ZANONI, 2012), aplicando-o em um sistema de navegação para veículos submarinos autônomos, onde a captura de dados foi realizada por sensores IMUs, bússolas magnéticas, profundímetros, velocímetros *Doppler* e sistemas acústicos de posicionamento (esses componentes foram utilizados devido a impossibilidade do uso eficiente do GPS em regiões submarinas mais profundas), mas essa fusão sensorial ocorre de maneira similar às aplicações em veículos terrestres. Os testes realizados mostram resultados positivos em relação à eliminação de **bias** e outros ruídos decorrentes das medições dos sensores inerciais, podendo assim, obter um posicionamento geográfico com uma precisão considerável. Uma das maneiras de implementação, adotada por (OLIVEIRA; NUNES, 2017), do filtro de *Kalman* discreto, foi em linguagem C através do IDE da plataforma *Open Source Arduino* programada em um microcontrolador *Atmel*. Foi utilizada a comunicação I2C para a transferência de dados capturados pelos sensores para o *arduino*. Os sinais foram analisados no *MatLab*, para detectar os ruídos e outras imprecisões, realizando uma

comparação de um sistema de navegação sem e com a fusão sensorial, podendo observar uma grande eficiência do algoritmo utilizado.

(COSTA, 2013), em seus estudos sobre o desenvolvimento de veículos autônomos, utilizou a fusão sensorial também realizada pelo filtro de *Kalman*, porém, para aplicações em veículos terrestres. Comparando as configurações modeladas (COSTA, 2013), chegou a conclusão de que o GPS em modo diferencial é o principal sensor responsável pela localização de um veículo autônomo, mas que sozinho não é capaz de retornar o posicionamento preciso devido às perdas de sinais. Neste trabalho foram utilizados apenas o acelerômetro e o giroscópio, porque o magnetômetro, segundo o autor, sofre grande interferência do campo magnético presente no veículo, tornando-se não confiável.

Nas análises realizadas em (SANTANA, 2011), não foi aplicado o GPS para se obter o posicionamento, foram utilizadas *landmarks* (marcas topográficas), como pontos de referência para o usuário e a fusão sensorial, pelo mesmo método adotado pelos autores anteriores, com o objetivo de obter um posicionamento com o mínimo de erros. Essas marcações em solo foram implantadas ao longo da trajetória de teste, para a medição do erro da estimativa de posicionamento nesses pontos. A conclusão após os testes realizados é que utilizando os mesmos sensores iniciais, esta fusão gerou resultados muito convenientes, possibilitando a reconstrução de trajetórias com deslocamentos de cerca de 2,7 km, embora com erro final de estimativa de posição de aproximadamente 3 m.

A busca por ferramentas que retornem um posicionamento preciso é realizada por empresas de diversos segmentos do mercado, como na área agrícola. Em (OLIVEIRA, 2012) são descritos os testes executados pela empresa Arvus Tecnologia, em seus estudos para o desenvolvimento de um piloto automático para máquinas agrícolas, que conta com um sistema eficiente e com menor custo de implantação, pois a qualidade do GPS é proporcional ao seu custo. Desta forma foram utilizados também a fusão sensorial pelo filtro de *Kalman*, realizando a implementação do GPS/INS no sistema embarcado da Placa do Piloto Automático. Os resultados mostraram que financeiramente é muito atraente, já que usando um sistema de baixo custo serão alcançadas respostas semelhantes aos sistemas de GPS mais com custos mais elevados. Dessa forma, essa pesquisa abre expectativa para máquinas que operem de forma autônoma e com baixo custo de aquisição pelos consumidores finais.

(POOLE, 2017) realizou melhorias desenvolvidas para o sistema de localização do veículo Autônomo SAE (*Society of Automotive Engineers*) na Universidade de Western Australia. As principais melhorias aplicadas ao sistema de localização foram a adição de odometria ao sistema de controle de baixo nível, bem como a implementação do Filtro de Kalman estendido e alterações no *software* de baixo nível e nos algoritmos de fusão sensorial. A detecção de odometria no veículo SAE foi adicionada usando um microcontrolador e sensores de efeito Hall. Este microcontrolador se comunica com o microcontrolador

responsável pela direção, frenagem e aceleração do veículo, para fornecer medições de velocidade da roda ao microcontrolador principal no sistema de processamento principal. O algoritmo de fusão do sensor tentou comparar e contrastar pelo menos três casos; fusão de sensores com odometria com Filtro de Kalman, fusão de sensores com odometria usando um Filtro de Kalman e fusão de sensores com odometria e um EKF. Ao final, foi obtido um sensor de medição de odometria confiável, que fornece velocidade para cada uma das quatro rodas.

No estudo realizado por (ALATISE; HANCKE, Setembro, 2017), foi realizada a fusão de um sensor inercial de seis graus de liberdade (6-DoF), que compreende os 3 eixos de um acelerômetro e os 3 eixos de um giroscópio, e o desenvolvimento de um robô móvel autônomo, que determina uma posição precisa e de baixo custo, onde foi aplicado um algoritmo de visão monocular para detecção de objetos, baseados no *Speeded-Pp Robust Feature* (SURF) e no *Random Sample Consensus* (RANSAC), nos quais foram integrados e usados para reconhecer um objeto de amostra em várias imagens capturadas. Ao contrário do método convencional que depende do rastreamento de pontos, o RANSAC usa um método iterativo para estimar os parâmetros de um modelo matemático a partir de um conjunto de dados capturados que contém discrepâncias. Essa solução proposta mostrou possuir implementação simples, de baixo custo e grande precisão. Com um Filtro de Kalman estendido, os dados dos sensores iniciais e uma câmera foram fundidos para estimar a posição e a orientação do robô móvel. Todos esses sensores foram montados no robô móvel a fim obter uma localização precisa, ao final, foi realizado um teste para validar e avaliar o desempenho, que mostraram que o método proposto é rápido em computação, confiável e robusto, e pode ser considerado para aplicações práticas. Este desempenho foi verificado pelos dados reais do solo e dos *Root-Mean-Square Deviation* (RMSEs).

(LIU et al., Novembro, 2019) realizaram um estudo da fusão e filtragem de dados entre banda ultralarga (*Ultra Wide Band*, UWB) e Unidade de Medida Inercial (*Inertial Measurement Unit*, IMU). O posicionamento de alta precisão de UWB em ambiente sem linha de visão (*non-line-of-sight*, NLOS) é um dos maiores problemas de estimativa da direção do posicionamento interno, para isso foi desenvolvido um método que utiliza o Filtro de Kalman complementar para fundir e filtrar dados do UWB e da IMU, a fim de se obter os erros de variáveis como posição, velocidade e direção. Com base na incerteza do magnetômetro e da aceleração, a matriz de covariância do ruído do magnetômetro e do acelerômetro é calculada dinamicamente e, em seguida, o peso dos dados do magnetômetro é definido de forma adaptativa para corrigir o erro direcional do giroscópio. Com base na incerteza das observações à distância UWB, a matriz de covariância do ruído de medição UWB foi calculada dinamicamente e, em seguida, o peso das observações dos dados UWB foi definido de forma adaptativa para corrigir o erro de posição. Os erros de posição, velocidade e direção são corrigidos pela fusão de UWB e IMU. Os resultados empíricos mostraram que o algoritmo pode reduzir o desvio do giroscópio com ruído magnético e

ruído de movimento, para que as estimativas de orientação possam ser melhoradas.

# 3 Materiais e Métodos

Neste capítulo serão abordados os componentes eletrônicos para a construção do sistema de navegação proposto; e também as metodologias, conceitos e ferramentas utilizadas para a técnica de fusão sensorial com o objetivo de se obter um sistema de navegação eficiente e de baixo custo de implementação.

## 3.1 Recursos Utilizados

Para o desenvolvimento e a implementação do projeto foram utilizados os componentes eletrônicos descritos na Subseção 3.1.1, para a construção do sistema de aquisição de dados referentes ao posicionamento geográfico, utilizando os Filtros Complementar e de Kalman.

### 3.1.1 Materiais

Os componentes eletrônicos utilizados para a implementação estão descritos na Tabela 3.1.1.

Tabela 2 – Materiais a serem utilizados no projeto

| Material  | Nome  | Descrição   |
|---|---|---|
|  | <i>Arduino<br/>Mega 2560</i>                            | Placa baseada no microcontrolador ATmega2560, com portas de entrada/saída digitais, portas analógicas, UARTs ( <i>Universal Asynchronous Receiver/Transmitter</i> ) e ICSP ( <i>In Circuit Serial Programming</i> ).  |
|  | <i>SparkFun<br/>9DoF IMU<br/>Breakout -<br/>LSM9DS1</i> | Sensor de movimento, que contém um acelerômetro, giroscópio e magnetômetro, cada um com 3 eixos, ou seja, possui nove graus de liberdade (9DOF) em um único circuito integrado. O LSM9DS1 está equipado com uma interface digital flexível, suportando comunicação I2C e SPI. |
|  | GPS<br>NEO-6M<br>com<br>Antena                          | Permite captar dados de localização do objeto em que o Módulo está instalado, enviando informações como: a latitude e longitude, data, hora e velocidade de deslocamento.   |

### 3.1.1.1 Especificações dos módulos de captação de dados.

1. **GPS NEO-6M:** O módulo possui o Ublox GPS NEO-6M, módulo pertencente a uma família de GPS autônomos. Em ([UBLOX, 2018](#)) é apresentado o *Datasheet* do módulo.

- Tensão de alimentação: 3V - 5V
- Modelo: GY-GPS6MV2
- Antena ativa de cerâmica
- Com a bateria para backup de dados
- LED indicador de sinal
- Tamanho da antena: 25x25mm
- Tamanho do módulo: 25x36mm
- Furo de Montagem: 3mm
- Taxa de transmissão: 9.600bps
- Interface: RS232 TTL 3,3V
- Compatível com vários módulos de controladores de vôo
- EEPROM salva os dados de parâmetro de configuração quando desligado

2. **IMU LSM9DS1:** Sensor que contém um acelerômetro, um giroscópio e um magnetômetro, cada um com três eixos, ou seja, nove graus de liberdade (9DOF) em um único circuito integrado, sendo um dos poucos CIs capazes de medir propriedades como a velocidade angular, a aceleração e o *heading* ([SPARKFUN, 2016](#)). Possui as seguintes especificações:

- Tensão de alimentação: 2.4V - 3.6V
- Interface I2C (*Inter-Integrated Circuit*) ou SPI (*Serial Peripheral Interface*)
- 1 acelerômetro com eixos x, y e z
- 1 giroscópio com eixos x, y e z
- 1 magnetômetro com eixos x, y e z

A Figura 13, mostrada anteriormente, ilustra as rotações ( $\Omega$ ) em relação ao eixo de coordenadas x, y e z da IMU LSM9DS1.

## 3.2 Métodos

Os métodos utilizados para o desenvolvimento do sistema de determinação de altitude e de estimativa de localização são: o Filtro Complementar usado para se obter as medições de *pitch*, *roll* e *yaw* com o auxílio do giroscópio e acelerômetro; a bússola a partir do magnetômetro; e o Filtro de Kalman usado para estimar a posição X e Y através dos dados do GPS e da saída do Filtro Complementar (medidas de *pitch*, *roll* e *yaw* calculadas).

### 3.2.1 Filtro Complementar

O Filtro Complementar foi proposto por Shane Colton em 2007, para determinação da altitude. Primeiramente, o filtro realiza a filtragem passa-baixa na medição de sinais de baixa frequência usando os dados acelerômetro enquanto a filtragem passa-alta na medição de sinais de alta frequência aplicado diretamente na saída do giroscópio. A fusão das duas estimativas fornece os ângulos de inclinação de um corpo (*Tilt Angle*), *pitch*, *roll* e *yaw* que são respectivamente, as inclinações nos eixos longitudinal, transversal e lateral. No curto prazo, utiliza os dados do giroscópio cujos dados são precisos e não suscetíveis a forças externas; no longo prazo, ele depende dos dados do acelerômetro para evitar o desvio nas medidas de altitude. ([VASCONCELOS STUDENT MEMBER; BATISTA STUDENT MEMBER, 2011](#)). A Figura 16 mostra a esquematização do Filtro Complementar.

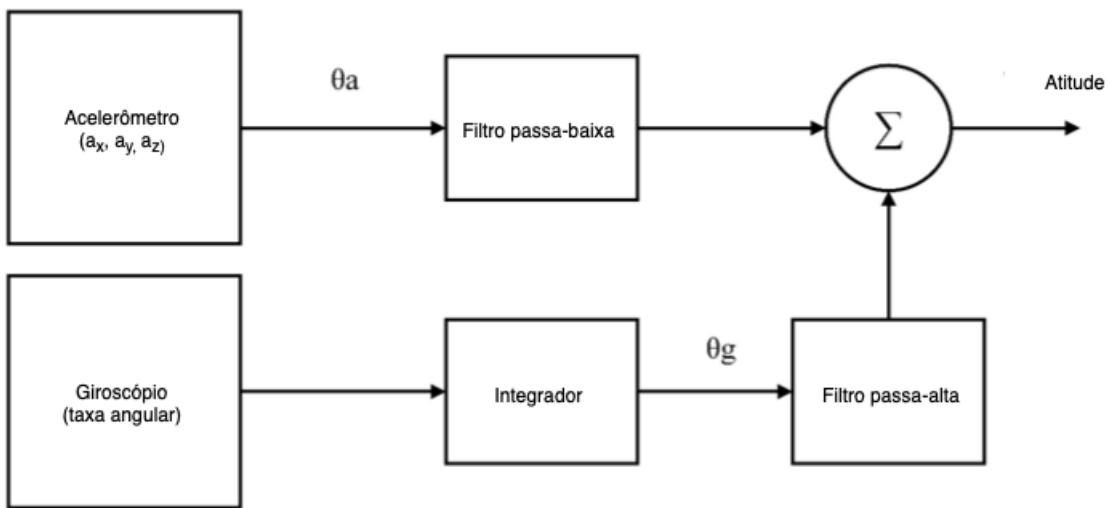


Figura 16 – Esquematização do funcionamento do Filtro de Complementar ([YOO et al., 2011](#))

As variáveis  $\theta_a$  e  $\theta_b$ , são, respectivamente, as velocidades angulares obtidas pelo acelerômetro (após a conversão da aceleração obtida pelo sensor para velocidade angular, tendo como base, o centro gravitacional da Terra); e pelo giroscópio.

Para a obtenção dos dados de *yaw* (ângulo de guinada), é utilizado, em paralelo ao Filtro Complementar, um terceiro sensor (também integrado ao módulo IMU), que é o magnetômetro, que possui a funcionalidade de uma bússola, detectanto o posicionamento do corpo em relação ao norte magnético da Terra (LI1; WANG, 2012).

### 3.2.2 Bússola Digital

A bússola é uma das ferramentas mais antigas de navegação, descoberto pelos chineses em 2.000 a.c, que se difundiu pela Europa pelos árabes, e desde então revolucionou a área da navegação, melhorando o comércio marítimo. A bússola é composta por um ponteiro livre e magnetizado que se alinha de forma precisa com o campo magnético terrestre. Um instrumento qualquer, que possua uma barra magnetizada girando livremente sobre um pivô, direcionando para o norte, pode ser denominado como uma bússola (MARCHI, 2009).

O princípio de funcionamento da bússola digital é o mesmo da tradicional: o campo magnético terrestre; no entanto o sensor que capta esse efeito possui propriedades magnético-resistivo, captando o campo magnético. Para este trabalho é utilizado a IMU, que contém o magnetômetro integrado, sendo executado o seguinte o Pseudocódigo 3.1.

```

1 void getCompassData(float mx, float my):
2     if (my == 0)
3         heading = (mx < 0) ? PI : 0;
4     else
5         heading = atan2(mx, my);
6
7     heading -= DECLINATION * PI / 180;
8
9     if (heading > PI) heading -= (2 * PI);
10    else if (heading < -PI) heading += (2 * PI);
11
12    return heading;

```

Pseudocódigo 3.1 – Função de implementação da bússola

Os valores de *mx* e *my* são, respectivamente, os valores da leitura do magnetômetro correspondentes aos eixos x e y, na unidade de medição inercial.

### 3.2.3 Filtro de Kalman

O Filtro de Kalman é um método criado por Rudolf Kalman em 1958, utilizado para atenuar os *bias* e outros ruídos indesejados provenientes das medições de sensores, esse sistema será implementado via *software* em linguagem C modificada no Arduino IDE. O método utiliza medidas realizadas ao longo do tempo, a fim de gerar resultados próximos aos valores reais de medição (OLIVEIRA; NUNES, 2017).

Portanto, esse filtro é um sistema recursivo e preditivo para medidas ruidosas, uma de suas mais importantes aplicações é na fusão sensorial, sendo capaz de produzir

estimativas de localização muito próximas ao estado real do sistema (LI1; WANG, 2012). Para esta aplicação, o *Filtro de Kalman* será utilizado para a fusão das informações obtidas pelo módulo LSM9DS1 e o GPS NEO-6M, visando estimar a posição X e Y e a atitude (*pitch*, *roll* e *yaw*) de um objeto em ambiente. A Figura 17 mostra a esquematização do *Filtro de Kalman*.

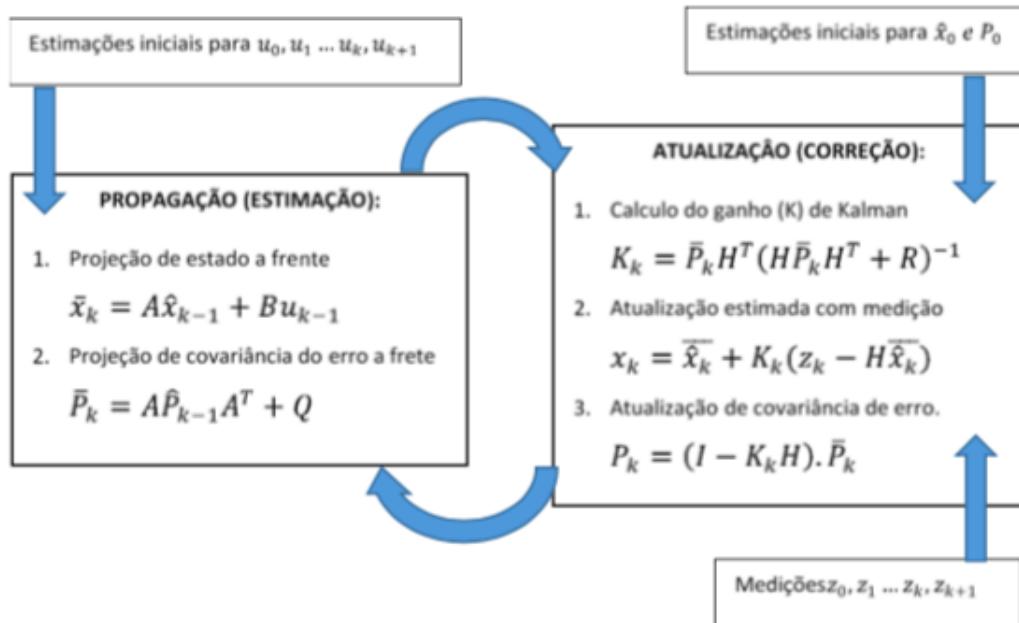


Figura 17 – Esquematização do funcionamento do *Filtro de Kalman* (OLIVEIRA; NUNES, 2017)

O *Filtro de Kalman* possui duas etapas: a **propagação (estimação)** e a **atualização (correção)** realizando uma estimativa sobre a dinâmica do sistema, fazendo o uso de técnicas recursivas aplicados em cada estado (OLIVEIRA; NUNES, 2017). Na propagação é realizada uma estimativa sobre a dinâmica do modelo e na segunda fase, é feita uma atualização, atuando na covariância do erro. Assim, como mostrada na figura anterior, este filtro gera um valor estimado pra o estado  $x_k$  durante a fase de propagação, e na fase de atualização a variação em relação a medida real é corrigida, obtendo-se o chamado *ganho de Kalman* ( $K_k$ ), que corresponde ao peso relativo dado às medições e estimativa do estado atual.

# 4 Desenvolvimento

Neste capítulo serão apresentadas as etapas estabelecidas para o projeto, tais como a montagem do sistema de obtenção de dados (contendo os módulos IMU e GPS), a implementação do Filtro Complementar, para o cálculo dos valores de *pitch* e *roll*, o cálculo do valor de *yaw* utilizando o magnetômetro, e por fim, como foi realizada a fusão sensorial utilizando o Filtro de Kalman. Tanto essa técnica quanto o Filtro Complementar foram ambos implementados no microcontrolador ATmega 2560 (kit Arduino). Para o monitoramento do sistema de navegação, foi criada uma estação de solo, que dispõe de quatro gráficos:

1. Variação dos valores de *pitch*, *roll* e *yaw*, todos em graus, em função do tempo, em segundos. Estes valores foram obtidos através do Filtro Complementar, utilizando a IMU.
2. Variação do posicionamento geográfico, dos dados em termos de coordenadas cartesianas, X e Y, ambos em metros, obtidos apenas com o módulo GPS.
3. Variação do posicionamento geográfico, dos dados em termos de coordenadas cartesianas, X e Y, ambos em metros, obtidos com a fusão sensorial por Filtro de Kalman utilizando o GPS e a IMU.
4. Sobreposição dos valores obtidos pelo item 2 e 3, para auxiliar a análise dos resultados.

## 4.1 Desenvolvimento do Sistema de Captura de Dados

Após serem realizados os estudos sobre o que é um sistema de navegação baseado na fusão sensorial entre os sensores iniciais (IMU) e o GPS, e conhecer o real custo *versus* benefício da fusão sensorial através dos Filtros Complementar e de Kalman, foi desenvolvido um sistema de navegação com baixo custo de implementação, utilizando as técnicas descritas anteriormente.

Primeiramente, foi construído um protótipo de captação de dados do posicionamento geográfico e das medidas iniciais, a partir dos módulos de Posicionamento Global (GPS) e da Unidade de Medição Inercial (IMU), respectivamente, com uma placa *Arduino Mega*.

Com o auxílio do software *Fritzing* foi realizada a esquematização da montagem do protótipo no *Arduino*, como apresentada na Figura 18.

O sistema apresentado na Figura 18 foi ligado a um computador, usando a comunicação serial USART (*Universal Synchronous/Asynchronous Receiver/Transmitter*) a partir

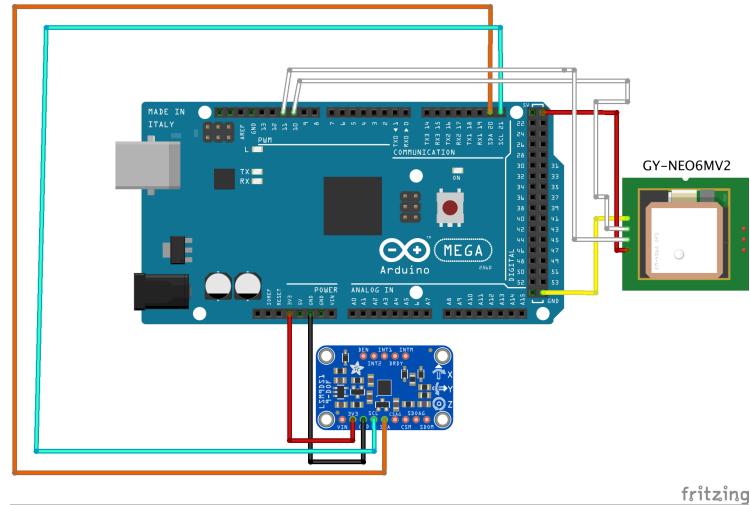


Figura 18 – Sistema de captação dos dados de posicionamento do sistema

de um cabo USB. Os dados processados (pelos filtros implementados no microcontrolador Atmega 2560) são transmitidos para a interface gráfica para permitir que o usuário visualize graficamente os resultados das medições realizadas. Essa interface gráfica é composta por dois diferentes módulos de interação com o usuário. O primeiro módulo é uma central de monitoramento que possui diversos gráficos, que tem por finalidade permitir que o usuário observe as medições dos sensores e os dados obtidos pelo GPS, bem como os resultados gerados pela filtragem após a implementação do filtro complementar e também pela fusão sensorial por filtro de Kalman. O segundo módulo é uma animação de um veículo, que se move com a movimentação do sistema representado acima, considerando os ângulos de atitude referente às medições de *pitch*, *roll* e *yaw*. Nas próximas seções serão explicadas o funcionamento desses dois módulos.

## 4.2 Módulo 1: Central de Monitoramento

A central de monitoramento consiste em uma aplicação desenvolvida em *Python* utilizando a biblioteca *Matplotlib*, para a criação e customização dos gráficos, documentação disponível em ([HUNTER et al., 2020](#))

A central de monitoramento consiste em uma interface com quatro gráficos, onde os gráficos mostram as saídas do Filtro Complementar (as estimativas de *pitch*, *roll* e *yaw*) e do Filtro de Kalman (as estimativas de posição X e Y), e também os dados de localização fornecidos apenas pelo GPS e uma sobreposição entre as medidas do GPS e da fusão sensorial através do Filtro Complementar e de Kalman. A aplicação é mostrada na Figura 19.

A Figura 19 mostra o gráfico no momento inicial, onde os componentes são inicia-

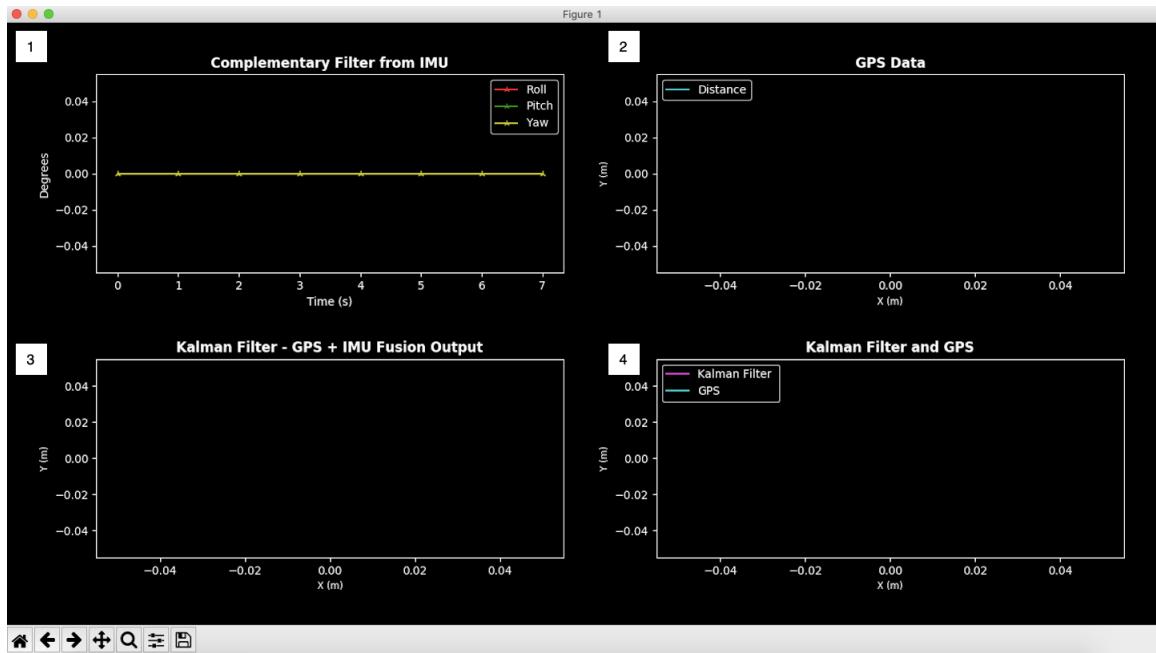


Figura 19 – Central de Monitoramento

lizados a partir da posição em repouso do veículo, considerando a posição inicial como  $X = 0$  e  $Y = 0$ , em um plano sem inclinação.

O gráfico 1 mostrará o resultado do Filtro Complementar, gerado a partir da fusão de dados do acelerômetro e do giroscópio, para a obtenção dos valores de *pitch* e *roll* e da medição de *yaw* utilizando apenas o magnetômetro, também presente na IMU.

O gráfico 2 mostrará uma representação gráfica obtida pelo GPS em coordenadas cartesianas (x e y, em metros), relativo ao posicionamento inicial do veículo. Os dados recebidos pelo módulo GPS são representados no sistema geodésico (definido em 2.1.3), ou seja, em termos de latitude e longitude. Dessa forma foi preciso realizar a conversão para o sistema de coordenadas cartesianas, para realizar a fusão sensorial.

O gráfico 3 será a representação gráfica do resultado do Filtro de Kalman, ou seja, após a fusão sensorial dos dados obtidos pela IMU e pelo módulo GPS, em termos de coordenadas cartesianas.

Por final, o gráfico 4 mostrará uma sobreposição dos gráficos obtidos em 2 e 3 para auxiliar a análise e comparação das saídas obtidas apenas com o módulo GPS e com a fusão sensorial através dos Filtros Complementar e de Kalman.

A implementação do filtro complementar, a transformação de coordenadas do GPS e a fusão sensorial por Filtro de Kalman serão descritos nas Seções 4.4, 4.5 e 4.6, respectivamente.

### 4.3 Módulo 2: Animação 3D

A animação 3D é uma aplicação também desenvolvida em *Python*, utilizando uma API de computação gráfica, o *OpenGL*. O *OpenGL* é uma biblioteca de rotinas gráficas e de modelagem 2D e 3D, extremamente portável. Sendo possível criar gráficos 3D com uma qualidade visual próxima de um *ray tracer*. Entretanto, a maior vantagem na sua utilização é a rapidez no processamento de dados para a criação dos pontos que compõem o componente gráfico (neste projeto trata-se de um carro), uma vez que usa algoritmos cuidadosamente desenvolvidos e otimizados pela *Silicon Graphics, Inc.*, líder mundial em Computação Gráfica e Animação. ([KHRONOS, 2013](#)).

A Figura 20 mostra a interface gráfica desenvolvida, onde foi criada uma animação de um carro, desenhado ponto a ponto utilizando conceitos de computação gráfica, e na área inferior são mostrados os parâmetros *pitch*, *roll* e *yaw* (todos medidos em graus) estimados pelo filtro complementar implementado no *Arduino*.

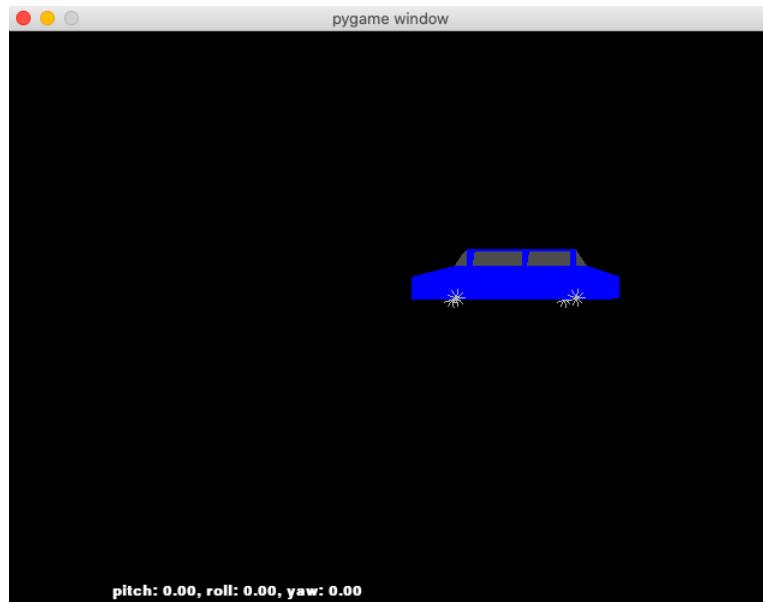


Figura 20 – Animação 3D com o *OpenGL*

A função em *Python* apresentada no pseudocódigo 4.1 mostra como é realizada a leitura dos dados seriais recebidos através do cabo USB, enviada pelo *Arduino*. O *Arduino* calcula os valores de *pitch*, *roll* e *yaw*, através do Filtro Complementar. Esses dados são organizados em uma sequência de *strings* separadas por vírgula e enviadas para o PC através da comunicação serial USART usando a porta USB. No código em *Python*, o comando: *ser = serial.Serial('/dev/cu.usbmodem14201', 115200, timeout = None)*, define a porta serial do PC e a taxa de transferência em *bits* por segundo (*baudrate*).

O método *read\_data* é chamado pela função principal (*main*) dentro de um *loop* infinito, dessa forma, ela irá capturar a sequência de dados (*pitch*, *roll* e *yaw*) recebidos do

*Arduino* ao longo do tempo, através da linha 6 do pseudocódigo 4.1, é lido uma sequência de *strings* contendo dados recebidos pelo microcontrolador, sendo enviada pela porta serial. Posteriormente, é realizada a quebra da *string* utilizando a vírgula como separador, e ao final, estes serão os parâmetros de atitude (*pitch*, *roll* e *yaw*) da animação desenvolvida.

```

1 def read_data():
2     global ax, ay, az
3     ax = ay = az = 0.0
4     line_done = 0
5     ser.write(b".")
6     line = ser.readline()
7     angles = line.split(b",")
8     if len(angles) == 3:
9         ax = float(angles[0])
10        ay = float(angles[1])
11        az = float(angles[2])
12        line_done = 1

```

Pseudocódigo 4.1 – Função de leitura de dados da porta serial

## 4.4 Filtro Complementar

O Filtro Complementar definido na seção 2.1.9 foi implementado usando a fusão sensorial do acelerômetro, giroscópio e magnetômetro, para calcular os valores de *pitch*, *roll* e *yaw*. Nas próximas seções serão apresentadas como foram configurados os sensores de forma a trabalharem ao nosso propósito e como a escolha da IMU LSM9DS1 facilitou a implementação do sistema.

### 4.4.1 Giroscópio

A medição do giroscópio, a longo prazo, passa a sofrer variações significativas em relação aos valores reais de medição, ou seja, a margem de erro da velocidade angular aumenta em função do tempo. Dessa forma, é necessária a implementação de um filtro passa-alta, para filtrar o componente de *drift* em baixa frequência.

Uma das grandes vantagens da seleção da IMU LSM9DS1 da *SparkFun* é que ela implementa o filtro passa-alta em sua lógica, facilitando o trabalho desenvolvido. Dessa forma é necessário apenas habilitá-la na configuração do módulo. A Figura 21 mostra um trecho de código da biblioteca da IMU LSM9DS1, desenvolvido pela *SparkFun*, onde podemos observar o atributo *settings.gyro.HPFEnable*, que pode ser *setado* para verdadeiro ou falso, dependendo da aplicação da IMU. Para este projeto, foi setado o valor *true*. Logo abaixo pode ser observado, que a biblioteca possui o *settings.gyro.HPFCutoff*, onde é possível configurar a frequência de corte para o filtro passa-alta.

Para o desenvolvimento deste projeto foi habilitado a opção para utilizar o filtro passa-alta (*settings.gyro.HPFCutoff = 1*) e foi utilizada uma frequência de corte na

```

void LSM9DS1::init(interface_mode interface, uint8_t xgAddr, uint8_t mAddr)
{
    settings.device.commInterface = interface;
    settings.device.agAddress = xgAddr;
    settings.device.mAddress = mAddr;

    settings.gyro.enabled = true;
    settings.gyro.enableX = true;
    settings.gyro.enableY = true;
    settings.gyro.enableZ = true;
    // gyro scale can be 245, 500, or 2000
    settings.gyro.scale = 245;
    // gyro sample rate: value between 1-6
    // 1 = 14.9    4 = 238
    // 2 = 59.5    5 = 476
    // 3 = 119     6 = 952
    settings.gyro.sampleRate = 6;
    // gyro cutoff frequency: value between 0-3
    // Actual value of cutoff frequency depends
    // on sample rate.
    settings.gyro.bandwidth = 0;
    settings.gyro.lowPowerEnable = false;
    settings.gyro.HPFEable = false;
    // Gyro HPF cutoff frequency: value between 0-9
    // Actual value depends on sample rate. Only applies
    // if gyroHPFEable is true.
    settings.gyro.HPFCutoff = 0;
}

```

Figura 21 – Trecho da função de inicialização, da biblioteca da IMU LSM9DS1 ([SPARK-FUN, 2018](#))

opção 1 ( $settings.gyro.HPFCutoff = 1$ ), que corresponde a  $4Hz$ . Essa medida foi definida empiricamente. O valor da frequência de corte possui quatro opções de valores, relativos ao *Output Data Rate* (ODR), que é a taxa que o giroscópio realiza a amostragem dos valores medidos. Esse valores são 0, 1, 2 ou 3, que são, respectivamente,  $\frac{ODR}{50}$ ,  $\frac{ODR}{100}$ ,  $\frac{ODR}{9}$ ,  $\frac{ODR}{400}$ , fornecidos pelo *datasheet* do módulo IMU ([STMICROELECTRONICS, 2015](#)).

#### 4.4.2 Acelerômetro

O acelerômetro possui sinais de baixa-frequência, portanto para que haja uma minimização dos ruídos obtidos pelas medições deste sensor, é utilizado um filtro passa-baixa.

Além do filtro passa-altas, a IMU também possui a implementação do filtro passa-baixa, dessa forma também não é necessário desenvolvê-lo, apenas configurá-lo de modo análogo ao representado pela Figura 21, porém o acelerômetro, em específico. De acordo com estudos realizados na literatura, como em ([LI; WANG, 2012](#)) e ([AHMAD; GHAZILLA;](#)

(KHAIRI, 2013), o acelerômetro se comporta melhor em instantes em que o sistema está em repouso (sem movimentação) e o giroscópio para corpos em movimento, então esses comportamentos podem ser integrados através da fusão por Filtro Complementar, usufruindo das vantagens desses dois sensores.

Utilizando essa constatação, o Filtro Complementar implementado leva em consideração as medições dos seguintes sensores: o giroscópio e o acelerômetro (para obtenção dos valores de *pitch* e *roll*); e o magnetômetro para o cálculo do *yaw*.

#### 4.4.3 Implementação

Após realizar as configurações do acelerômetro e do giroscópio, descritas nas subseções 4.4.1 e 4.4.2, respectivamente, foi inicializado o desenvolvimento do filtro. O primeiro passo foi definir as constantes do Filtro Complementar, ou seja, o "peso" dos dados de cada um dos sensores para se obter a estimativa da atitude. Em várias referências discutidas na literatura, algumas abordadas na Seção 2.1.9, os valores nos quais o filtro obtém uma eficiência razoável são de 0.02 para o acelerômetro e de 0.98 para o giroscópio, definidos através de estudos e análises de valores utilizados na literatura.

A partir dos dados obtidos pelo acelerômetro e giroscópio, são calculadas as velocidades angulares em torno dos eixos x, y e z, as integrando a cada intervalo de tempo usando a Equação 4.1. Dessa forma, o ângulo de rotação para cada um dos três eixos (x, y e z) é realizado o seguinte cálculo:

$$\begin{bmatrix} \phi \\ \psi \\ \theta \end{bmatrix} = 0.98 \times \left( \begin{bmatrix} \phi \\ \psi \\ \theta \end{bmatrix} + \begin{bmatrix} gyr_x \\ gyr_y \\ gyr_z \end{bmatrix} \times dt \right) + 0.02 \times \begin{bmatrix} acc_x \\ acc_y \\ acc_z \end{bmatrix} \quad (4.1)$$

Os parâmetros  $\psi$ ,  $\phi$  e  $\theta$  representam, respectivamente, os ângulos de rotação em torno dos eixos x (*roll*), y (*pitch*) e z (*yaw*). Na implementação deste sistema de navegação são obtidos dois valores de *yaw*, o primeiro, a partir do Filtro Complementar, utilizando o acelerômetro e o giroscópio, e o outro a partir da implementação da bússola utilizando o magnetômetro. Posteriormente eles serão aplicados, respectivamente, nas fases de atualização e propagação do Filtro de Kalman, conforme descrito na Seção 4.6. Os valores  $gyr_x$ ,  $gyr_y$ ,  $gyr_z$  são as velocidades angulares em torno dos eixos x, y e z, respectivamente; e  $acc_x$ ,  $acc_y$ ,  $acc_z$  são as acelerações lineares em torno dos eixos x, y e z, respectivamente. A função que implementa o Filtro Complementar no Arduino está apresentado no Anexo A.1.

Após obter os valores de *pitch*, *roll* e *yaw* a partir do Filtro Complementar, foi calculado o *yaw* obtido através da bússola, utilizando apenas os dados do magnetômetro,

segundo a Equação 4.2.

$$\theta_2 = \text{atan2}(mx, my) \quad (4.2)$$

O parâmetro  $\theta_2$  representa o valor do ângulo *yaw*, e os valores de *mx* e *my* são, respectivamente, os valores de força magnética nos eixos x e y. O cálculo realizado pela Equação 4.2 simula uma bússola, que será utilizada para correção da orientação do veículo na fase de propagação do Filtro de Kalman, como será mostrado posteriormente no Capítulo 5.

## 4.5 Sistema de Posicionamento Global (GPS)

Os dados obtidos pelo módulo GPS estão em formato geodésico, ou seja, em termos de latitude e longitude, para que seja possível realizar a fusão sensorial por Filtro de Kalman (descrito na próxima seção 4.6). É necessário converter para o sistema de coordenadas cartesianas de forma a combinar com os dados da IMU.

Para o desenvolvimento desta parte do projeto, foi considerado que a Terra é um elipsóide como mostrada na Figura 6, da seção 2.1.3, e que ela possui um raio equatorial de  $R = 6.371$  km (6.371.000 m). A transformação para coordenadas cartesianas (x, y e z) foi realizada da seguinte forma.

Nessa "elipsóide" são consideradas duas linhas, o meridiano de *Greenwich* e a linha do Equador que a cortam no centro da Terra. A latitude é a distância medida verticalmente a partir da localização do corpo até a linha do Equador e a longitude é a distância medida horizontalmente em relação ao meridiano de *Greenwich*, ambas em graus. A partir das medidas de latitude e longitude, as coordenadas cartesianas são calculadas da seguintes forma (CAMARA, 2005):

$$X = R \times \cos(\Phi) \times \cos(\lambda) \quad (4.3)$$

$$Y = R \times \cos(\Phi) \times \sin(\lambda) \quad (4.4)$$

$$Z = R \times \sin(\Phi) \quad (4.5)$$

Os valores X, Y e Z representam a localização do corpo nas respectivas coordenadas cartesianas, em metros. A constante R é o raio da Terra, em metros, e os valores de  $\Phi$  e  $\lambda$  são, respectivamente, os valores da latitude e longitude, em metros.

Com a obtenção do posicionamento global em coordenadas cartesianas foi possível coletar as amostras para análise e posterior implementação do Filtro de Kalman.

Os dados (obtidos pelo GPS) utilizados no projeto são sempre em relação a posição de partida do veículo, dessa forma, quando o GPS é inicializado, o posicionamento (em coordenadas cartesianas, x, y e z) são salvas em uma variável global, para que o sistema sempre possa utilizar esses valores para calcular o deslocamento em relação ao ponto inicial. Dessa forma é possível obter a distância percorrida pelo veículo desde a inicialização do sistema até o final de sua trajetória.

## 4.6 Fusão sensorial por Filtro de Kalman

Após a implementação do Filtro Complementar e da transformação de coordenadas geodésicas para cartesianas, foi possível realizar a fusão sensorial por Filtro de Kalman.

O primeiro passo realizado foi definir as variáveis de entrada e saída do sistema, e também construir o vetor de estados.

### 4.6.1 Implementação

A partir das medições de *pitch*, *roll* e *yaw* obtidas pelo Filtro Complementar e das coordenadas cartesianas provenientes dos dados obtidos pelo módulo GPS NEO-6M e das medidas de aceleração nos eixos x e y e velocidade angular em torno de x, y e z, foi implementado o Filtro de Kalman para fundir esses dados e estimar a posição do veículo em relação um a sistema de coordenada inercial. A Figura 22 traz a representação do sistema de navegação desenvolvido.

O primeiro passo executado pelo sistema de navegação é a captura de dados obtidos pelos módulos GPS e IMU. Ao inicializar o sistema, é realizada a leitura dos valores de posicionamento ( $P_x$ ,  $P_y$ ,  $P_z$ ), em coordenadas cartesianas x, y e z obtidas pelo módulo GPS, que são utilizadas na fase de atualização, descrita na subseção 4.6.1.2, e também nesta fase é utilizado o valor de *yaw* ( $\psi$ ), obtida pela bússola implementada utilizando o magnetômetro. Na fase de propagação, descrita na seção 4.6.1.3 são utilizados os valores de *pitch*, *roll* e *yaw* obtidos pelo Filtro Complementar.

Com a leitura das medições realizadas pelo giroscópio e acelerômetro, são calculados os valores de *pitch* e *roll*, através do Filtro Complementar. Estes valores são utilizados pela fase de propagação (Seção 4.6.1.2).

O pseudocódigo 4.6.1 (CABRAL, 2017) mostra o algoritmo do Filtro de Kalman implementado.

Como mostrado no diagrama da Figura 22 e o pseudocódigo acima, o Filtro de Kalman é composto por três fases: Inicialização, atualização e propagação.

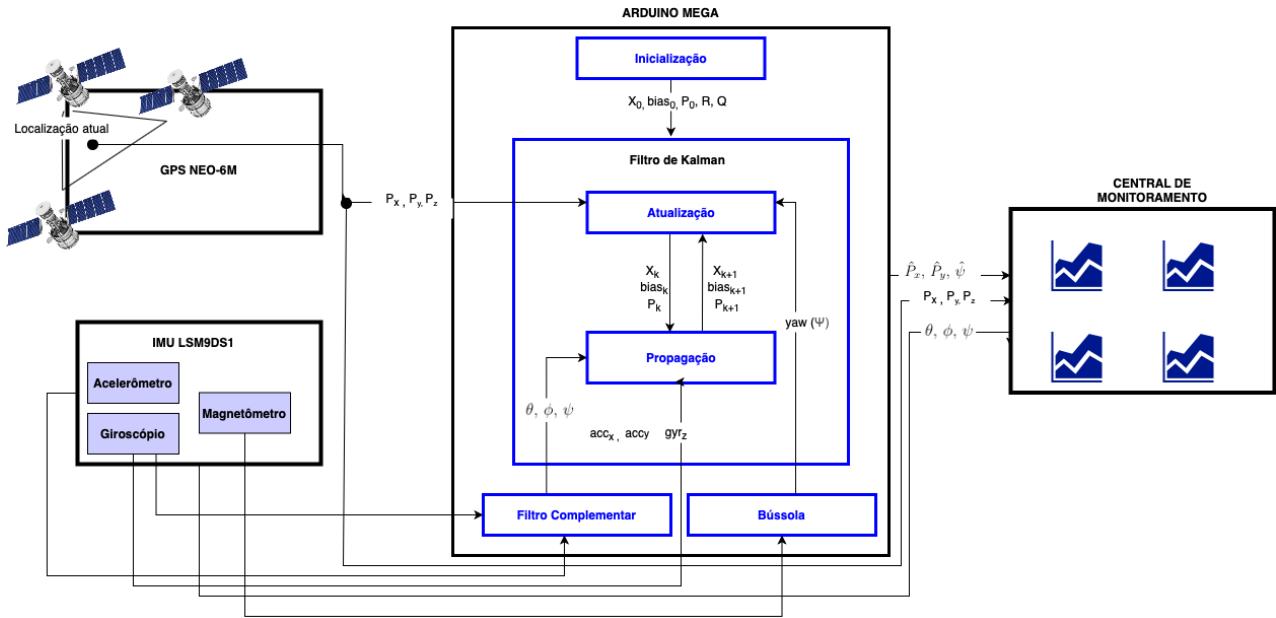


Figura 22 – Representação completa do Sistema de Navegação

```

1: function FILTRO DE KALMAN
2:   while novos dados disponíveis do
3:     if GPS e IMU disponíveis then
4:       Executa atualização
5:     end if
6:     if acelerômetro e giroscópio disponíveis then
7:       Executa propagação
8:       Envia dados de  $\hat{p}_x$ ,  $\hat{p}_y$ ,  $\hat{\psi}$  para a central de monitoramento
9:     end if
10:   end while
11: end function

```

#### 4.6.1.1 Inicialização

A primeira fase é a inicialização do sistema, onde são atribuídos valores iniciais a todas as matrizes que compõem o método. As matrizes são representadas abaixo.

- Vetor  $X_0$ , definido na Equação 2.4.

$$X_0 = \begin{bmatrix} V_x^{INS} \\ V_y^{INS} \\ P_x^{INS} \\ P_y^{INS} \\ \psi^{INS} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \quad (4.6)$$

- Vetor  $bias_0$ , definido em 2.13, contém os *bias* iniciais nos eixos X, Y e Z. O *bias* são variações ou desvios causados nas saídas do acelerômetro e do giroscópio, que

são ocasionados por serem sensores MEMS (*Micro Electro Mechanical Systems*). As propriedades físicas desses sensores mudam ao longo do tempo, o que resulta em características diferentes ao longo do tempo.

$$bias_0 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \quad (4.7)$$

- Em  $P_0$  definida na equação 2.27, os valores iniciais de seus elementos foram obtidos empiricamente, a fim de obter a melhor medição, sem que gere uma divergência no Filtro de Kalman.

$$P_0 = \begin{bmatrix} 50 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 50 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 50 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 50 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0,174 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 10 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 10 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 10 \end{bmatrix} \quad (4.8)$$

- $Q$ , definida na Equação 2.22.

$$Q = \begin{bmatrix} 0,0196 & 0 & 0 \\ 0 & 0,0196 & 0 \\ 0 & 0 & 0,0196 \end{bmatrix} \quad (4.9)$$

- $R$ , definida na Equação 2.23.

$$R = \begin{bmatrix} 0,25 & 0 & 0 \\ 0 & 0,25 & 0 \\ 0 & 0 & 0,25 \end{bmatrix} \quad (4.10)$$

#### 4.6.1.2 Atualização

A atualização verifica se o sistema recebeu novos valores de medições realizadas pelo GPS e a bússola, sempre que houver um novo dado, é executado este passo. Essas novas medições são combinadas com as medidas obtidas na iteração anterior, isto é, se o sistema acabou de ser inicializado, as matrizes da fase de inicialização serão incorporadas aos primeiros dados recebidos pelos sensores.

O primeiro passo é calcular o ganho de Kalman ( $K$ ), que consiste em uma correção do vetor de variáveis de estado. Para calcular  $K$ , são utilizadas as matrizes  $P_k^-$  e  $R$ ,

que são, respectivamente, a matriz de covariância obtida *a priori*, ou seja, pela fase de propagação da iteração anterior; e a matriz de ruídos de medição também obtida *a priori*. O ganho de Kalman é calculado pela Equação 4.11.

$$K_k = P_k^- \times H^T [H \times P_k^- \times H^T + R]^{-1} \quad (4.11)$$

As matrizes  $H$  e  $H^T$  são, respectivamente, a matriz de parâmetros referentes às variáveis de estado e a sua transposta.

Após o cálculo do ganho de Kalman, é realizada a atualização do vetor de estados do modelo de erro ( $P_k$ ), dos estados estimados do veículo ( $X_k$ ), e de bias ( $bias_k$ ), seguindo o algoritmo descrito na subseção 2.1.10.1.

#### 4.6.1.3 Propagação ou Predição

A fase denominada propagação ou predição é o passo onde são calculadas as estimativas futuras,  $k + 1$ , ou seja, serão lançadas matrizes estimadas de estado,  $\hat{X}_{k+1}$ , de bias,  $\hat{bias}_{k+1}$ , e de covariância de erro,  $\hat{P}_{k+1}$ , utilizando os resultados obtidos pela fase de atualização e realizando correções da matriz de erro com os dados do acelerômetro e do giroscópio, que possuem maior sensibilidade que o módulo GPS NEO-6M. Esta etapa é executada aplicando algoritmo descrito na subseção 2.1.10.2.

A central de monitoramento receberá os dados correspondentes ao resultado desta fase, ou seja, a saída do Filtro de Kalman, observada nos gráficos são correspondentes as estimativas realizadas utilizando valores *a priori* combinados com os capturados instaneamente, de forma, a obter medições mais próximas possíveis das reais.

Os dados estimados para o instante  $k + 1$  serão utilizados na fase de atualização da próxima iteração e este *loop* durará enquanto o sistema for alimentado com novos dados obtidos pela bússola e pelo GPS.

No próximo capítulo serão apresentados os resultados obtidos com o algoritmo descrito.

# 5 Resultados

Neste capítulo serão apresentados os resultados obtidos com o desenvolvimento do projeto (descrito no Capítulo 4), desde o levantamento dos custos, aquisição dos materiais utilizados até, efetivamente, os resultados da implementação do Filtro Complementar, da transformação dos dados do GPS de coordenadas geodésicas para cartesianas e, do Filtro de Kalman, através de alguns testes realizados. Esses resultados são mostrados com o auxílio da interface gráfica composta pelo animação 3D implementada em OpenGL e a central de monitoramento usada para plotar os resultados.

O sistema de navegação envia novos dados à estação de monitoramento em solo a uma taxa de  $1Hz$ . Esses dados são as medidas de atitude (*pitch*, *roll* e *yaw*), do posicionamento geográfico do veículo obtido apenas com o módulo GPS e também o resultado da fusão sensorial através dos Filtros Complementar e de Kalman). Os dados do módulo GPS e da IMU são transferidos do Arduino para o PC com uma taxa transferência de dados de 115200 *bits* por segundo (bps).

Primeiramente, na Seção 5.1 serão apresentados os custos obtidos com a implementação do sistema de navegação através da aquisição do microcontrolador e dos módulos GPS e da IMU. Seguido pelos resultados obtidos após a montagem do sistema de captação de dados e a implementação da bússola e dos Filtros Complementar e de Kalman.

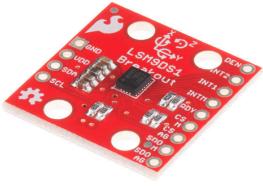
## 5.1 Custos de implementação

Esta seção apresentará os custos obtidos com o desenvolvimento do projeto. Os valores relacionados a cada um dos componentes são apresentados na Tabela 5.1.

Com base nos valores apresentados, o custo total foi de R\$ 230,50. Esse valor é comparativamente baixo para um sistemas de navegação baseado em satélites artificiais.

Nas próximas seções serão apresentados os resultados obtidos com o sistema de captação de dados montado.

Tabela 3 – Materiais a serem utilizados no projeto

| Material   | Nome  | Preço   |
|--|---|---|
|   | <i>Arduino Mega 2560</i>                    | R\$ 109,90, preço com base na loja virtual da <i>RoboCore</i> .           |
|   | <i>SparkFun 9DoF IMU Breakout - LSM9DS1</i> | U\$ 14,20 (R\$78,10), preço com base na loja virtual da <i>Sparkfun</i> . |
|  | GPS NEO-6M com Antena                       | R\$ 42,50, preço com base no <i>e-commerce</i> do Mercado Livre.          |

## 5.2 Determinação da atitude usando o Filtro Complementar

Nesta seção será descrita a implementação do Filtro Complementar no Arduino, utilizando o módulo IMU. Na parte superior desse sensor, apresentado na Figura 23, é mostrada as orientações dos eixos x, y e z.

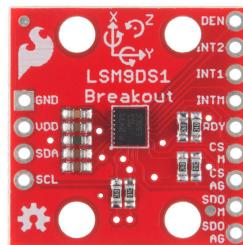


Figura 23 – SparkFun 9DoF IMU Breakout - LSM9DS1

A partir da implementação do Filtro Complementar, abordado na seção 4.4 do capítulo anterior, foram realizados testes do seu funcionamento utilizando a animação criada com a biblioteca *OpenGL*, como observado na Figura 24.

Considerando a Figura 24, a imagem 1 mostra quando a IMU está reta em relação ao seu eixo de rotação; o resultado das inclinações nos eixos longitudinal, lateral e vertical

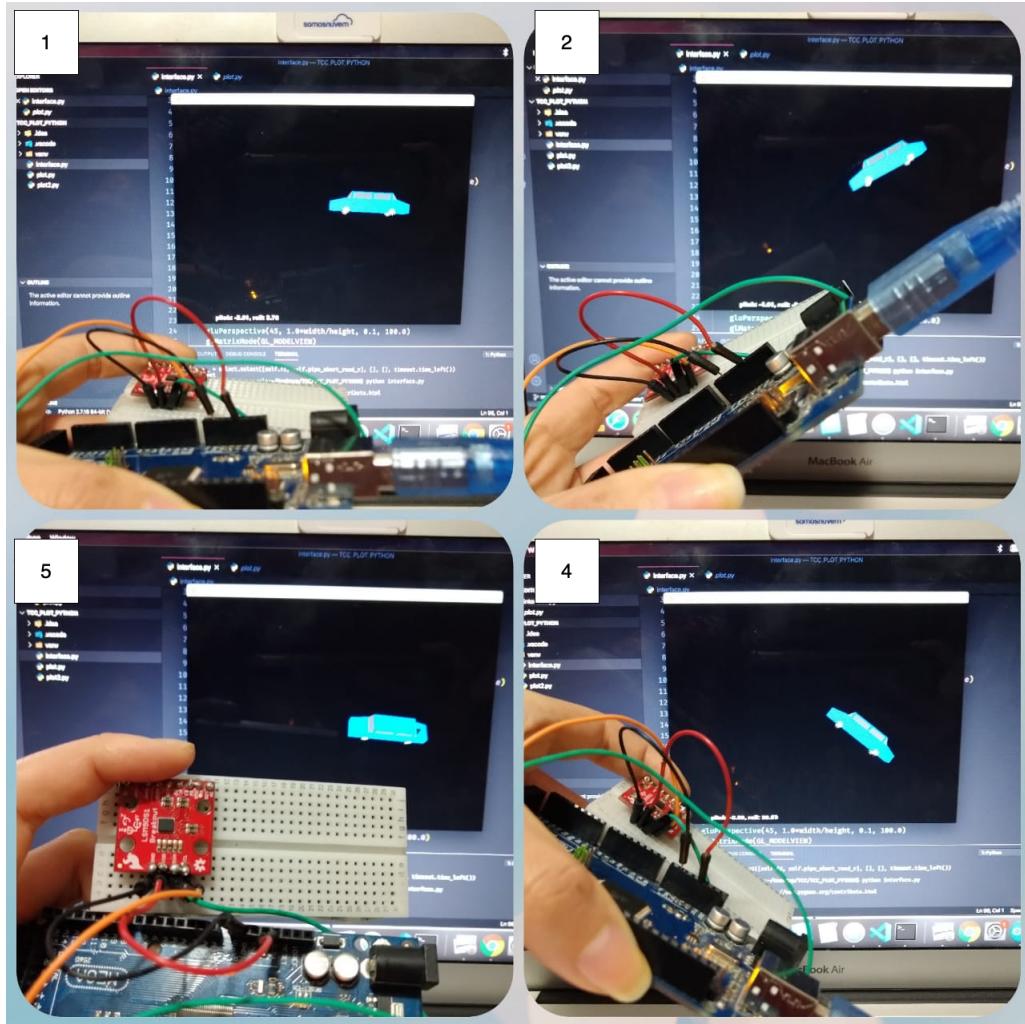


Figura 24 – Funcionamento da interface com os dados da IMU

estão representadas nas imagens 2, 3 e 4, respectivamente. Dessa forma, podemos analisar as variações do parâmetro de *pitch* e *roll* do veículo no plano da interface.

O segundo módulo desenvolvido, na estação de monitoramento em solo, mostrado na Figura 25, apresenta os resultados obtidos pelo Filtro Complementar, que são as medidas de atitude: *pitch*, *roll* e *yaw*. Nesta figura, o sistema foi inicializado com o módulo em repouso, em um plano sem inclinação em nenhum de seus eixos.

É possível observar que após ser inicializado, mesmo em uma superfície plana, sem rotação em nenhum dos eixos, há uma pequena variação ocasionada pelos ruídos de medição obtidos pelo giroscópio, acelerômetro e magnetômetro. A Figura 25 mostra o comportamento de *pitch*, *roll* e *yaw*, com a IMU em repouso, sobre uma mesa.

A vantagem de representar as medidas realizadas na forma de um gráfico é a facilidade de observar a variação dos valores de ângulos de inclinação em função do tempo decorrido. A Figura 26 mostra o comportamento do gráfico quando o módulo IMU sofre

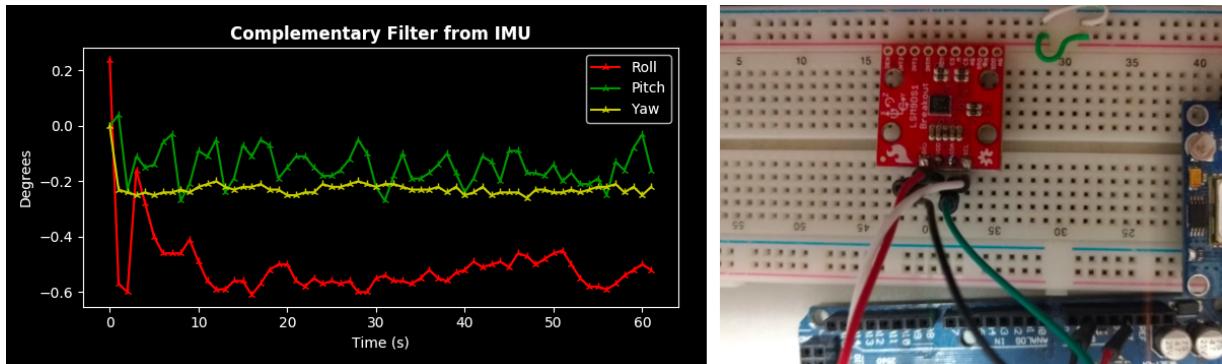


Figura 25 – Saída do Filtro Complementar a IMU em repouso em uma superfície plana (sem inclinação)

uma ação em relação ao eixo lateral, com uma inclinação de  $90^\circ$ , em relação ao plano da mesa (como observado na figura). Assim, podemos observar a alteração do valor do ângulo de *pitch*.

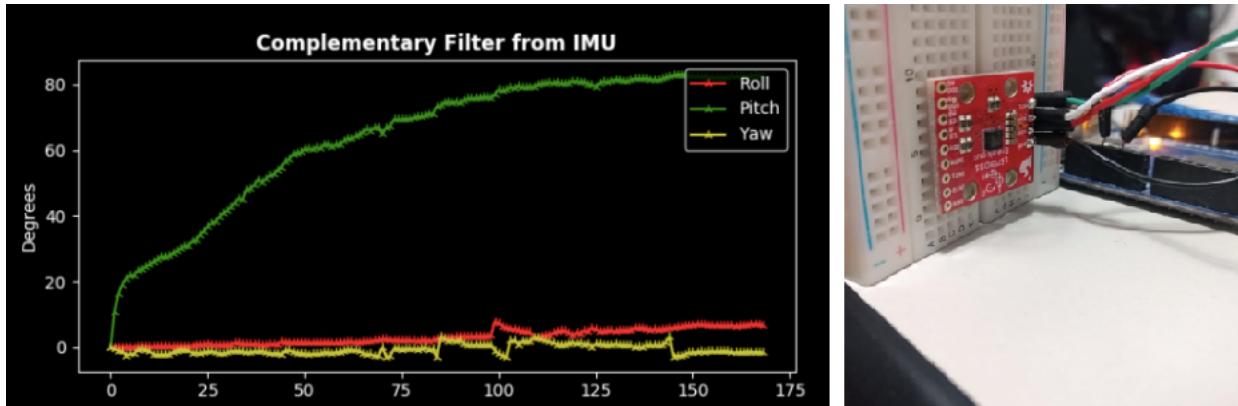


Figura 26 – Saída do Filtro Complementar com relação ao eixo lateral

Posteriormente, reiniciando o sistema e rotacionando a IMU em relação ao eixo longitudinal, em aproximadamente  $-90^\circ$ , em relação ao plano da mesa (o valor negativo se dá pela orientação do eixo como desenhado no sensor, na Figura 23), pode ser observado a variação do ângulo de *roll*.

Novamente, reiniciando o sistema, para observar a variação do parâmetro *yaw*, foram obtidos os seguintes resultados. O primeiro teste foi deixar o sensor com inclinação nula em relação ao eixo vertical, como mostrado na Figura 28.

O segundo teste foi inclinar a IMU  $90^\circ$  em relação ao eixo vertical, seguindo o sistema de eixos marcado no papel, como mostrado na Figura 29.

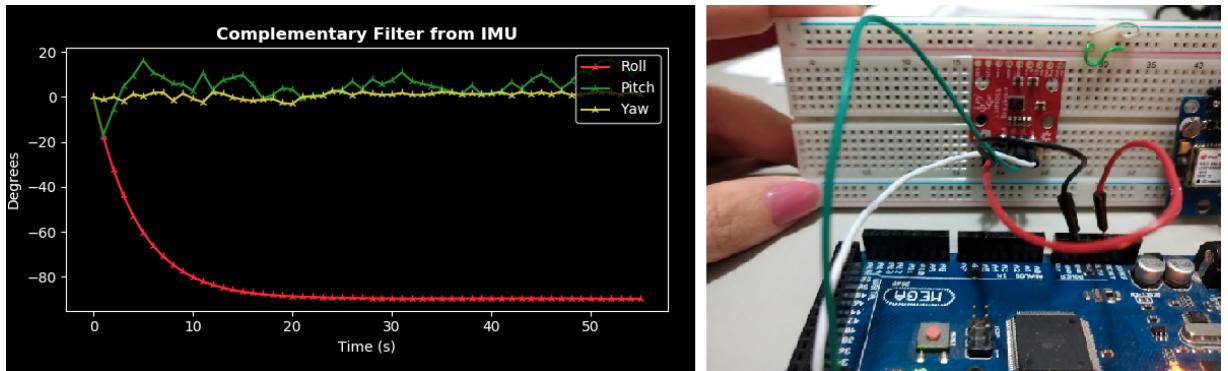


Figura 27 – Saída do Filtro Complementar com relação ao eixo longitudinal

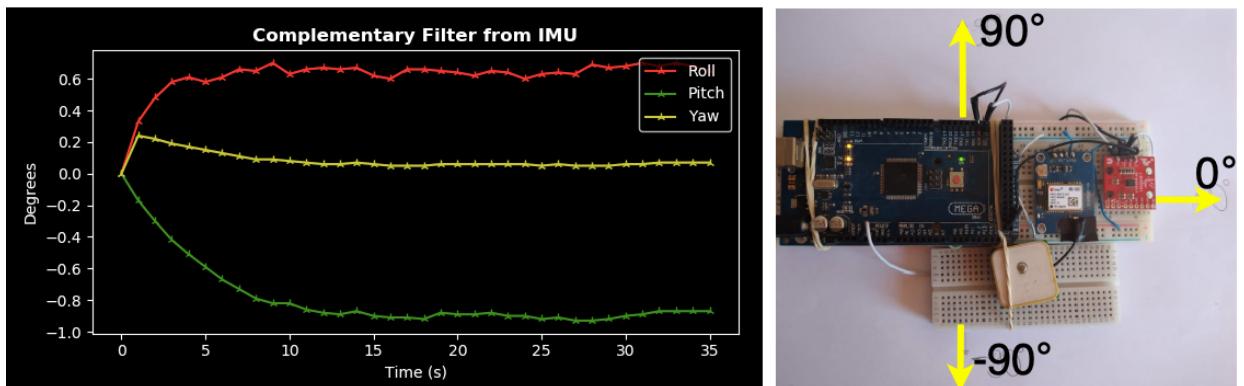


Figura 28 – IMU sem inclinação em relação ao eixo vertical

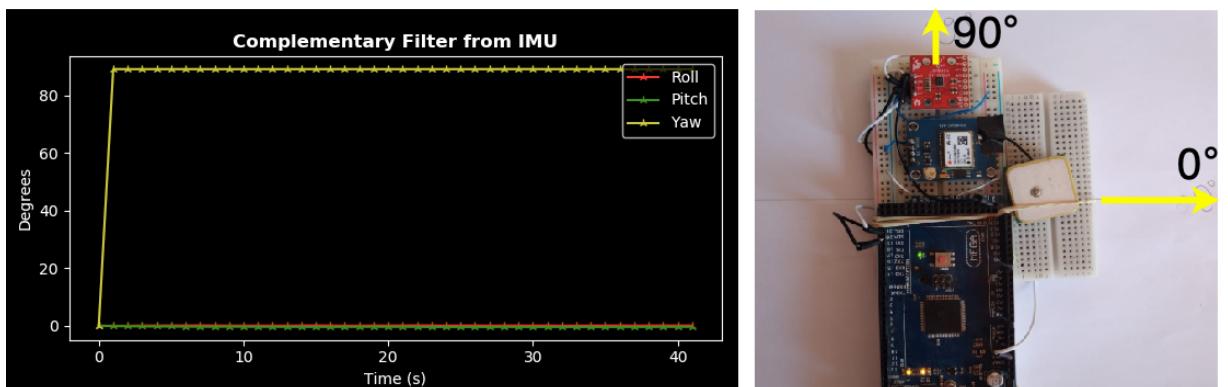


Figura 29 – IMU com inclinação de 90° em relação ao eixo vertical

### 5.3 Navegação com o Módulo GPS

Para realizar a navegação, é necessário converter o sistema de coordenadas geodésica (latitude e longitude) obtidas pelo módulo GPS NEO-6M para o sistema de coordenadas cartesianas, em metros. Para isso, foram realizados os testes com um automóvel, para

analisar o comportamento dos valores capturados e o perfil criado durante a trajetória do veículo, com o gráfico de monitoramento.

Considerações importantes acerca dos testes realizados:

- Todos os resultados obtidos nesta seção utilizam os dados fornecidos pelo módulo GPS, sem nenhum tipo de fusão sensorial.
- Os resultados obtidos são em comparação ao GPS do celular com o auxílio do aplicativo *Google Maps*. Mais adiante serão mostrados os resultados obtidos pela leitura do GPS no módulo central de monitoramento e sobre seu gráfico, haverá uma linha tracejada amarela, que representa a localização obtida pelo GPS do celular.
- Os ponto A e B, no gráfico são, respectivamente, o ponto de partida e o destino final.
- No gráfico, a linha ciano representa a leitura do módulo GPS, após a conversão das coordenadas geodésicas para cartesianas; e a linha amarela tracejada é o percurso obtido pelo GPS do celular.
- O veículo utilizado no teste realiza a trajetória a uma velocidade de 40 km/h.
- Em cada teste, ao lado do gráfico da central de monitoramento, há uma imagem retirada do *Google Maps*, representando visualmente a trajetória realizada pelo veículo.
- Os marcadores circulares em azul claro representam pontos referentes as medições do módulo GPS conectado ao Arduino e em azul escuro estão os pontos obtidos pelo GPS do celular utilizando o aplicativo *Google Maps*.
- Em todas as trajetórias realizadas, os valores de X e Y obtidos pelo módulo GPS são valores **absolutos**, ou seja, possuem apenas valores positivos.

Utilizando o módulo GPS (sem nenhum tipo de fusão sensorial) foram realizados 4 testes:

1. **Percorso em descida:** A partir da análise do gráfico, pode ser observado que a posição final do GPS do celular (ponto B em azul escuro) é de, aproximadamente  $X = 120$  m, e quanto ao módulo GPS (ponto B em azul claro) é de, aproximadamente,  $X = 130$  m, portanto uma diferença de 10 m, entre as 2 medições, considerando ambas com o ponto de partida em A.
2. **Percorso em subida:** A partir da análise do gráfico pode ser observado que a posição final do GPS do celular (ponto B em azul escuro) é de, aproximadamente  $X = 115$  m, e quanto ao módulo GPS (ponto B em azul claro) é de, aproximadamente,  $X = 122$  m, portanto uma diferença de 7 m, entre as 2 medições, considerando ambas com o ponto de partida em A.

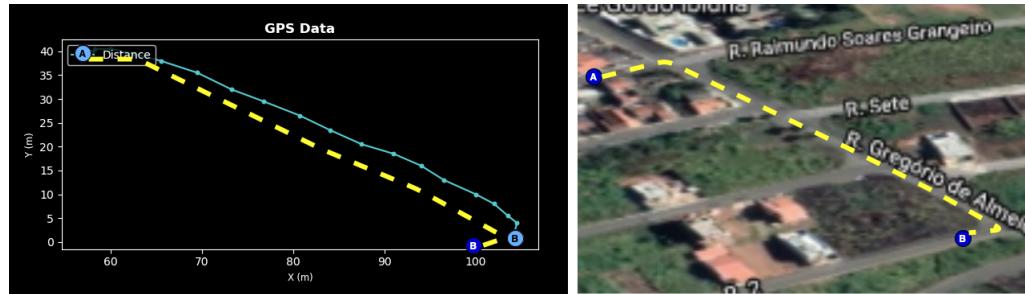


Figura 30 – Resultado da trajetória do automóvel em descida, com o GPS

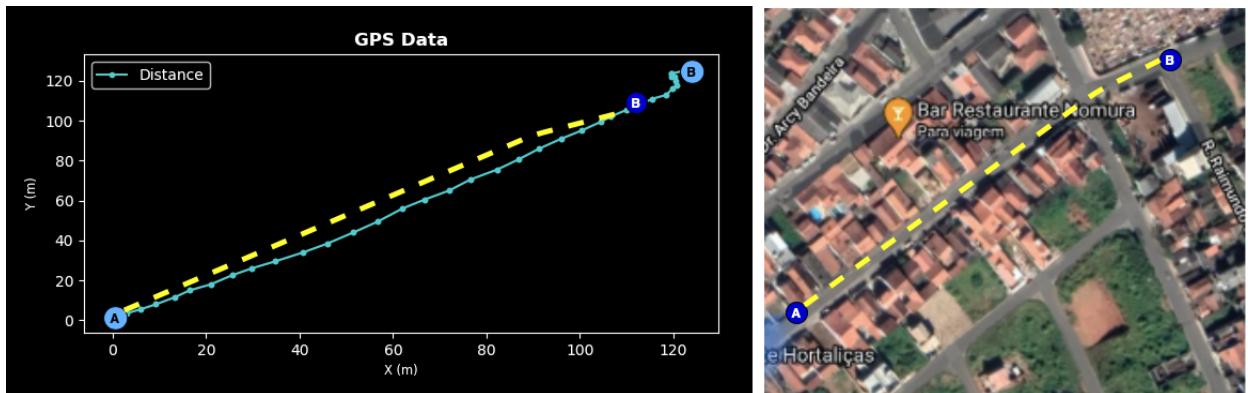


Figura 31 – Resultado da trajetória do automóvel subindo uma ladeira, com o GPS

**3. Percurso com mudança de orientação do veículo:** A Figura 32 apresenta o resultado obtido pelo veículo saindo da posição A, realizando um contorno e finalizando no ponto B. Neste teste foi observado um erro mais significativo em relação aos testes anteriores. Um fator possível para este resultado é a interferência causada pelas falhas de recebimento dos sinais de satélite pelo módulo GPS, isso faz com que o sistema de triangulação e trilateração descritas na subseção 2.1.2.1 sofra falhas na estimativa da localização. Como pode ser observado, o erro maior está na inclinação da curva do gráfico ao final do percurso, no eixo X, a diferença entre o GPS do celular é pequena, pois a posição final (ponto B calculado pelo módulo GPS, em azul claro) é de, aproximadamente,  $X = 18m$  e o GPS do celular é de, aproximadamente,  $X = 20m$ , assim, resultando em uma variação de  $20m - 18m = 2m$  entre estas duas medições no eixo X.

**4. Percurso ao contornar um quarteirão em formato de letra "L":** A Figura 33 mostra o resultado obtido ao realizar uma trajetória fechada. Como descritos nas considerações sobre os testes no início desta seção, os valores X e Y são valores absolutos, dessa forma, neste teste, a trajetória obtida pelo gráfico e a imagem do *Google Maps* são "espelhados", pois neste teste foi realizado um percurso no sentido contrário aos outros apresentados anteriormente, assim, as posições teriam valores

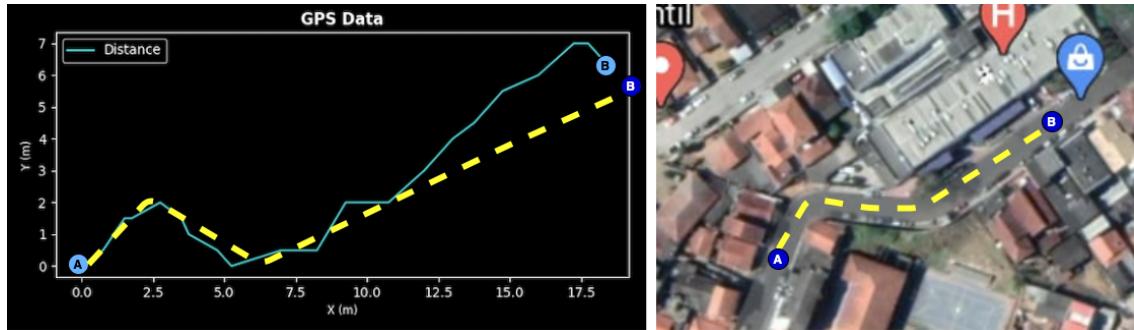


Figura 32 – Resultado da trajetória em linha reta do automóvel com o GPS

negativos, já que o deslocamento foi para "trás". A trajetória segue A para o sentido dos marcadores, em azul escuro, B →C →D →E →F.

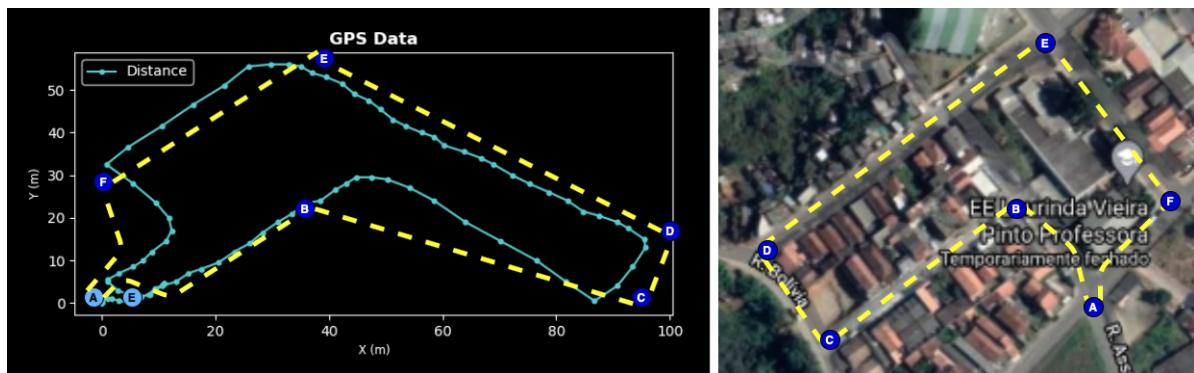


Figura 33 – Resultado de uma trajetória fechada

O percurso obtido com o módulo GPS inicia em A e finaliza em E, já o obtido pelo GPS do celular, os pontos inicial e final coincidem. Esse motivo pode ser causado por dois fatores: atraso na atualização dos dados no GPS ou pela perda dos sinais obtidos pelo módulo GPS, resultado nesse erro de medição.

Todos os resultados descritos anteriormente foram obtidos através de testes em locais mais abertos com poucos edifícios e vegetação, de forma a minimizar ao máximo a interferência da captura de dados do posicionamento geográfico, mas ainda assim é possível notar uma margem significativa de erro nessas medições. O Filtro de Kalman, que será abordado na próxima seção, foi implementado justamente com esse intuito, de melhorar a precisão dos dados do sistema de posicionamento do veículo.

## 5.4 Navegação usando a Fusão Sensorial entre IMU e GPS a partir do Filtro de Kalman

Esta seção apresenta os resultados obtidos pelo desenvolvimento do Filtro de Kalman. Para esta etapa foram realizados três testes, realizando trajetórias com auxílio de um automóvel, inserido dentro dele, o sistema de captação de dados (GPS + IMU). São considerações relevantes para este teste:

- A central de monitoramento contém as saídas de atitude do Filtro Complementar, utilizando o acelerômetro e o giroscópio para calcular o valor de *pitch*, *roll* e *yaw*.
- No Filtro de Kalman são utilizados 2 valores *yaw* obtidos de formas diferentes, a primeira pelo Filtro Complementar, que pode ser observada no gráfico da central de monitoramento; e a segunda pelo magnetômetro, que simula uma bússola.
- Diferentemente da Seção 5.3, que compara os dados obtidos pelo módulo GPS com o GPS do celular, os testes a seguir realizam a comparação **apenas** dos resultados do módulo GPS com da fusão sensorial pelos Filtros Complementar e de Kalman.
- Em todos os *screen shots* retirados da central de monitoramento a seguir, o gráfico 1 representa as saídas do Filtro Complementar, utilizando o acelerômetro e o giroscópio, que são as medidas de atitude *pitch*, *roll* e *yaw*; o gráfico 2 é a saída em coordenadas cartesianas da leitura realizada apenas com o módulo GPS, sem nenhum tipo de fusão sensorial; o gráfico 3 é o resultado do Filtro de Kalman, utilizando o Filtro Complementar, a bússola (implementada utilizando o magnetômetro da IMU) e o módulo GPS, com os passos descritos na seção 4.6; e o gráfico 4 é a sobreposição dos gráficos 3 e 4 para melhorar a visualização das diferenças obtidas entre elas.
- Todos os testes descritos a seguir, são trajetórias percorridas com uma velocidade média de 40 km/h.
- Todas as trajetórias realizadas pelo veículo são fechadas, ou seja, partem do ponto  $X = 0$  e  $Y = 0$  e terminam neste mesmo.
- As respostas obtidas pelo gráfico 1 das Figuras 34, 35 e 36 não foram atualizadas com os valores correntes de atitude (*pitch*, *roll* e *yaw*), utilizado no Filtro de Kalman.

Os testes realizados nesta etapa foram:

1. **Trajetória em formato de "número 8":** A Figura 34 mostra o resultado obtido neste percurso. Pode ser observado que em comparação ao gráfico 2, o 3 possui traços mais suaves com menos oscilações, isso se dá pela atuação do Filtro Complementar

na fase de propagação do Filtro de Kalman, os valores de altitude obtidos por esse primeiro método corrigem essas oscilações das medições realizadas apenas com o módulo GPS.

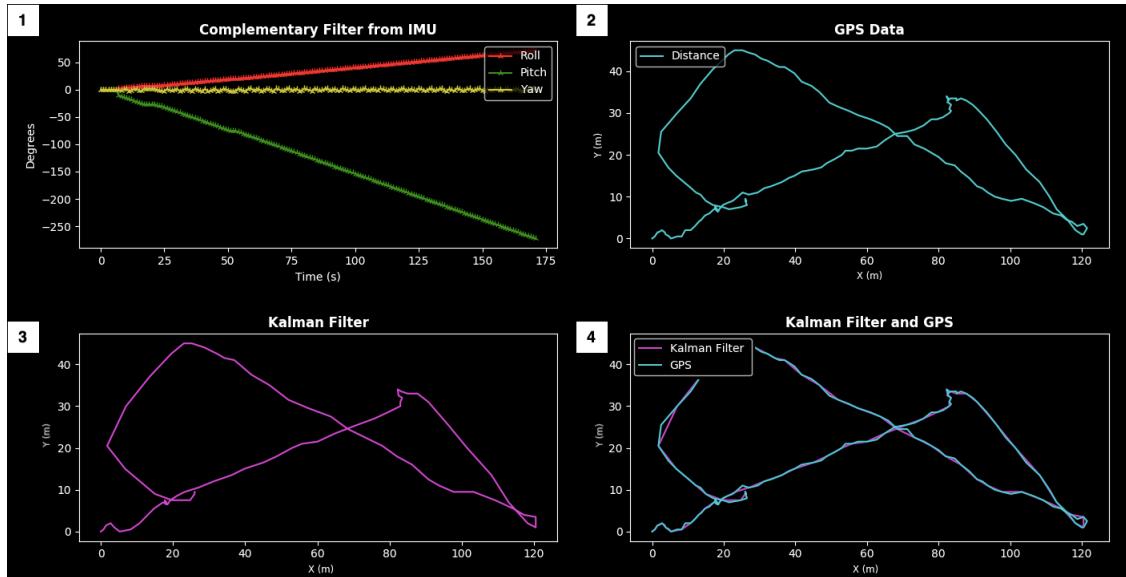


Figura 34 – Central de monitoramento em resposta a trajetória 1

2. **Trajetória contornando um quarteirão 1:** A Figura 35 mostra o resultado obtido neste percurso. Assim, no teste anterior, ser observada a atuação da correção da medição do módulo GPS com a de altitude obtida pelo Filtro Complementar. No intervalo  $[0, 25]$  no eixo x, há um enlaçamento ocasionado por uma interferência na captação de dados do módulo GPS, ocasionando um erro de medição que foi também propagado para o Filtro de Kalman, como observado no gráfico 3.
3. **Trajetória contornando um quarteirão 2** A Figura 36 mostra o resultado obtido neste percurso. Neste último teste realizado, além da resposta obtida pela central de monitoramento, foram recolhidos valores da variação no eixo X (em metros), Y (em metros) e o ângulo de guinada (em graus) em função do tempo (em segundos), e também da variação *bias* correspondente aos eixos x, y e z.

Todos os gráficos e análises realizadas a seguir são correspondente ao teste da Figura 36. Para facilitar o processo de análise, foram plotadas as variações das medições dos eixos x e y, e do *bias* em função do tempo, como já descrito anteriormente, obtendo os resultados mostrados a seguir, onde a linha azul e magenta, são, respectivamente, os valores obtidos pelo GPS e pela fusão sensorial com os Filtros Complementar e de Kalman.

- A Figura 37 mostra a variação do eixo X correspondente ao gráfico 4 da Figura 36, em metros, em função do tempo, em segundos.

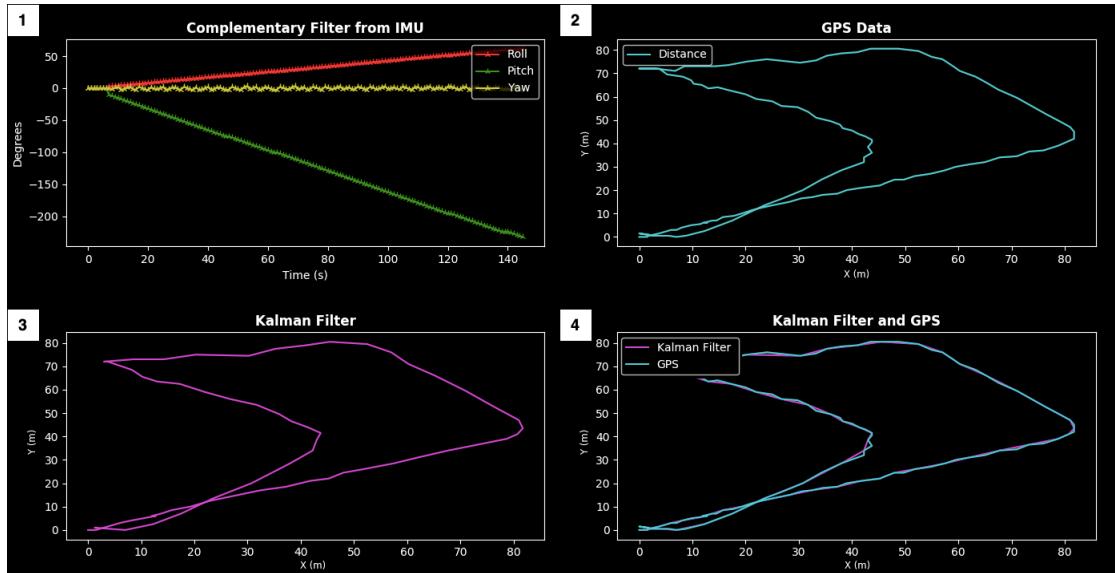


Figura 35 – Resposta da central de monitoramento com a trajetória 2

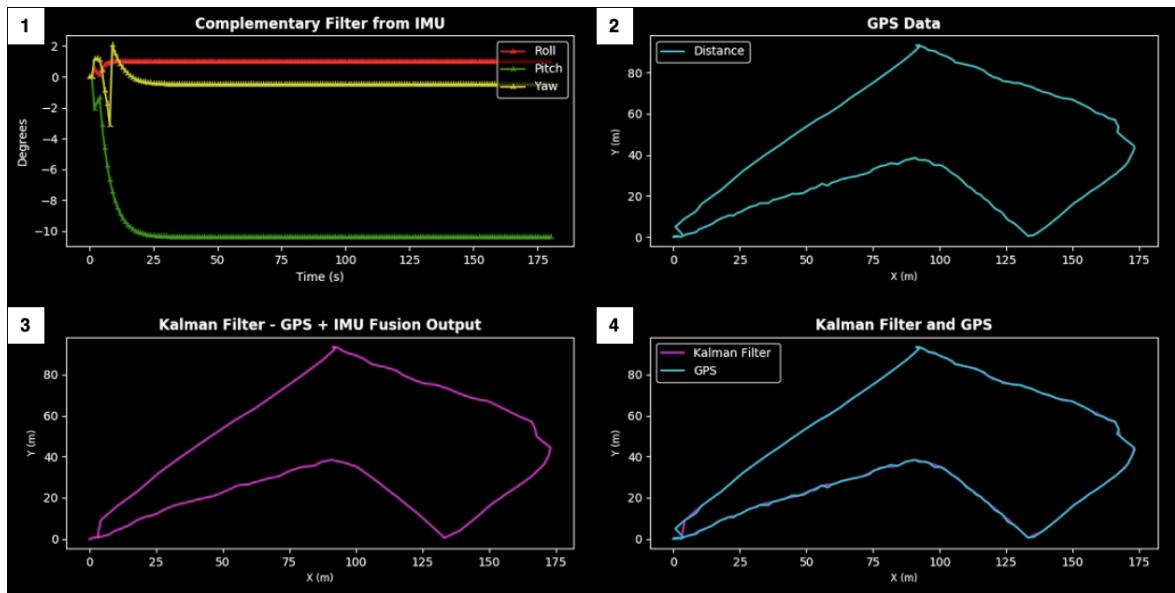


Figura 36 – Resposta da central de monitoramento com a trajetória 3

- A Figura 38 mostra a variação do eixo Y correspondente ao gráfico 4 da Figura 36, em metros, em função do tempo, em segundos.

Pode ser observada a grande diferença entre a medida do *yaw* utilizando o Filtro Complementar (curva amarela do gráfico 1 da Figura 36) e o obtido utilizando o magnetômetro. Dessa forma, podemos notar a grande vantagem da fusão sensorial, pois podemos melhorar as estimativas realizadas com uma técnica, utilizando outros sensores como "corretores", neste caso, o *yaw* obtido pela fusão sensorial pelo Filtro Complementar, com o acelerômetro e o giroscópio com a

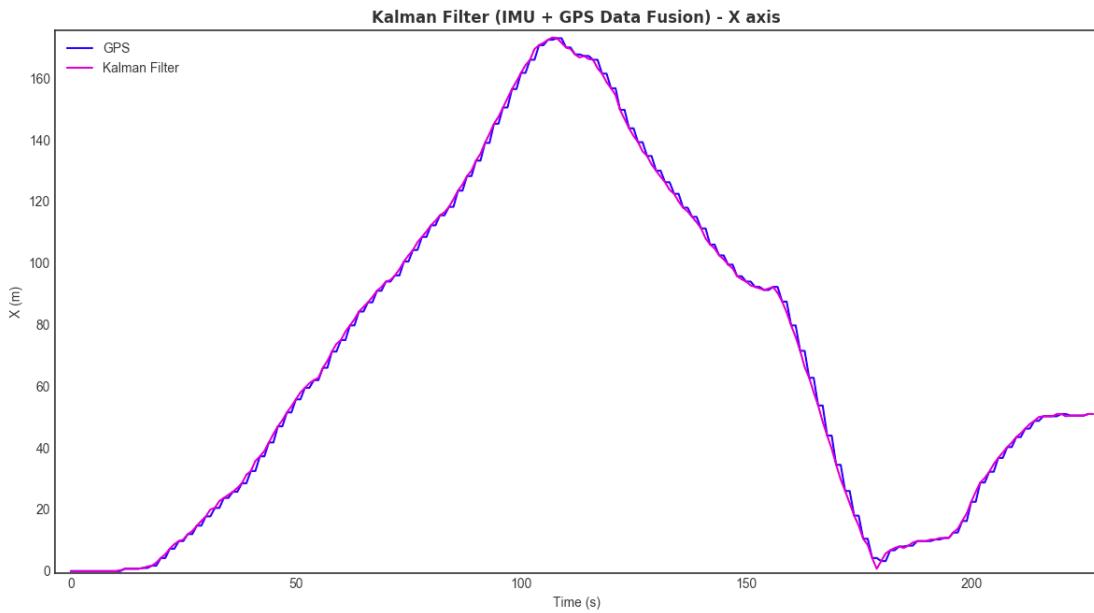


Figura 37 – Trajetória 3: Variação do eixo X em função do tempo

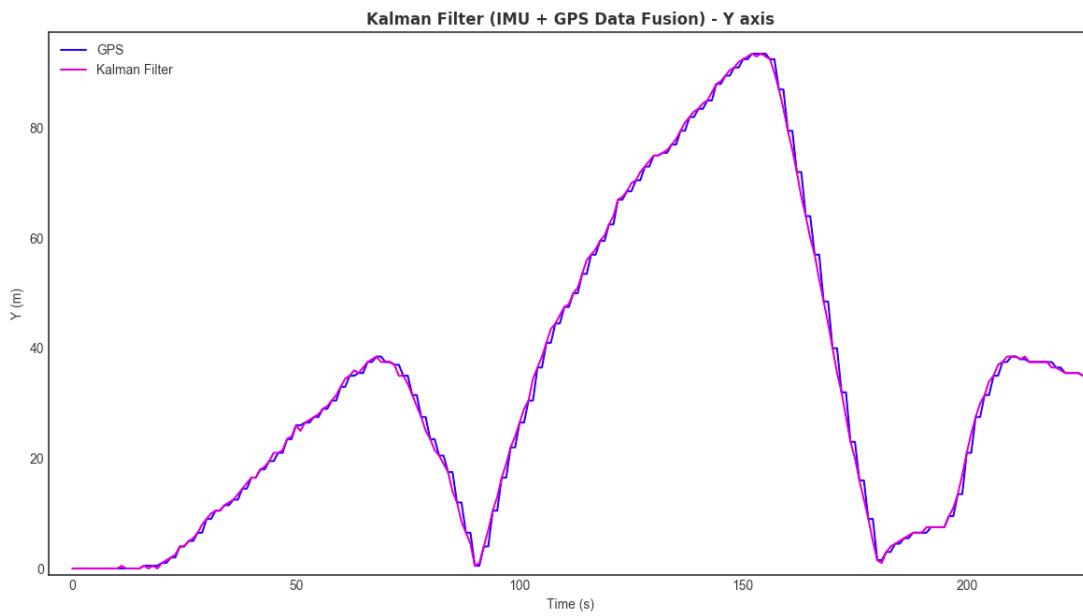


Figura 38 – Trajetória 3: Variação do eixo Y em função do tempo

medição pela bússola, implementada com o magnetômetro.

A partir da análise do comportamento dos eixos x, y e do ângulo de guinada, em função do tempo, é possível observar que a linha magenta, que representa a resposta do Filtro de Kalman, possui uma oscilação muito menor nos seus valores do que o obtido apenas com o módulo GPS.

A Figura 39 mostra a diferença entre a posição no eixo x, em metros, estimado pelo

Filtro de Kalman e o obtido apenas com o módulo GPS, ponto a ponto, ao longo do tempo.

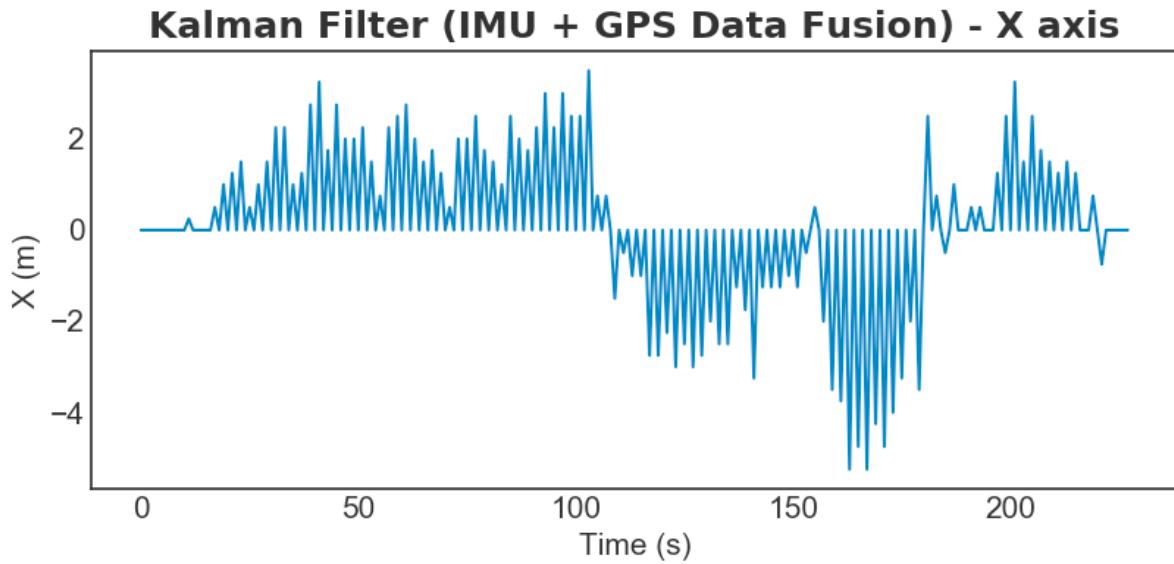


Figura 39 – Trajetória 3: Diferença observada entre o resultado do Filtro de Kalman e do módulo GPS, no eixo x, em função do tempo

A Figura 40 mostra a diferença entre a posição no eixo y, em metros, estimado pelo Filtro de Kalman e o obtido apenas com o módulo GPS, ponto a ponto, ao longo do tempo.

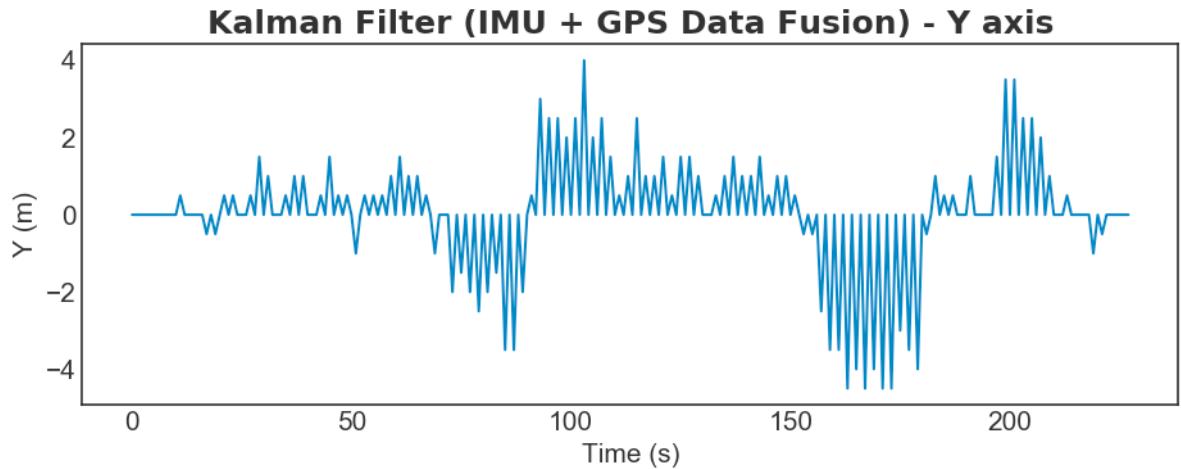


Figura 40 – Trajetória 3: Diferença observada entre o resultado do Filtro de Kalman e do módulo GPS, no eixo y, em função do tempo

Outro parâmetro importante para a análise do Filtro de Kalman é o *bias*. Para sua análise, foram armazenadas a variação do vetor *bias*, em função do tempo e

esboçados três gráficos, que mostram a variação do *bias* nos eixos x, y e z, em função do tempo, em segundos, como será mostrado a seguir.

A Figura 41 representa cada componente do vetor de *bias* estimado durante o teste, ou seja, o *bias* nos eixos x, y e z.

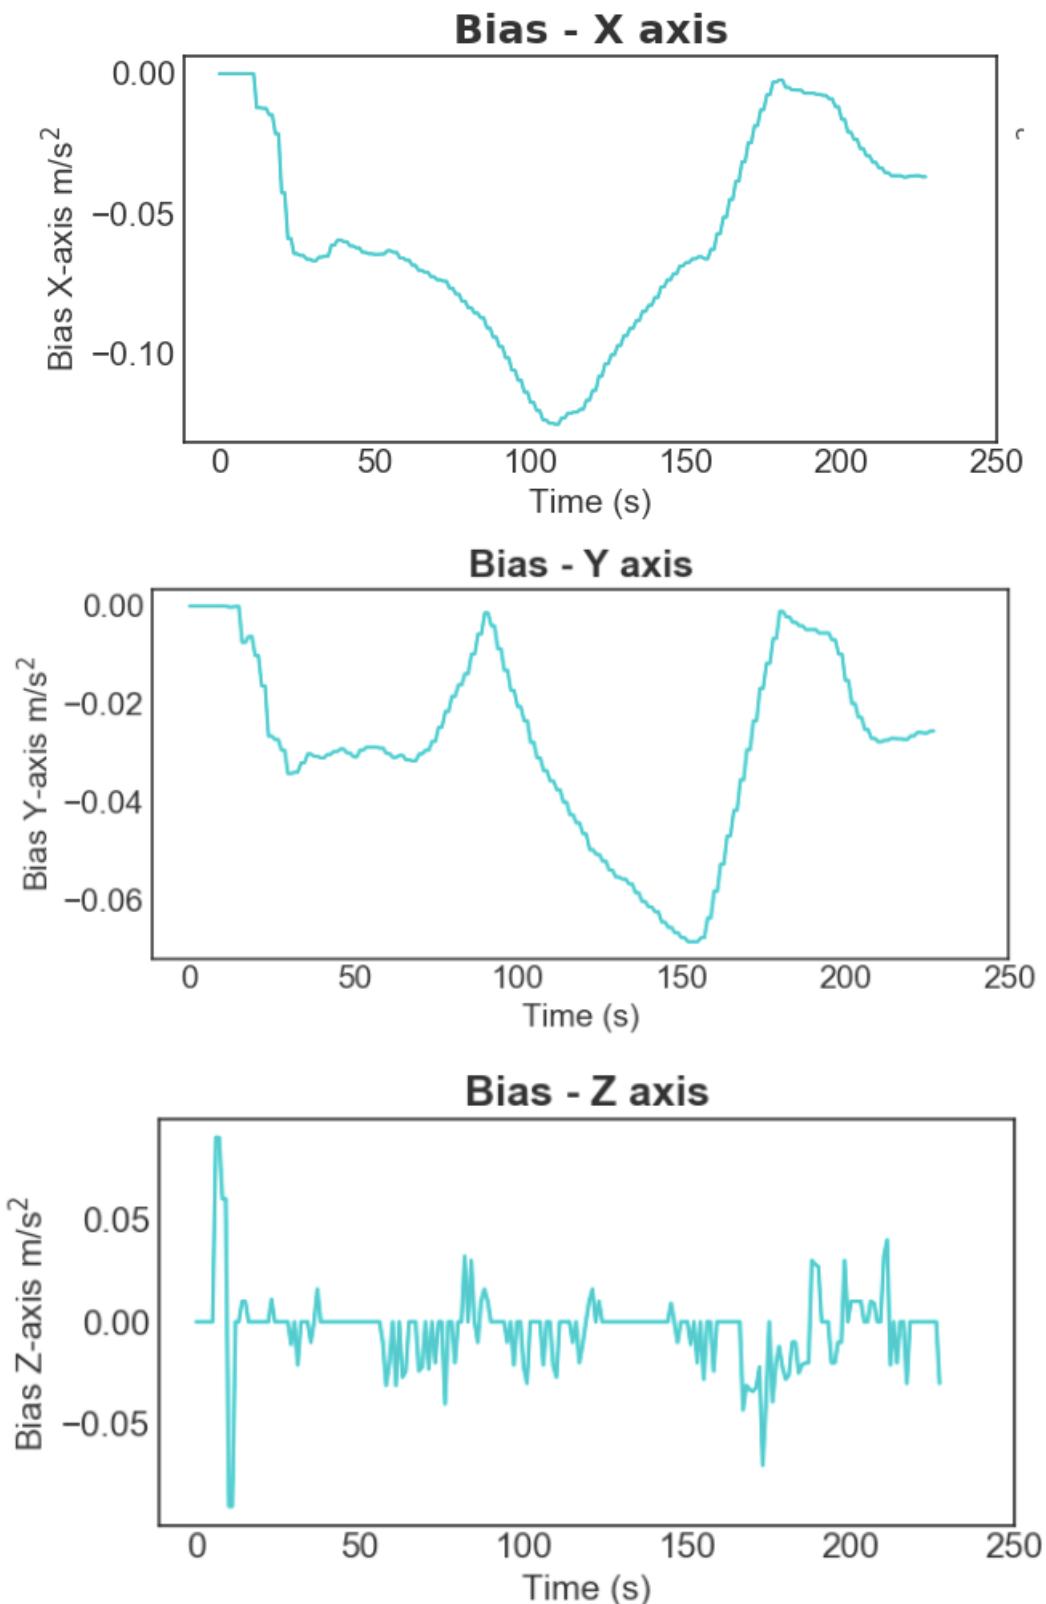


Figura 41 – Variação do vetor *bias*, em função do tempo, em segundos

Como descrito por (KHAN, 2019), o *bias* pode ser definido como a intensidade

do desvio que o sensor tem de seu valor médio da taxa de saída, ou seja, informa o quanto estável é a polarização de um sensor MEMS, no caso a IMU, ao longo de um determinado período de tempo. Podemos observar nos resultados obtidos pelos gráficos da Figura 41, correspondentes aos eixos x, y e z (guinada) são valores bem pequenos variando entre [-0.1, 0], [-0.06, 0] e [-0.06, 0.06], respectivamente. Podendo concluir que a IMU LSM9DS1 possui uma boa eficiência para o propósito deste trabalho.

O desenvolvimento da central de monitoramento em solo, a bússola, os Filtros Complementar e de Kalman e a interface gráfica estão disponíveis no repositório descrito no Anexo C. A partir dos testes descritos neste capítulo obtemos resultados positivos. No próximo capítulo serão descritas a conclusão e as considerações finais sobre o desenvolvimento do projeto.

## 6 Conclusão

Com o desenvolvimento do projeto e os testes montados com o sistema de captação de dados do posicionamento global e das medidas inerciais, pode-se concluir que os Filtros Complementar e de Kalman se comportaram de maneira eficiente para o presente propósito, que era desenvolver um sistema de baixo custo de implementação e melhorar a precisão obtida durante a medição do posicionamento de um veículo terrestre.

Os aspectos importantes encontrados durante o desenvolvimento do trabalho foram que a taxa de atualização do módulo IMU é maior que o do GPS. Essa diferença é de, aproximadamente, de 1 Hz; outra consideração importante é que a IMU possui grande vantagem, que diferente do módulo GPS, não é suscetível a perda de sinais decorrentes de barreiras físicas, que geram falhas na transmissão de sinais, como árvores e construções.

Com a análise dos resultados, pode ser notado que a medição do posicionamento do veículo utilizando apenas o GPS apresenta grandes valores de erro, e a fusão de dados com a IMU é uma forma de minimizá-lo. Através das respostas obtidas com a análise da central de monitoramento, com todos os testes realizados, foi possível observar que não há diferenças significativas em relação a distância percorrida apenas com o GPS e o Filtro de Kalman (fusão GPS + IMU), porém as oscilações do posicionamento estimado pelo filtro durante a trajetória são bem mais atenuadas. Isso também está associado a taxa de atualização dos dados pelo IMU que é muito maior do que do módulo GPS. E como descrito no desenvolvimento, as medições do acelerômetro e do giroscópio passaram por filtros antes da fusão, que diminuíram as incertezas desses valores. Em suma, a fusão INS/GPS melhora a precisão das medidas realizadas em comparação a apenas as medidas do GPS, porém a perda do sinal GPS faz com que o Filtro de Kalman divirja rapidamente.

Foram obtidos resultados positivos com os testes realizados com o sistema INS/GPS desenvolvido, a diferença entre a medição apenas com o módulo GPS e o resultante do Filtro de Kalman é perceptível ao percorrer pequenas distâncias e a baixa velocidade. Quando os valores desses parâmetros são elevados, as diferenças obtidas são praticamente imperceptíveis. Portanto todos os testes necessitaram estar sob essas condições descritas.

As maiores dificuldades encontradas durante o desenvolvimento do projeto foram encontrar parâmetros corretos de calibragem do filtro, que precisaram ser obtidos empiricamente e também a obtenção de sinal do módulo GPS utilizado, pois o sinal se encontra disponível apenas em ambientes extremamente abertos, em que não haja prédios ou árvores, pois qualquer interferência faz com que o módulo deixe de captar informações.

Um dos melhoramentos que pode ser realizados futuramente, acerca do projeto desenvolvido, é o estudo para substituição do módulo GPS NEO-6M, por outro que possua

menor sensibilidade às interferências físicas, descritas anteriormente, ou a integração de uma terceira fonte de dados de posicionamento global, como por exemplo, sensores ultrassônicos, sistemas acústicos, sistema de captura e processamento de imagens, entre outras, para que dessa forma, possa ser usufruído o melhor recurso que cada um desses componentes possa oferecer.

## Referências

- AHMAD, N.; GHAZILLA, R. A. R.; KHAIRI, N. M. Reviews on various inertial measurement unit, imu, sensor applications. *International Journal of Signal Processing Systems* Vol. 1, No. 2, University of Malaya, 2013. Citado 2 vezes nas páginas 40 e 71.
- ALATISE, M. B.; HANCKE, G. P. Pose estimation of a mobile robot based on fusion of imu data and vision data using an extended kalman filter. *Sensor*, Setembro, 2017. Citado na página 56.
- BERNARDI, J. V. E.; LANDIM, P. M. B. *Aplicação do sistema de posicionamento global (GPS) na coleta de dados*. UNESP/campus de Rio Claro Departamento de Geologia Aplicada - IGCE, 2002. Citado na página 36.
- BLEWITT, G. Basics of the gps technique: Observation equations. *Department of Geomatics, University of Newcastle Newcastle upon Tyne, NE1 7RU, United Kingdom*, 2001. Disponível em: <<http://gauss.gge.unb.ca/papers.pdf/gpsworld.july95.pdf>>. Citado na página 37.
- CABRAL, K. M. *Sistema de Navegação de Robôs Móveis em Ambientes Internos Baseado em Sensores Ultrassônicos*. 148 p. Monografia (Mestrado) — Instituto Tecnológico de Aeronáutica, São José dos Campos - SP, 2017. Citado 8 vezes nas páginas 28, 46, 47, 48, 52, 53, 54 e 73.
- CALACHE, D. C. *Caracterização de um Acelerômetro Baseado em Sistemas Microeletromecânicos (MEMS)*. Universidade do Estado do Rio de Janeiro, Centro de Tecnologia e Ciências, 2013. Citado 2 vezes nas páginas 15 e 41.
- CAMARA, G. *Representação computacional de dados geográficos*. Curitiba: Mundogeo, 2005. P. 11-52. Citado na página 72.
- CAMARA, G.; CASANOVA, M. A.; MAGALHAES, G. C. *Anatomia de sistemas de informação geográfica*. 1996. Citado 3 vezes nas páginas 15, 35 e 36.
- COSTA, J. H. R. *Implementação de Fusão Sensorial para Localização de um Veículo Autônomo*. Dissertação (Mestrado) — Universidade Federal de Minas Gerais, 2013. Citado 2 vezes nas páginas 40 e 55.
- EMBRAPA. *GPS – Global Positioning System*. 2015. [Online; accessed 29-Junho-2020]. Disponível em: <[https://www.cnpm.embrapa.br/projetos/sat/conteudo/missao\\_gps.html](https://www.cnpm.embrapa.br/projetos/sat/conteudo/missao_gps.html)>. Citado 2 vezes nas páginas 15 e 33.
- FARIA, A. P. de. Sistema de captura de movimentos baseados em unidade de medida inercial. In: *Anais do EVINCI-UniBrasil 3.2*. [S.l.: s.n.], 2018. Citado 3 vezes nas páginas 15, 41 e 43.
- FARRELL, J. *Aided navigation: GPS with high rate sensors*. [S.l.]: McGraw-Hill, Inc., 2008. P. 21. Citado na página 31.
- FARRELL, J.; BARTH, M. *The global positioning system and inertial navigation*. New York: McGraw-hill, 1999. Citado 3 vezes nas páginas 15, 31 e 32.

FILHO, E. A. M. *Navegação através de um Sistema Integrado GPS-INS Baseado em IMU não giroscópica*. Dissertação (Mestrado) — INPE, 2005. Dissertação de Mestrado. Citado na página 40.

FLORENZANO; CALLOTTI, T. *Imagens de Satélite para Estudos Ambientais*. [S.l.]: Oficina de Textos, 2002. Citado 2 vezes nas páginas 32 e 33.

FRANCA, A. *Simulação e Implementação em Tempo Real de Sistemas de Navegação Inercial Integrados INS / GPS*. Dissertação (Mestrado) — IME, 2009. Dissertação de Mestrado. Citado 3 vezes nas páginas 15, 39 e 40.

FRANCISCO, J.; MONICO, G. *Posicionamento pelo NAVSTAR - GPS Descrição, fundamentos e aplicações*. [S.l.]: Unesp, 2001. Citado 4 vezes nas páginas 17, 32, 36 e 38.

GABRIEL, T. A. R. *Desenvolvimento de sistema de navegação de baixo custo de veículo terrestre não tripulado*. Dissertação (Mestrado) — Instituto Militar de Engenharia, 2014. Dissertação de Mestrado. Citado 2 vezes nas páginas 42 e 43.

GIS, G. *Trilateration vs Triangulation – How GPS Receivers Work*. 2019. [Online; accessed 12-Abril-2020]. Disponível em: <<https://gisgeography.com/trilateration-triangulation-gps/>>. Citado 3 vezes nas páginas 15, 34 e 35.

HOSSEINYALAMDARY, S. Deep kalman filter: Simultaneous multi-sensor integration and modelling; a gnss/imu case study. *Sensor*, 2018. Citado na página 42.

HUNTER, J. et al. *Matplotlib: Visualization with Python*. 2020. <<https://matplotlib.org>>. [Online; accessed 1 de julho de 2020]. Citado na página 66.

ISLAM, T. et al. Comparison of complementary and kalman filter based data fusion for attitude heading reference system. *AIP Conference Proceedings 1919*, 2017. Citado 3 vezes nas páginas 15, 44 e 45.

KHAN, J. What is bias stability and why is it a key parameter for inertial sensor performance. *BMJ quality safety*, 2019. Citado na página 91.

KHRONOS, G. *OpenGL API Documentation Overview*. 2013. [Online; accessed 30-Junho-2020]. Disponível em: <<https://www.opengl.org/documentation/>>. Citado na página 68.

KUGA et al. *Satélites Artificiais–Movimento Orbital*. INPE, 2000. Citado na página 33.

LI1, W.; WANG, J. Effective adaptive kalman filter for mems-imu/magnetometers integrated attitude and heading reference systems. *The Journal of Navigation*, 2012. The Royal Institute of Navigation. Citado 5 vezes nas páginas 40, 41, 62, 63 e 70.

LIU, F. et al. An adaptive uwb/mems-imu complementary kalman filter for indoor location in nlos environment. *remote sensing*, Novembro, 2019. Citado na página 56.

MACIEL, G. M. *Sistema de Navegação Semiautônomo para Robótica Móvel Assistiva Baseado em Movimentos de Cabeça e Comandos de Voz*. 100 p. Monografia (Pós graduação) — Universidade Federal de Juiz de Fora, 2018. Citado na página 28.

MACIEL, J. G. et al. *A Antiga Matemática na Atual Tecnologia*”. [S.l.]: Revista Módulos -TACOS/CNEC, Brasil, p 15-28, 2012. Citado 2 vezes nas páginas 27 e 39.

- MAELE, P.-J. V. de. *Reading a IMU Without Kalman: The Complementary Filter*. 2013. <<https://www.pieter-jan.com/node/11>>. Citado na página 45.
- MARCHI, A. A. Implementação de uma bússola digital. *Trabalho de Conclusão de Curso apresentado à Escola de Engenharia de São Carlos, da Universidade de São Paulo*, 2009. Citado na página 62.
- MARQUES, A. P. da S.; DECANINI, M. M. S.; PUGLIES, E. A. Sistema de navegação e guia de rota áudio-dinâmico com múltiplas escalas automáticas. *Revista Brasileira de Cartografia N0 64/1: 57-68*, 2012. P. 58. Citado na página 31.
- MATHWORKS. *atan2*. 2011. <<https://www.mathworks.com/help/matlab/ref/atan2.html#buct8h0-4>>. [Online; accessed 6 de março de 2019]. Citado na página 43.
- MONTELLA, C. The kalman filter and related algorithms: A literature review. 2011. Citado na página 46.
- NASCIMENTO, P. P. L. L. do. *Uma Solução Cooperativa Positioning Integrada com Dead Reckoning para Suporte a GPS Sem Linhas de Visada Utilizando a Tecnologia de Radio*. [S.l.]: Simpósio Brasileiro de Redes de Computadores (SBRC), 2018. Citado 2 vezes nas páginas 27 e 39.
- OLIVEIRA, D. F. de. *Implementação de um Sistema de Navegação INS/GPS, Aplicado a Agricultura de Precisão*. Florianópolis, 2012. Citado 2 vezes nas páginas 40 e 55.
- OLIVEIRA, W. dos S.; NUNES, E. Implementação em c: Filtro de kalman, fusão de sensores para determinação de ângulos. *ForScience*, 2017. Citado 7 vezes nas páginas 15, 27, 43, 44, 54, 62 e 63.
- POOLE, M. *Improved Localization in UWA REV Autonomous Driving SAE Vehicle Through IMU, GPS, Wheel Encoders and Extended Kalman Filter*. 52 p. Monografia (Mestrado) — University of Western Australia, 2017. Citado na página 55.
- SANTANA, D. D. S. *Navegação terrestre usando unidade de medição inercial de baixo desempenho e fusão sensorial com Filtro de Kalman adaptativo suavizado*. Tese (Doutorado) — Escola Politécnica da Universidade de São Paulo, São Paulo, 2011. Citado 3 vezes nas páginas 15, 36 e 55.
- SANTANA, D. D. S. et al. *Estimação de trajetórias utilizando sistema de navegação inercial strapdown*. São Paulo, 2004. Citado na página 35.
- SCILAB. *Arco-tangente 2-quadrantes e 4-quadrantes*. 2017. <[https://help.scilab.org/docs/5.3.2/pt\\_BR/atan.html](https://help.scilab.org/docs/5.3.2/pt_BR/atan.html)>. [Online; accessed 6 de março de 2019]. Citado na página 43.
- SIMON, D. Kalman filtering. *Embedded System Programming*, 2001. Citado 8 vezes nas páginas 19, 26, 27, 54, 101, 102, 104 e 110.
- SPARKFUN. *LSM9DS1 Breakout Hookup Guide*. 2016. <<https://learn.sparkfun.com/tutorials/lsm9ds1-breakout-hookup-guide#lsm9ds1-overview>>. Citado na página 60.
- SPARKFUN. *LSM9DS1 Breakout*. 2018. <>. [Online; accessed 4 de julho de 2020]. Citado 2 vezes nas páginas 15 e 70.

STMICROELECTRONICS. *LSM9DS1: Datasheet - production data*. 2015. [Online; accessed 20-Outubro-2020]. Disponível em: <<https://www.st.com/resource/en/datasheet/lsm9ds1.pdf>>. Citado na página 70.

T.HIGGINS, J. R. W. A comparison of complementary and kalman filtering. *IEEE TRANSACTIONS ON AEROSPACE AND ELECTRONIC SYSTEMS*, Arizona State University, 1975. Citado na página 44.

UBLOX. *NEO-6 u-blox 6 GPS Modules*. 2018. [Online; accessed 12-Outubro-2018]. Disponível em: <[https://www.u-blox.com/sites/default/files/products/documents/NEO-6\\_DataSheet\\_\(GPS.G6-HW-09005\).pdf](https://www.u-blox.com/sites/default/files/products/documents/NEO-6_DataSheet_(GPS.G6-HW-09005).pdf)>. Citado na página 60.

VARGAS, R. M. de A. *ANÁLISE DA APLICAÇÃO DO SISTEMA DE POSICIONAMENTO GLOBAL (GPS) EM LEVANTAMENTO TOPOGRÁFICO DE VIAS URBANAS*. 139 p. Monografia (Mestrado) — Universidade Federal de São Carlos, São Carlos - SP, 2001. Citado na página 32.

VASCONCELOS STUDENT MEMBER, I. B. C. C. S. M. I. P. O. M. I. J. F.; BATISTA STUDENT MEMBER, I. P. *Discrete-Time Complementary Filters for Attitude and Position Estimation: Design, Analysis and Experimental Validation*. 2011. <<http://www.dem.tecnico.ulisboa.pt/poliveira/Invest/TCST2040619.pdf>>. [Online; accessed 6 de março de 2019]. Citado na página 61.

WELCH, G.; BISHOP, G. An introduction to the kalman filter. *Department of Computer Science*, 1995. Citado 2 vezes nas páginas 46 e 47.

YOO, T. S. et al. Gain-scheduled complementary filter design for a mems based attitude and heading reference system. *Sensors*, 2011. Citado 3 vezes nas páginas 15, 44 e 61.

ZANONI, F. D. *Modelagem e Implementação do Sistema de Navegação para um AUV*. Dissertação (Mestrado) — Universidade de São Paulo, 2012. Dissertação de Mestrado. Citado 8 vezes nas páginas 15, 35, 36, 40, 51, 52, 53 e 54.

# Apêndices

# APÊNDICE A – Filtro de Kalman proposto por (SIMON, 2001)

O Filtro de Kalman proposto por (SIMON, 2001), em Matlab, analisa a variação da velocidade e do posicionamento de um veículo terrestre. Este algoritmo (em Anexo B.1) realiza a estimativa da velocidade e da posição ao longo do tempo e também dos erros atrelados a estas. Sendo considerado um veículo percorrendo uma estrada, com a posição medida com um desvio padrão de 10 ft e o ruído decorrente da medida da aceleração, possuindo um desvio padrão de  $0.2 \frac{ft}{s^2}$ .

Como pode ser observado no código B.1, a função da simulação possui dois parâmetros de entrada: a duração (em segundos) em que o veículo percorre a estrada e o  $dt$ , que representa o tamanho do passo, ou seja, o tempo (em segundos) necessário para se obter um valor de posicionamento do veículo. Utilizando uma duração de 60 segundos e um tempo  $T = 0.1dt$ , foram obtidos os resultados, descritos abaixo.

- A Figura 42 mostra o posicionamento do veículo, em pés, ao decorrer do tempo, em segundos. A curva em vermelho representa as posições medidas, em verde, as reais e em laranja, as estimadas.
- A Figura 43 representa o erro obtido através da medição do posicionamento do veículo (linha azul) e o erro obtido pela estimativa utilizando o Filtro de Kalman (em vermelho). Pela observação do gráfico, pode-se notar que o erro obtido pelo estimador é extremamente próximo a zero, quanto que o obtido pela medição possui grandes distorções e ruídos atrelados aos valores reais.
- A Figura 44 representa os valores de velocidade medida, curva em vermelho, e a velocidade estimada pelo Filtro de Kalman, em azul. Mesmo com a aproximação (gráfico menor) há uma dificuldade de observar diferenças significativas entre a curva de velocidade real do veículo e a estimada.
- E por final, a Figura 45 representa o erro obtido durante a estimativa da velocidade ao decorrer do tempo. Podendo notar que esse erro é muito próximo à zero, variando, aproximadamente, no intervalo entre  $-0.35 \frac{ft}{s}$  a  $0.2 \frac{ft}{s}$ .

Através das observações descritas anteriormente, pode-se notar os resultados positivos e consistentes da aplicação do Filtro de Kalman. Os valores medidos possuem quantidade significativa de ruídos, enquanto os obtidos pelo estimador estão bem próximos

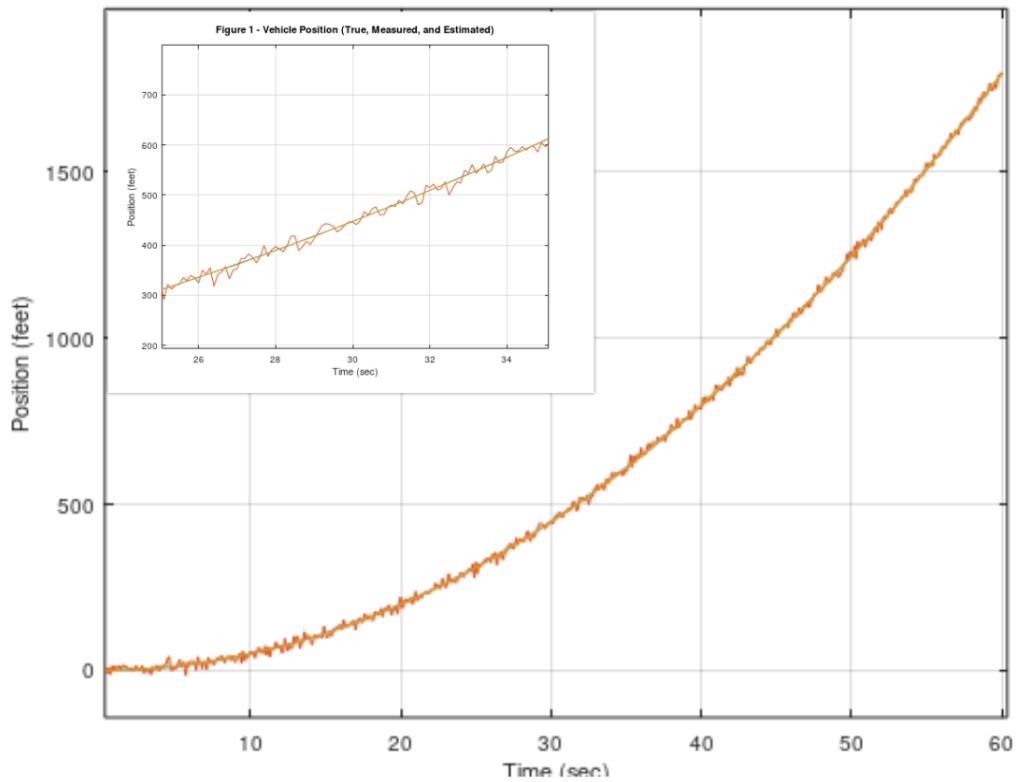
**Figure 1 - Vehicle Position (True, Measured, and Estimated)**

Figura 42 – Posicionamento do veículo em função do tempo

aos valores reais. Isso pode ser observado principalmente na Figura 43, o erro ao longo da duração do teste para os valores de medição, possuem grandes variações, já o erro associado às saídas do estimador estão bem próximos a zero.

Com a observação da eficácia do Filtro de Kalman para o desenvolvimento de sistemas de baixo custo e para a obtenção de estimativas próximas aos dados reais, a próxima etapa é o desenvolvimento do Filtro de Kalman utilizando os dados obtidos com o sistema constituído pela IMU e pelo módulo GPS.

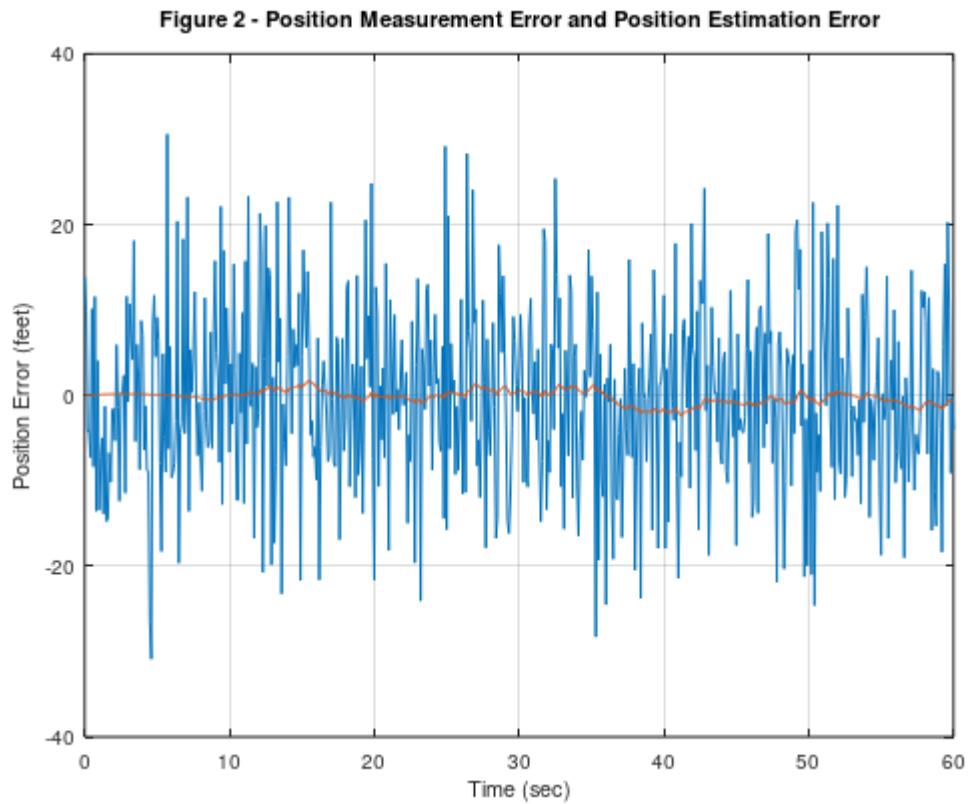


Figura 43 – Erro obtido pela medição e o obtido pelo estimador (Filtro de Kalman)

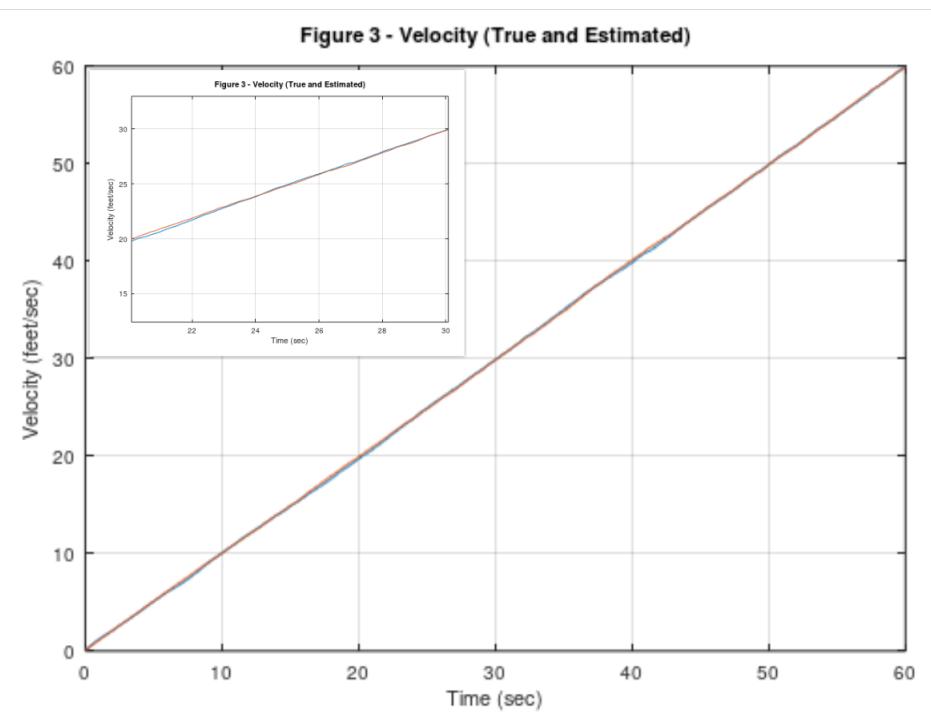


Figura 44 – Velocidade medida e estimada do veículo

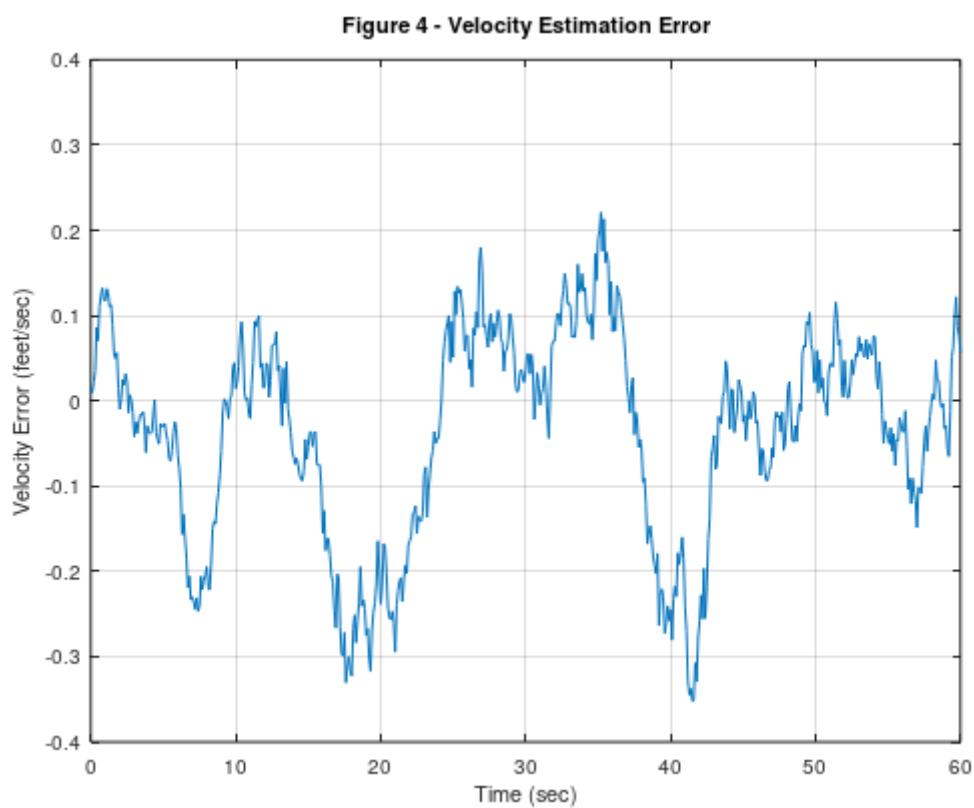


Figura 45 – Erro na estimação da velocidade do veículo

## Anexos

# ANEXO A – Filtro Complementar

```

1 void complementaryFilter (float ax, float ay, float az, float gx, float gy, float mx,
2   float my, float mz){
3
4   float pitchAcc, rollAcc;
5
6   pitch += (float)(gx/ GYROSCOPE_SENSITIVITY)* dt;
7   roll -=(float)(gy/ GYROSCOPE_SENSITIVITY) * dt;
8
9   int forceMagnitudeApprox = abs(ax) + abs(ay) + abs(az);
10  if (forceMagnitudeApprox > 8192 && forceMagnitudeApprox < 32768)
11  {
12    pitchAcc = atan2(ay, az) * 180 / PI;
13    pitch = (pitch * 0.98) + (pitchAcc * 0.02);
14
15    rollAcc = atan2(ax, az) * 180 / PI;
16    roll = (roll * 0.98) + (rollAcc * 0.02);
17  }
18
19  yaw = atan2(-my*cos(roll) + mz*sin(roll), mx*cos(pitch) + my*sin(pitch)*sin(roll) +
20    mz*sin(pitch)*cos(roll));
21
22  Serial.print(roll);
23  Serial.print(",");
24  Serial.print(pitch);
25  Serial.print(",");
26  Serial.print(yaw);
27  Serial.println(",0,0,0,0");
28 }

```

Pseudocódigo A.1 – Implementação do Filtro Complementar no Arduino

## ANEXO B – Simulação do Filtro de Kalman

```

1
2 function kalman(duration, dt)
3
4 %function kalman(duration, dt)
5 %Kalman filter simulation for a vehicle travelling along a road. %INPUTS
6 %duration = length of simulation (seconds)
7 %dt = step size (seconds)
8   measnoise = 10; % position measurement noise (feet)
9   accelnoise = 0.2; % acceleration noise (feet/sec^2)
10  a = [1 dt; 0 1]; % transition matrix b = [dt^2/2; dt]; % input matrix
11  c = [1 0]; % measurement matrix
12  x = [0; 0]; % initial state vector xhat = x; % initial state estimate
13  Sz = measnoise^2; % measurement error covariance
14  Sw = accelnoise^2 * [dt^4/4 dt^3/2; dt^3/2 dt^2]; % process noise cov
15  P = Sw; % initial estimation covariance
16  % Initialize arrays for later plotting. pos = []; % true position array
17  poshat = []; % estimated position array
18  posmeas = []; % measured position array
19  vel = []; % true velocity array
20  velhat = []; % estimated velocity array
21  for t = 0 : dt: duration,
22    % Use a constant commanded acceleration of 1 foot/sec^2.
23    u = 1;
24    % Simulate the linear system.
25    ProcessNoise = accelnoise * [(dt^2/2)*randn; dt*randn];
26    x = a * x + b * u + ProcessNoise;
27    % Simulate the noisy measurement
28    MeasNoise = measnoise * randn;
29    y = c * x + MeasNoise;
30    % Extrapolate the most recent state estimate to the present time.
31    xhat = a * xhat + b * u;
32    % Form the Innovation vector.
33    Inn = y - c * xhat;
34    % Compute the covariance of the Innovation.
35    s = c * P * c' + Sz;
36
37    % Form the Kalman Gain matrix.
38    K = a * P * c' * inv(s);
39    % Update the state estimate.
40    xhat = xhat + K * Inn;
41    % Compute the covariance of the estimation error.
42
43    P = a * P * a' - a * P * c' * inv(s) * c * P * a' + Sw; % Save some parameters
44    % for plotting later.
45    pos = [pos; x(1)];
46    posmeas = [posmeas; y];
47    poshat = [poshat; xhat(1)]; vel = [vel; x(2)];
48    velhat = [velhat; xhat(2)];
49  end
50  % Plot the results close all;
51  t = 0 : dt : duration;
52  figure;
53  plot(t,pos, t, posmeas, t, poshat);
54  grid;

```

```
54 xlabel('Time (sec)');
55 ylabel('Position (feet)');
56 title('Figure 1 - Vehicle Position (True, Measured, and Estimated)');
57 figure;
58 plot(t, pos-posmeas, t, pos-poshat);
59 grid;
60 xlabel('Time (sec)');
61 ylabel('Position Error (feet)');
62 title('Figure 2 - Position Measurement Error and Position Estimation Error');
63 figure;
64 plot(t, vel, t, velhat);
65 grid;
66 xlabel('Time (sec)');
67 ylabel('Velocity (feet/sec)');
68 title('Figure 3 - Velocity (True and Estimated)');
69 figure;
70 plot(t, vel-velhat);
71 grid;
72 xlabel('Time (sec)');
73 ylabel('Velocity Error (feet/sec)');
74 title('Figure 4 - Velocity Estimation Error');
```

Pseudocódigo B.1 – Simulação do Filtro de Kalman (SIMON, 2001)

## ANEXO C – Repositório no GitHub

Todas as aplicações desenvolvidas no projeto estão disponíveis em um repositório remoto, na plataforma do GitHub, tais como este trabalho textual e o vídeo apresentado à banca, que demonstra a execução dos testes realizados com o Sistema de Navegação GPS/INS através dos Filtros Complementar e de Kalman. Acesse o repositório em <https://github.com/rosangela-shigenari/navigation-system-sensory-fusion>.

O repositório está organizado em três diretórios:

- **arduino\_files**: Contém os arquivos do desenvolvimento no Arduino. Nesse diretório estão o `navigation-system.ino`, que é a função principal que organiza toda a lógica da chamada de cada fase do Filtro de Kalman; o `kalman-filter.ino` que possui a implementação das fases do Filtro de Kalman; o `gps-data.ino`, que possui a lógica de recebimento dos dados do GPS e as funções de conversão de coordenadas geodésicas para cartesianas; `imu-data.ino`, que contém o desenvolvimento do Filtro Complementar da bússola e o `auxiliar-functions.ino`, que possui funções auxiliares utilizadas no Filtro de Kalman.
- **python\_files**: Contém o desenvolvimento da aplicação da estação de monitoramento em solo. O arquivo `interface.py` contém o desenvolvimento da interface gráfica, que simula a rotação do objeto no espaço 3D utilizando como entrada, o resultado obtido com o Filtro Complementar; o `cockpit.py` é a aplicação referente aos gráficos que mostram os resultados obtidos pelo Filtro Complementar, os dados recebidos pelo módulo GPS convertidos em coordenadas cartesianas e os resultados obtidos pela fusão sensorial através do Filtro Complementar e de Kalman; o `kalman_oficial.txt` são os dados gerados no experimento do item 3 descrito na seção 5.3, sendo uma demonstração de um arquivo enviado à central de monitoramento.
- **monograph**: Contém um txt com o *link* para o Google Drive, que contém este PDF e o vídeo apresentado à banca.